



UNAM

Facultad de Ciencias

Licenciatura Ciencias de la computación

Inteligencia Artificial

Dra. Jessica Sarahi Méndez Rincón

Tema 4 – Actividad 1 Métricas y Aprendizaje Supervisado

Objetivo

Aplicar conceptos relacionados a Métricas y Aprendizaje Supervisado (Regresión, SVM, K-NN, Naive Bayes).

Formato: Hoja tamaño carta entregada en clase/classroom, legible, con títulos por ejercicio.

Tiempo: Resolver individualmente (máx. 60 min en clase, 5 minutos por ejercicio aprox.).

Entrega: Entregar por escrito en cuaderno u hojas blancas en clase o mediante la actividad en classroom.

Nota importante: Se debe entregar durante el día de la actividad para ser evaluado sobre 100, después serán sobre 85.

1. Matriz de confusión + métricas

Ejercicio 1: Construcción básica

Se tiene el siguiente resultado de un clasificador binario:

- TP = 50
- FP = 10
- FN = 5
- TN = 35

Preguntas:

1. Construir la matriz de confusión
2. Calcular:
 - Accuracy
 - Precision
 - Recall
 - F1-score
3. *Discusión:* ¿Qué métrica es más importante si es detección de enfermedad?



2. Métricas con desbalance de clases

Ejercicio 2: Dataset médico: detección de enfermedad (solo 5% positivos)

	Pred: Sí	Pred: No
Real: Sí	8	2
Real: No	90	900

Preguntas:

1. ¿Accuracy es una buena métrica aquí?
2. Calcula Recall y Precision
3. ¿Qué métrica priorizarías y por qué?
4. ¿Es un buen modelo? ¿Por qué?

3. Error en regresión (MSE vs MAE)

Ejercicio 3: Predicciones de precios:

Real	Pred
100	90
200	210
300	1000

Calcular:

1. MAE
2. MSE
3. Pregunta de reflexión, ¿Cuál penaliza más errores grandes?

4. Regresión lineal

Ejercicio 4: Interpretación de coeficientes

Modelo:

$$y = 5 + 2x_1 - 3x_2$$

Preguntas:

1. Interpretar cada coeficiente
2. ¿Qué pasa si x_2 aumenta?

5. Regresión logística (interpretación)

Ejercicio 5. Modelo:

$$P(y = 1|x) = \frac{1}{1 + e^{-(2x-4)}}$$

Preguntas:

- ¿Qué pasa cuando $x = 2$?
- ¿Cuál es el umbral de decisión?
- ¿Qué significa el coeficiente 2?



6. Support Vector Machines (SVM)

Ejercicio 6: Margen máximo

Dado un plano con puntos separables:

Clase+1: (2,2), (3,3)

Clase -1: (0,0), (1,1)

Preguntas:

1. Dibujar los puntos
2. Proponer una recta separadora
3. Identificar soporte vectorial (intuitivo)

Ejercicio 7. SVM con kernel

Un dataset NO es linealmente separable.

Preguntas conceptuales:

1. ¿Por qué falla un SVM lineal?
2. ¿Por qué usar un kernel?
3. En un ejemplo con datos en forma de círculo, explicar cómo el kernel RBF soluciona el problema
4. Dar un ejemplo real

7. K-NN

Ejercicio 8: Clasificación manual

Puntos:

Clase A: (1,1), (2,2)

Clase B: (4,4), (5,5)

Nuevo punto: (3,3)

Preguntas:

1. Clasificar con $k = 1$
2. Clasificar con $k = 3$
3. ¿Qué cambia?

Ejercicio 9: Escalamiento de variables

Dataset con:

- Edad (0–100)
- Ingreso (0–1,000,000)

Pide:

1. ¿Qué problema hay en k-NN?
2. ¿Cómo solucionarlo?

Tip: **normalización / estandarización**

8. Naive Bayes

Ejercicio 10: Clasificación probabilística

Dataset:



Actividad 1 - Tema 4 Algoritmos de aprendizaje

Clase	P(A)	P(B)
Spam	0.6	0.7
No Spam	0.2	0.3

Prior:

- $P(\text{Spam}) = 0.4$
- $P(\text{No Spam}) = 0.6$


Nuevo correo:

- Contiene A y B

Calcular:

1. $P(\text{Spam} \mid \text{datos})$
2. $P(\text{No Spam} \mid \text{datos})$
3. Clasificar
4. ¿La independencia es real?

Problema ⑥ ①-



Clase +1 {azul} = (2,2) y (3,3)

Clase -1 {rojo} = (0,0) y (1,1)

②- Como todos los puntos están sobre $y=x$ son perfectamente separables por una recta perpendicular a esa diagonal, que pasa entre (2,2) y (1,1). Una recta que lo separe intuitivamente es: $x+y=3$

Comprobación

C: Para (0,0): $0+0=0 < 3 \rightarrow$ lado -1D: Para (1,1): $1+1=2 < 3 \rightarrow$ lado -1A: Para (2,2): $2+2=4 > 3 \rightarrow$ lado +1B: Para (3,3): $3+3=6 > 3 \rightarrow$ lado +1

Alternativa Simétrica: La recta $x+y=3$ está bien pero también podríamos elegir 3.5 o una bisectriz perpendicular exacta entre los puntos más cercanos. El punto medio entre (1,1) y (2,2) es (1.5, 1.5). Una recta perpendicular $xy=x$ tiene pendiente -1

Ecuación que pasa por (1.5, 1.5) con pendiente -1

$$y - 1.5 = -(x - 1.5)$$

$$y = -x + 3$$

$$\underline{y + x = 3}$$

③- Los vectores de soporte es SVM son los puntos más cercanos al margen de separación aquellos que sostienen al margen máximo.

Entre los puntos de una clase y otra, la menor distancia entre el plano de características aquí es el mismo plano (x,y) ocurre entre (1,1) de la clase -1 y (2,2) de la clase +1. Por lo tanto:

Vectores de soporte (1,1) y (2,2) los puntos (0,0) y (3,3) no son de soporte porque están más lejos de la recta $x+y=3$ y no definen el margen

Problema ⑦ ①- Un SVM lineal busca separar las clases mediante una línea recta en 2D o hiperplano

en dimensiones superiores. Si los datos están mezclados de tal forma que no existe ninguna línea recta capaz de dividir los grupos sin cometer errores masivos (como cuando una clase rodea a la otra) el modelo lineal simplemente no puede encontrar una solución válida. Por lo tanto falla cuando los datos no son linealmente separables.

2.- El truco del Kernel permite proyectar los datos de su espacio original a un espacio de mayor dimensión donde si sean linealmente separables sin necesidad de calcular explícitamente esa transformación (Truco del Kernel)

Beneficios:

- 1.- Encontrar separaciones no lineales en el espacio original
- 2.- Mantener la eficiencia computacional del SVM lineal
- 3.- Usar funciones como polinomial, RBF, sigmoide

Formula clave $K(X_i, X_j) = \phi(X_i) \cdot \phi(X_j)$

El SVM trabaja con productos punto en el espacio transformado $\phi(X)$

ϕ : función que lleva los datos a un espacio más complejo para que el SVM funcione mejor

3.- Imagina un tiro al blanco, los puntos rojos son el centro y los puntos azules son el anillo exterior. No puedes pasar una línea recta que los separe.

Al aplicar un Kernel RBF (Radical Basis Function): $K(X, y) = \exp\left(-\frac{\|X - y\|^2}{2\sigma^2}\right)$

- El modelo mide la distancia de cada punto hacia un centro

- Los puntos del centro (rojos) "se elevan" en una tercera dimensión (2) mientras que los anillos azules se quedan abajo

- Ahora puedes pasar por un plano horizontal como un hoja de papel entre los puntos elevados y los puntos de abajo. Al proyectar ese corte de regreso al plano 2D, se ve como un círculo perfecto

4.- Un ejemplo clásico es el reconocimiento de rostros o la clasificación de imágenes complejas. En una imagen los píxeles no tienen una relación lineal sencilla. Las características que definen un ojo o una boca dependen de combinaciones no lineales de luz y sombra. Un Kernel permite al SVM extender esas fronteras lineales y complejas para distinguir entre diferentes personas o tipos de objetos.

Problema 8) 1.- Para clasificar el nuevo punto (3,3), observamos las distancias usando la distancia euclidiana por percepción visual, ya que todos están en la misma diagonal $y=2$

Clase A distancia a (2,2) $\sqrt{(3-2)^2 + (3-2)^2} = \sqrt{2} = 1.41$

Clase B distancia a (4,4) $\sqrt{(3-4)^2 + (3-4)^2} = \sqrt{2} = 1.41$

en este caso (3,3) está a la misma distancia pero en caso de empate se elige al 42% o por percepción

Para $K=1$ buscamos al vecino más cercano el cual sería (2,2) de la clase A (o (4,4) de la clase B ya que ambos están a la misma distancia mínima).

2.- Con $K=3$ buscamos los 3 vecinos más cercanos:

(2,2) Clase A: Distancia 1.41

(1,1) Clase B: Distancia 1.41

(4,4) Clase A: Distancia 2.82

Al hacer la votación:

Votos Clase A: 2 puntos (2,2) (1,1)

Votos Clase B: 1 punto (4,4)

La clase ganadora es la Clase A

3.- Lo que cambia es la estabilidad de la predicción y la sensibilidad del ruido:

- Con K pequeño (como $K=1$). El modelo es muy sensible. Si (2,2) fuera un dato ruidoso o un error de percepción la predicción cambia por completo. Es un modelo con tendencia al over fitting.

- Con K más grande ($K=3$) la decisión se vuelve más democrática. Al considerar más vecinos, el modelo avanza la frontera de decisión y es menos probable que un solo dato atípico altere la clasificación.

Problema 9) 1.- KNN Calcula distancias euclidianas por lo general entre puntos.

Problema:

edad: rango 0-100

ingreso: 0-1,000,000

La escala del ingreso es mucho mayor (millones) comparados con la edad. Por lo tanto la distancia se

$d = \sqrt{(edad_i - edad_j)^2 + (ingreso_i - ingreso_j)^2}$ La diferencia en ingreso domina completamente la distancia

Consecuencias Prácticas:

- La variable edad prácticamente no influye en la clasificación
- El algoritmo se comporta como si solo usara el ingreso, perdiendo información valiosa
- Vecinos cercanos se eligen casi exclusivamente por similitud en ingresos

2.- Solución: Escalar las variables para que tengan magnitudes comparables. Existen 2 técnicas comunes:

a) Normalización (Min-Max scaling) lleva los datos a un rango fijo, Por ejemplo: $(0,1)$:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Aplicando

- edad normalizada a $[0,1]$

- ingreso normalizado a $[0,1]$

Ambas variables contribuyen por igual a la distancia.

b) Estandarización (Z-score scaling)

Media = 0 desviación estándar = 1

$$x' = \frac{x - \mu}{\sigma}$$

- Útil para valores atípicos outliers

Problema 10) Naive Bayes asume que las características (A y B) son independientes entre sí dadas la clase. La fórmula simplificada para la probabilidad posterior es:

$$P(\text{Clase} | A, B) \propto P(A | \text{Clase}) \cdot P(B | \text{Clase}) \cdot P(\text{Clase})$$

1.- $P(A | \text{Spam}) = 0.6$

$P(B | \text{Spam}) = 0.7$

$P(\text{Spam}) = 0.1$

$P(\text{Spam} | \text{datos}) \propto (0.6)(0.7)(0.1) = \underline{0.042}$

2.- $P(A | \text{NoSpam}) = 0.2$

$P(B | \text{NoSpam}) = 0.3$

$P(\text{NoSpam}) = 0.9$

$P(\text{NoSpam} | \text{datos}) \propto (0.2)(0.3)(0.9) = \underline{0.054}$

3.- Comparamos ambos resultados y clasificar viendo cual es el mejor
Es según ya que 0.168 y 0.036

4.- No. En el mundo real, casi nunca existe una independencia absoluta entre las características por eso el algoritmo se llama Naive (ingenuo)

Problema ①: ①- La matriz de confusión organiza los aciertos y errores del modelo. Para un clasificador binario, se estructura de la siguiente manera.

	Predicción (+)	Predicción (-)
Clase Real Positiva	TP = 50	FN = 50
Clase Real Negativa	FP = 10	TN = 35

②- Accuracy (Exactitud): Representa el porcentaje total de predicciones correctas

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{50 + 35}{100} = 0.85$$

Precisión: Mide que tan confiable es el modelo cuando dice que algo es positivo

$$\text{Precisión} = \frac{TP}{TP + FP} = \frac{50}{50 + 10} = \frac{50}{60} = 0.833 = 83.3\%$$

Recall (Sensibilidad): Mide la capacidad del modelo para encontrar todos los casos positivos (TP)

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{50}{50 + 5} = \frac{50}{55} = 0.909 = 90.9\%$$

F1-Score: Es la media armónica entre Precisión y Recall. Útil para buscar un equilibrio entre ambos.

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2(0.833)(0.909)}{0.833 + 0.909} = 0.864 = 86.4\%$$

③- En un contexto médico, la métrica más importante suele ser el Recall (sensibilidad) ¿Porque?

- Un falso Negativo (FN) en medicina puede significar una persona enferma que está sana. Esto es crítico porque el paciente no recibirá tratamiento poniendo en riesgo su vida. Preferimos tener algunos falsos Positivos (FP) personas sanas que se envían a pruebas confirmatorias adicionales que dejar pasar un solo caso positivo real por alto. Aunque el Recall es prioritario para no perder enfermos, siempre se debe vigilar que la precisión no se excluya completamente.

Problema ② ①- No, en datasets desbalanceados, el Accuracy es engañoso. Si lo calculamos

$$\text{Accuracy} = \frac{8 + 900}{1000} = 0.908 = 90.8\%$$

A la primera vista el 90% parece excelente, sin embargo, un modelo "tonto" que simplemente diga siempre "No está enfermo" sin analizar nada tendría un Accuracy del 99% en este dataset. El 90.8% es de hecho peor que el azar estadístico de la clase mayoritaria.

2.- Identifiquemos los valores: $TP=8$ $FN=2$
 $FP=98$ $TN=900$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{8}{8+2} = \frac{8}{10} = 0.8 = 80\%$$

$$\text{Precisión} = \frac{TP}{TP+FP} = \frac{8}{8+98} = \frac{8}{106} = 0.081 = 8.1\%$$

3.- En medicina seguimos priorizando el Recall pero aquí tenemos ~~un~~ un dilema ético y operativo.

- Con el Recall del 80% estamos dejando ir el 20% de las enfermas sin tratamiento 2 de cada 10
- Sin embargo con una precisión del 8.1% de cada 100 personas que el modelo marca como enfermas más del 90 están sanas, esto causará una angustia innecesaria masiva y saturación de hospitales con pruebas diagnósticas costosas

4.- No, es un modelo deficiente

- 1.- Buja Precisión: el modelo es demasiado paranoico pero poco asertivo, falla demasiado al predecir positivos
- 2.- Recall insuficiente: Para una enfermedad un 20% de emisión (FN) sigue siendo muy alto
- 3.- Costo de error: Un modelo útil en este escenario debería de subir el recall al menos en un rango del 99% sin destruir la precisión. Actualmente, el modelo está advirtiendo un mejor que el ruido, pero con un costo operativo altísimo por la cantidad de falsos positivos

Problema 3.- Aquí se visualiza el impacto de los valores atípicos (outliers), por la 3ra predicción que distorsiona las métricas de forma distinta

1.- MAE (mean absolute error): Mide las diferencias absolutas, entre el valor real y la predicción. No le importa la dirección del error, solo la magnitud

$$\text{Error 1: } 1100 - 901 = 10$$

$$\text{Error 2: } 1210 - 2001 = 10$$

$$\text{Error 3: } 1300 - 10001 = +700$$

$$\text{MAE} = \frac{10 + 10 + 700}{3} = \frac{720}{3} = 240$$

2.- MSE, eleva los errores al cuadrado antes de promediarlos. Esto cambia drásticamente el peso de error;

$$\text{Error 1: } (100 - 90)^2 = 10^2 = 100$$

$$\text{Error 2: } (200 - 210)^2 = 10^2 = 100$$

$$\text{Error 3: } (300 - 1000)^2 = (-700)^2 = 490,000$$

$$\text{MSE} = \frac{100 + 100 + 490,000}{3} = \frac{490,200}{3} = 163,400$$

3.- El MSE, penaliza mucho más los errores grandes, ya que, al elevar al cuadrado los errores pequeños, se mantienen relativamente bajos pero con los errores grandes crecen de forma exponencial

Problema 4 1.- Interpretación

• Intersección ($b_0 = 5$) es el valor esperado de y cuando tanto x_1 como x_2 son iguales a 0. Es el punto de partida del modelo

• Coeficiente x_1 ($w_1 = 2$) es una relación positiva contribuyendo a nuestra variable objetivo y aumenta en 2 unidades

• Coeficiente x_2 ($w_2 = -3$) es una relación negativa y disminuye en 3 unidades

2.- Si x_2 aumenta, el valor de y disminuye, x_2 tiene impacto o fuerza mayor que x_1 en el resultado final, pero en sentido opuesto. El signo negativo actúa como penalizador. En un escenario real si fuera la Satisfacción del Cliente

x_1 podría ser

Calidad del producto

x_2 sería por lo tanto

Tiempo de espera

Problema 5 La función Sigmoide que convierte valores lineales en Probabilidades

1.- Si sustituimos el valor en la ecuación para ver que probabilidades obtenemos

• El exponente se vuelve $2(2) - 4 = 4 - 4 = 0$

La fórmula queda: $\frac{1}{1+e^0}$ Como $e^0 = 1 \therefore \frac{1}{1+1} = \frac{1}{2} = 0.5 = 50\%$

Cuando $X=2$ la Probabilidad de que la clase Positiva es exactamente del 50%

2- El umbral de decisión estándar suele ser 0.5. En este modelo específico el umbral de decisión en términos de la variable de entrada es $X=2$

• Si $X > 2$ la probabilidad será mayor a 0.5, el modelo predice la clase 1

• Si $X < 2$ la probabilidad será menor a 0.5, el modelo predice la clase 0

3- El coeficiente que acompaña a X (el peso $w=2$) determina la pendiente o el crecimiento de la curva

- Al ser un valor positivo indica que a medida que X aumenta la probabilidad de que $y=1$ también aumenta

- Su magnitud de 2 nos dice que tan rápido el modelo cambia de opinión. Entre más grande sea este número más "vertical" será el salto en la curva sigmoide haciendo que la transición de las clases sean más abruptas

El término -1 es el Bias o SEGO y es el que desplaza la curva hacia la derecha. Si el bias fuera 0, el punto de indecisión (oS) estaría exactamente en $X=0$



UNAM

Facultad de Ciencias

Licenciatura Ciencias de la computación

Inteligencia Artificial

Dra. Jessica Sarahi Méndez Rincón

Tema 4 – Actividad 5 Parte II: Aprendizaje Supervisado y no Supervisado

Objetivo

Aplicar conceptos relacionados a Aprendizaje Supervisado (Árboles de decisión, Random Forest, XGBoost y Gradient Boosting) y no Supervisado (K-means y DBSCAN, Detección de Anomalías e Isolation Forest)

Formato: Hoja tamaño carta entregada en clase/classroom, legible, con títulos por ejercicio.

Tiempo: Resolver individualmente (máx. 60 min en clase, 5 minutos por ejercicio aprox.).

Entrega: Entregar por escrito en cuaderno u hojas blancas en clase o mediante la actividad en classroom.

Nota importante: Se debe entregar durante el día de la actividad para ser evaluado sobre 100, después serán sobre 85.

1. Árboles de Decisión

Ejercicio 1: Cálculo de Entropía

Dataset:

Clase	Conteo
Sí	6
No	4

Calcular:

1. La entropía del nodo

Ejercicio 2: Ganancia de Información

Dataset:

Clima	Humedad	Viento	Jugar
Soleado	Alta	No	No
Soleado	Alta	Sí	No
Nublado	Alta	No	Sí
Lluvioso	Media	No	Sí
Lluvioso	Baja	No	Sí
Lluvioso	Baja	Sí	No
Nublado	Baja	Sí	Sí
Soleado	Media	No	No



Actividad 5 - Tema 4 Algoritmos de aprendizaje

Calcular:

1. Calcular la entropía inicial
2. Calcular la ganancia de información para:
 - a. Clima
 - b. Humedad
 - c. Viento
3. Elegir la **raíz del árbol**
4. Dividir el dataset
5. Repetir el proceso hasta hojas puras

2. Random Forest

Ejercicio 3: Bagging conceptual

Pregunta:

Tienes 5 árboles que predicen:

- [1, 0, 1, 1, 0]

Calcular:

1. Predicción final
2. ¿Por qué reduce varianza?

Ejercicio 4: Overfitting

Escenario:

Un árbol tiene profundidad 20.

Calcular:

1. ¿Qué problema existe?
2. ¿Cómo lo soluciona Random Forest?
3. ¿Qué pasa si todos los árboles son iguales?

Hit: diversidad del bosque

3. Gradient Boosting / XGBoost

Ejercicio 5: Boosting paso a paso

Modelo inicial predice:

- $y_{pred} = [10, 10, 10]$

Valores reales:

- $y = [12, 8, 15]$

Calcular:

1. Calcular errores (residuos)
2. Entrenar “conceptualmente” siguiente modelo
3. Nueva predicción (idea general)

Ejercicio 6: Diferencia clave

Pregunta conceptual:

Calcular:

1. Diferencia entre:
 - Random Forest
 - Gradient Boosting



Actividad 5 - Tema 4 Algoritmos de aprendizaje

2. ¿Cuál sobreajusta más fácilmente?
3. ¿Cuál es más interpretable?

4. K-means

Ejercicio 7: Iteración manual

Puntos:

- (1,1), (2,2), (8,8), (9,9)

Centroides iniciales:

- $C1 = (1,1)$
- $C2 = (9,9)$

Calcular:

1. Asignar clusters
2. Recalcular centroides
3. Una iteración más

Ejercicio 8: Elección de K

Responde:

1. ¿Qué pasa si K es muy pequeño?
2. ¿Qué pasa si K es muy grande?
3. Explicar método del codo (elbow method)

5. DBSCAN

Ejercicio 9: Clasificación de puntos

Parámetros:

- $\text{eps} = 2$
- $\text{minPts} = 3$

Puntos:

- (1,1), (2,1), (2,2), (8,8)

Calcular:

1. Identificar:
 - núcleo
 - borde
 - ruido

6. Detección de Anomalías / Isolation Forest

Ejercicio 10: Intuición de aislamiento

Dataset:

- [10, 12, 11, 13, 100]

Calcular:

1. ¿Cuál es anomalía?
2. ¿Por qué Isolation Forest lo detecta rápido?
3. ¿Qué significa “profundidad corta”?

Problema ① ① Sumamos el total de instancias (S) para obtener el denominador de nuestras Probabilidades

Clase Si: 6 Total (N) = 6 + 4 = 10
Clase No: 4

Probabilidades (P_i): $P(Si) = \frac{6}{10} = 0.6$ $P(No) = \frac{4}{10} = 0.4$

② La entropía de Shannon para un conjunto de datos se define como:

$$H(S) = - \sum_{i=1}^2 P_i \log_2(P_i)$$

Para nuestro caso binario (2 clases) la fórmula extendida es:

$$H(S) = - [P(Si) \log_2(P(Si)) + P(No) \log_2(P(No))]$$

③ Sustituimos los valores en la fórmula:

① Término para "Si": $0.6 \times \log_2(0.6) = (0.6) (-0.737) \approx -0.4422$

② Término para "No": $0.4 \times \log_2(0.4) = (0.4) (-1.3219) \approx -0.5287$

$$H(S) = -(-0.4422 - 0.5287)$$

$$H(S) = -(-0.9709) = \underline{0.9709 \text{ bits}}$$

Nota: $\frac{\log_{10}(x)}{\log_{10}(2)} \approx \log_2(x)$

Interpretación: Como el valor está muy de 1 (0.9709) el nodo tiene una impureza alta. Si tuviéramos 5 "Si" y 5 "No", la entropía sería exactamente 1. (máxima incertidumbre)


Problema ② 1.- Analizamos la columna objetivo "lugar",

Total de casos: 8 Si: 4 No: 4

Como la distribución es perfecta (solso) la incertidumbre es máxima.

$$H(S) = -[0.5 \log_2(0.5) + 0.5 \log_2(0.5)] = 1.0$$

ÁRBOL



2.- Ganancia de Información $IG(S, A) = H(S) - \sum \frac{|Sv|}{|S|} H(Sv)$

a.- Clima: Analizamos cada valor del clima respecto a lugar:

• Soleado (3 casos): 0 Si, 3 No $\rightarrow H(\text{Soleado}) = 0$

• Nublado (2 casos): 2 Si, 0 No $\rightarrow H(\text{Nublado}) = 0$

• Lluvioso (3 casos): 2 Si, 1 No $\rightarrow H(\text{Lluvioso}) = - \left[\frac{2}{3} \log_2 \left(\frac{2}{3} \right) + \frac{1}{3} \log_2 \left(\frac{1}{3} \right) \right] = 0.918$

Entropía Residual (Clima): $\frac{3}{8}(0) + \frac{2}{8}(0) + \frac{3}{8}(0.918) = 0.344$

$IG(\text{Clima}) = 1 - 0.344 = 0.656$

b.- Humedad

• Alta (3 casos): 1 Si, 2 No $\rightarrow H = 0.918$

• Media (2 casos): 1 Si, 1 No $\rightarrow H = 1$

• Baja (3 casos): 2 Si, 1 No $\rightarrow H = 0.918$

Entropía Residual (Humedad): $\frac{3}{8}(0.918) + \frac{2}{8}(1) + \frac{3}{8}(0.918) = 0.938$

$IG(\text{Humedad}) = 1 - 0.938 = 0.062$

c.- Viento

No (5 casos): 3 Si, 2 No $\rightarrow H = 0.971$

Si (3 casos): 1 Si, 2 No $\rightarrow H = 0.918$

Entropía Residual (Viento): $\frac{5}{8}(0.971) + \frac{3}{8}(0.918) = 0.951$

$IG(\text{Viento}) = 1.0 - 0.951 = 0.049$

3) Comparamos las ganancias $IG(\text{Clima}) = 0.656$ Ganador

$IG(\text{Humedad}) = 0.062$

$IG(\text{Viento}) = 0.049$

El nodo Raíz del árbol es el Clima

4) Al Dividir por Clima observamos los subconjuntos resultantes:

1) Si Clima es Soleado: Todos los nodos son "No" (Hoja Pura)

2) Si Clima es Nublado: Todos los casos son "Si" (Hoja Pura)

③ Si clima = lluvioso = El subconjunto es $[Si, Si, No]$ Aquí hay una ganancia para Humedad y Viento que calcular

⑤ Repetición para el nodo lluvioso: Si observamos los datos originales cuando llueve

- Lluvioso + Humedad Media + Viento No $\rightarrow Si$

- Lluvioso + Humedad Baja + Viento No $\rightarrow Si$

- Lluvioso + Humedad baja + Viento Si $\rightarrow No$

Aquí el viento separa perfectamente: Si no hay viento $\rightarrow$ Se juega

Si hay viento $\rightarrow$ No se juega

Problema ③ $[1, 0, 1, 1, 0]$ 1.- En un problema de clasificación (etiqueta 0,1) Random Forest utiliza el mismo de Votación Mayorista (Majority Voting).

- Predicciones individuales: $\{1, 0, 1, 1, 0\}$

- Conteo de votos

Clase 1: 3 votos

Clase 2: 2 votos

- Resultado: Como $3 > 2$, la predicción final del ensamble es 1.

2.- 1: La ley de los grandes números: Al promediar o votar los resultados de múltiples modelos independientes, el error aleatorio de cada uno tiende a cancelarse. Un solo árbol puede ser muy sensible al ruido de los datos y alta varianza pero el promedio es mucho más estable

2: Descorrelación: Gracias al Bootstrapping (muestreo aleatorio por reemplazo) o a la selección aleatoria de características (Feature Randomness) cada árbol "ve" una versión ligeramente distinta al problema. Si los árboles fueran idénticos, la varianza sería la misma, al ser diferentes sus errores no coinciden

3: Efecto "Sabiduría de las masas": Es menos probable que la mayoría de los árboles se equivoque al mismo tiempo en la misma dirección, lo que suaviza la frontera de decisión y evita el overfitting

- Si le preguntas a un solo médico, su diagnóstico puede estar sesgado por su experiencia particular (varianza alta)

- Si juntas a 100 médicos y tomas la opinión de la mayoría, el diagnóstico final es mucho más robusto y menos propenso a errores individuales

Problema ④ 1.- Un árbol con profundidad 20 es extremadamente complejo. El Problema principal es el overfitting (Sobreajuste)

- Al ser tan profundo, el árbol deja de aprender patrones generales y comienza a "memorizar" el ruido y los casos particulares del dataset de entrenamiento
- Consecuencia: Tendría un error casi nulo en el entrenamiento, pero fallaría drásticamente con datos nuevos, poca capacidad de generalización

2.- Random Forest no solo combina árboles sino que introduce aleatoriedad para forzar la generalización mediante dos mecanismos:

- Bagging (Bootstrap Aggregating): Cada árbol se entrena con una muestra distinta de los datos
- Feature Randomness: En cada división (split), el árbol solo puede elegir entre un subconjunto aleatorio de características. Esto evita que un solo atributo dominante dicte la estructura de todos los árboles permitiendo que el bosque capture diferentes perspectivas de los datos

3.- Si eliminamos la aleatoriedad y todos los árboles son idénticos:

- 1.- La Varianza no se reduce: El error que cometa un árbol lo cometerán todos. Votar entre 100 personas que piensan exactamente igual no aporta nueva información
- 2.- Se pierde la "Sabiduría de las masas": el ensamble heredaría el overfitting del árbol individual de profundidad 20

3.- Resultado: El modelo deja de ser un "Random Forest" y se convierte simplemente en un árbol individual repetido, perdiendo toda la ventaja del aprendizaje por conjunto. La diversidad del Bosque es lo que permite que el error de un árbol sea compensado por el acierto de otros. Si no hay diversidad, no hay robustez.

Problema ⑤ 1.- Calcular Errores: En boosting, los residuos son la diferencia entre el valor actual y la predicción actual. Representa "lo que el modelo aún no explica". La fórmula es Residuo = $y - y_{pred}$

- Para $y_1 = 12 - 10 = 2$
 - Para $y_2 = 8 - 10 = -2$
 - Para $y_3 = 15 - 10 = 5$
- Vector residuo = $[2, -2, 5]$

2.- Entrenar: A diferencia de Random Forest, donde cada árbol intenta predecir y en Gradient Boosting el siguiente modelo (h₂) se entrena para predecir los residuos generados por el modelo anterior.

- Objetivo de Árbol 2: Aprender el patrón del vector $[2, -2, 5]$

- Intuición: El nuevo modelo intentará entender porque nos faltaron 2 unidades en el primer caso, por que nos pasamos por 2 en el segundo y porque nos faltaron 5 en el último.

3.- La nueva predicción no reemplaza a la anterior, sino que le suma ligeramente multiplicada por una tasa de aprendizaje o learning rate. La lógica es:

$$Y_{nueva} = Y_{anterior} + (\eta \times \text{predicción del residuo})$$

- Para el primer dato: $10 + (0.1 \times 2) = 10.2$

- Resultado: La predicción se mueve lentamente hacia el valor real. En cada paso (iteración) el error global disminuye.

Bagging (RF): Árboles independientes en paralelo. El error se reduce promediando.

Boosting (XGBoost): Árboles secuenciales. Cada árbol intenta corregir los errores del anterior, reduce el sesgo.

Problema ⑥ 1 Diferencias Principales

Característica	Random Forest Bagging	Gradient Boosting
Construcción	En Paralelo (árboles independientes)	Secuenciales (un árbol tras otro)
Objetivo	Reducir la varianza (evitar overfitting)	Reducir el sesgo (mejorar la precisión)
Mecanismo	Cada árbol vota, se promedian	Cada árbol corrige el error del anterior
Sensibilidad	Robusto frente a datos ruidosos	Sensible a valores atípicos (outliers)

2.- Gradient Boosting sobre ajusta más fácilmente. Como su objetivo es reducir el error a toda costa, si le damos demasiadas iteraciones (árboles) o una tasa de aprendizaje muy alta, el modelo termina aprendiendo perfectamente el ruido de los datos de entrenamiento. En Random Forest, agregar más árboles no suele causar overfitting, en Boosting sí. Por eso en XGBoost es vital usar Early Stopping.

3.- En términos estrictos ambos son modelos de "caja negra" comparados con un solo árbol de decisión pero: Random Forest suele considerarse ligeramente más interpretable de manera empírica. Es más fácil entender el impacto promedio de variables a través de "Feature Importance" global.

Gradient Boosting es más complejo de interpretar porque el efecto de una variable en el árbol 100 depende de lo que hicieron los 99 árboles anteriores.

Herramientas de apoyo: Para ambos casos en la industria usamos valores SHAP o LIME para poder explicar las predicciones a un cliente o usuario final.

- Si quieres un modelo rápido de entrenar y difícil de romper: Random Forest

- Si buscas la máxima precisión posible y tienes tiempo para tunear hiperparámetros Gradient Boosting (XGBoost / LightGBM)

Problema ⑦ ① Distancia Euclidiana (asignación de clusters). Calculamos la distancia de cada punto a los centroides iniciales C_1 y C_2 . Por aspecto visual o aplicando

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

• (1,1): Distancia a $C_1 = 0$, se queda en el cluster 1

• (2,2): Esta más cerca del C_1 (1,1) que del C_2 (4,4) se queda en el cluster 1

- (8,8): Esta más cerca del $(2,9)$, se queda en el cluster 2
 - (9,9): Distancia a $(2,9)$ es 0 - se queda en cluster 2
- Grupos resultantes: $G_1 = \{(1,1), (2,2)\}$ $G_2 = \{(8,8), (9,9)\}$

② Para calcular centroides, el nuevo centroide es el promedio (la media) de los puntos asignados en cada grupo:

$$\text{Nuevo } C_1: C_1 = \left(\frac{1+2}{2}, \frac{1+2}{2} \right) = (1.5, 1.5)$$

$$\text{Nuevo } C_2: C_2 = \left(\frac{8+9}{2}, \frac{8+9}{2} \right) = (8.5, 8.5)$$

③ Una iteración más (¿Hay cambios?): Volvemos a evaluar la cercanía de los puntos con los nuevos centroides $(8.5, 8.5)$ y $(1.5, 1.5)$

- 1.- $(1,1)$ y $(2,2)$ siguen estando mucho más cerca de 1.5 que de 8.5. Se mantienen en el cluster 1
- 2.- $(8,8)$ y $(9,9)$ siguen estando mucho más cerca de 8.5 que de 1.5. Se mantienen en el cluster 2

Conclusión: Como la asignación de los puntos no cambio, los centroides tampoco cambiarán en la siguiente suma. El algoritmo ha convergido

Problema ⑧ 1. Si elegimos un valor de K menor al número natural de grupos en los datos (Por ejemplo K=1):

- Subajuste (Underfitting): El modelo agrupa datos que son muy diferentes entre sí en un mismo cluster
- Inercia total alta: La suma de las distancias al cuadrado dentro de los clusters será muy grande porque los puntos están lejos de su centroide

2.- Si elegimos un valor de K excesivo (por ejemplo $K=N$, donde N es el número de puntos):

- Sobreajuste (Overfitting): Cada punto termina siendo su propio cluster
- Fragmentación: Se pierde el propósito del clustering que es encontrar estructuras generales. La inercia será 0, pero el modelo no tendrá utilidad práctica

3.- Método del codo (Elbow Method): Este método busca "el punto de equilibrio" donde añadir un cluster más ya no reduce significativamente la inercia (WSS - Within-cluster sum of squares).

- Supongamos que calculamos la inercia para diferentes valores de K en un dataset:

K (cluster)	Inercia (WSS)	Reducción de la Inercia
1	500	
2	250	250
3	100	150 (Punto de inflexión)
4	85	15
5	75	10

- Análisis del Ejemplo (tabla):
- 1.- Al pasar de $K=1$ a $K=2$ la inercia baja drásticamente 250 unidades
 - 2.- De $K=2$ a $K=3$ baja otras 150 unidades
 - 3.- De $K=3$ a $K=4$, la mejora es mínima (solo 15 unidades)

Resultado: El dato está en $K=3$, a partir de ahí, el esfuerzo computacional de añadir más clusters no vale la pena por la poca ganancia en precisión

Problema (9) Parámetros de control

eps (Epsilon) = 2 ~~El~~ El radio máximo para buscar vecinos

minPts = 3 El número mínimo de puntos (incluyéndose a sí mismo) para ser núcleo

1) Análisis de Vecindades (N) Evaluamos cuantos vecinos tiene cada punto que una distancia ≤ 2 :

1 Punto A (1,1): Vecinos: (2,1) dist=1; (2,2) distancia = $\sqrt{2} \approx 1.41$
total: 3 puntos en su vecindad

2 Punto B (2,1): Vecinos: (1,1) distancia=1; (2,2) distancia=1
total: 3 puntos en su vecindad

3 Punto C (2,2): Vecinos: (1,1) distancia=1.41; (2,1) dist=1
total: 3 puntos en su vecindad

4 Punto D (8,8): Vecinos: Ninguno cerca
total: 1 punto (él mismo)

2) Clasificación Final

- Puntos Núcleo (Core): Aquellos con ≥ 3 en su radio
Resultado: (1,1), (2,1) y (2,2)

- Puntos Borde (Border): Aquellos con menos de 3 puntos, pero que son alcanzables desde el núcleo
Resultado: Ninguno (En este caso todos los puntos cercanos cumplieron para ser núcleo)

- Puntos Ruidos (Noise/Outlier): Aquellos que no son núcleo ni son alcanzables por uno
Resultado: (8,8)

En DBSCAN, el modelo tiene la "honestidad" de decir: Esto es ruido y no pertenece a ningún patrón. En K-means el punto (8,8) habría sido a pertenecer a un grupo

En DBSCAN es tan diferente a K-means: aquí no hay centros, hay vecindades. Un punto se incluye a sí mismo en el conteo de su vecindad

Problema (10)

23/04/2026
Luis Juárez Lick
① Z-Core: Para saber que tan extraño es un punto, calculamos cuantas desviaciones estándar se aleja de la media del grupo

① Calcular la media ($\bar{x}$): $\bar{x} = \frac{10+12+11+13+100}{5} = \frac{146}{5} = 29.2$

② Calcular la varianza (σ^2): Calculamos la diferencia de cada punto con respecto a la media, la elevamos al cuadrado y promediamos:

1- $(10-29.2)^2 = 368.64$

2- $(12-29.2)^2 = 295.84$

3- $(11-29.2)^2 = 331.24$

4- $(13-29.2)^2 = 262.44$

5- $(100-29.2)^2 = 5012.64$

$\sigma^2 = \frac{368.64 + 295.84 + 331.24 + 262.44 + 5012.64}{5} = \frac{6270.8}{5} = 1254.16$

Calcular la desviación estándar σ : $\sigma = \sqrt{1254.16} = 35.41$

Calcular el z-core del punto sospechoso (100). La fórmula es $z = \frac{x - \bar{x}}{\sigma}$

$z = \frac{100 - 29.2}{35.41} \approx 1.99$

Regla de Oro: Normalmente en una distribución normal cualquier punto con un $|z| > 3$ se considera una anomalía externa.

Aunque 1.99 no llega a 3 (porque dataset es muy pequeño y 100 "jala" la media hacia arriba, los otros puntos tienen z-scores negativos o muy cercanos a 0).

Para 12: $z = \frac{12 - 29.2}{35.41} \approx -0.49$

$z_{100} \approx 2$ frente $z_{12} = -0.49$ la diferencia de magnitud es evidente. El punto 100 está a casi 2 desviaciones estándar de la media mientras que el resto está armontando en el lado negativo, confirmando matemáticamente que el 100 es un outlier.

② El algoritmo de IsolationForest funciona bajo una premisa simple: las anomalías son pocas y diferentes.

- Para aislar un punto el algoritmo realiza particiones aleatorias.

- Debido a que el 100 está muy del resto, es mucho más probable que una línea de corte aleatoria lo separe del grupo principal en los primeros intentos.

- Intuición: Es mucho más fácil separar a una persona que está sola en un campo que una que está en medio de una multitud.

③ En este contexto, la Profundidad se refiere al número de particiones (niveles del árbol) que se necesitan para aislar un punto.

- Profundidad Corta: Significa que el punto se aisló en muy pocos pasos. Esto es un indicador directo de que el punto es una anomalía.

- Profundidad larga: Los puntos que están muy agrupados (como el 10/11/12) requieren muchas más ~~particiones~~ particiones aleatorias para ser separados individualmente por lo tanto, una profundidad mayor indica que el punto es normal.