

****P.1.****

Es una 2D

Escala de grises (una sola capa/matriz de intensidad)

RGB: Es un tensor en 3D. En lugar de una matriz, tenemos 3 matrices (canales) superpuestas (rojo, verde, azul) cada pixel se representa por un vector [R, G, B]

****P.2 Descomposición en canales****

Una imagen digital a color no es una sola matriz, sino la superposición de 3 capas independientes.

* ****Canal R (Red):**** Contiene la intensidad de rojo en cada pixel.

* ****Canal G (Green):**** Intensidad de verde.

* ****Canal B (Blue):**** Intensidad de azul.

Cada canal es, por sí solo, una matriz en escala de grises donde el blanco representa el máximo de ese color y el negro la ausencia total. Al combinarse mediante síntesis aditiva crean el espectro completo de colores.

1. ****Si ponemos todos los valores de la matriz B en 0:**** Dominancia de tonos amarillos. El cerebro percibirá una imagen compuesta solo de Rojo y verde. En el modelo aditivo: Rojo + Verde = Amarillo.

2. ****Pérdida de información:**** Cualquier objeto que fuera puramente azul (como un cielo) se vería negro y los colores compuestos (como el morado o el blanco) perderían su componente azul, alterando totalmente la fidelidad de la imagen.

Página 2

****P.3 La operación consiste en el producto punto entre la submatriz de la imagen y el kernel.****

1. ****Submatriz (2x2 arriba izquierda):**** $\begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}$

2. ****Operación:**** $(1 \times 1) + (2 \times 0) + (4 \times 0) + (5 \times -1)$

* Resultado: $1 + 0 + 0 - 5 = -4$

3. ****Este filtro es un detector de bordes diagonales / cambios de intensidad en diagonal:****

* Al tener valores opuestos (1 y -1) en la diagonal principal y ceros en la otra, el filtro arroja un valor alto (positivo o negativo) solo cuando hay una diferencia marcada entre los pixeles en esa diagonal.

* Si los pixeles fueran iguales (todos 5), $5 - 5 = 0$, indicando que el resultado sería una zona plana sin bordes.

****P.4****

El operador Sobel utiliza dos kernels (matrices pequeñas de 3x3) uno para cambios horizontales (Gx) y otro para cambios verticales (Gy).

1. ****Operación:**** El filtro recorre la imagen (convolución) calculando la diferencia de intensidad entre pixeles adyacentes.

* ****Gradiente:**** Si hay un cambio brusco de color (ej. de negro a blanco) el resultado numérico es alto, lo que genera una línea brillante en la imagen resultante. Si la zona es muy uniforme, el resultado es cero (negro).

2. ****Los bordes son fundamentales porque:****

1. ****Reducción de datos:**** Eliminan info. irrelevante (como texturas de fondo) y mantienen solo la estructura geométrica del objeto.

2. **Extracción de características:** Son el primer paso para detectar formas (círculos y cuadrados) que luego permiten identificar objetos complejos (caras, autos, animales).

3. **Invarianza:** Los bordes suelen ser más estables ante cambios de iluminación que los colores sólidos.

Página 3

Gretel Lugo

P7.2

Según vemos en la imagen, podemos enlistar:

1. **Flip (volteo):** Espejear la imagen en dif. ángulos.
2. **Rotation (rotación):** Girar la imagen en dif. ángulos.
3. **Blur (desenfoque):** Simular pérdida de nitidez o movimiento.
4. **Exposure/contrast (exposición):** Cambiar el brillo y contraste para simular distintas condiciones de luz.

5. **Grayscale (escala de grises):** Eliminar el color para que el modelo se enfoque en las formas.

2. Diversidad forzada: Al presentarle al modelo la imagen en distintas formas, evitamos que memorice la posición exacta de los píxeles:

1. **Invarianza:** Obligamos a la red neuronal a entender que un gato sigue siendo un gato, aunque esté de cabeza, borroso o en la oscuridad.
2. **Generalización:** En lugar de aprender un solo ejemplo, el modelo aprende la esencia del objeto, lo que permite funcionar mejor con datos reales que nunca ha visto.

P.8

La calidad del dato es todo.

Al etiquetar surgen estos retos:

* **Ambigüedad de los límites:** ¿La caja debe incluir la antena del auto o solo el cuerpo? ¿Y si la persona lleva una mochila?

* **Oclusión:** Si la persona está detrás del auto ¿dibujamos solo lo que se ve o estimamos dónde está todo su cuerpo?

* **Objetos múltiples y amontonados:** En una multitud las cajas se enciman tanto que es difícil para el modelo separar una instancia de otra (Non-Maximum Suppression).

* **Subjetividad del etiquetador:** Diferentes personas pueden dibujar cajas de distintos tamaños para el mismo objeto, introduciendo ruido.

* **Truncamiento:** Cuando el objeto está solo a la mitad, la caja no representa la forma real del objeto.

P.10

1: Entrada -> Convolución -> Pooling -> Fully Connected

1. **Entrada (Input):** Una matriz 2D o cubo 3D si es RGB.
2. **Convolución:** El "extractor de características". Filtros que buscan bordes y texturas (Sobel).
3. **Pooling:** El "reductor", comprime la info y mantiene lo más importante (Max Pooling).
4. **Fully Connected (Capa densa):** El "clasificador". Toma los rasgos extraídos y decide si la imagen es un coche o una persona.

2.

* **a) Explosión de parámetros:** Una imagen de 1000x1000 píxeles tendría 1 millón de entradas; la primera capa oculta tendría billones de conexiones, lo que es computacionalmente imposible de entrenar.

* **b) Pérdida de estructura espacial:** Las redes densas "aplanan" la imagen a un vector, perdiendo la relación de vecindad entre píxeles.

* **c) Falta de invarianza:** Si un objeto se mueve unos pocos píxeles, una red densa lo vería como un patrón totalmente nuevo. La CNN, gracias a la convolución, reconoce el patrón sin importar su ubicación exacta.

Página 4

Gretel Lugo

19-mayo-2026

P11

Identificación de modalidades

* **Entrada:** Imagen (Matriz de píxeles y tensor)

* **Salida:** Texto (Secuencia de Tokens / Lenguaje Natural (palabras))

**¿Es un sistema unimodal o multimodal?*

* Es un sistema Multimodal.

* **Razón:** Procesa y relaciona información proveniente de dos tipos distintos que tienen estructuras y representaciones matemáticas diferentes (píxeles vs. texto).

Un ejemplo muy común es la Búsqueda por voz en Youtube.

* **Entrada:** Audio (ondas sonoras)

* **Salida:** Video (secuencia de imágenes) y texto (Títulos)

Otro ejemplo: Los sistemas de Traducción de lenguaje de señas

* **Entrada:** Video

* **Salida:** Voz

P12

| Concepto | Early Fusion (Fusión Temprana) | Late Fusion (Fusión Tardía) |

| :--- | :--- | :--- |

| | Se concatenan las características (features) crudas o de bajo nivel de ambas modalidades antes de entrar al modelo de aprendizaje. | Se entrena un modelo indep. para cada modalidad y se combinan solo sus predicciones finales en la capa de salida. |

| **Proceso** | (Imagen + Texto) $\rightarrow$ un solo vector de entrada $\rightarrow$ Red Neuronal | (Imagen $\rightarrow$ Modelo A) + (Texto $\rightarrow$ Modelo B) $\rightarrow$ Promedio/Votación de resultados |

P. 12.2

Usaríamos Early Fusion:

Cuando el Texto y la imagen están íntimamente ligados (por ejemplo, una descripción técnica exacta de una pieza mecánica), la Fusión Temprana permite que la red detecte patrones cruzados que se perderían si procesas cada etapa por separado y ayuda a capturar la semántica compartida de forma mucho más profunda.

Página 5

Gretel Lugo

****19-mayo-2026.****

****P.15****

****CLIP (Contrastive Language-Image Pre-Training)****

Funciona conectando conceptos visuales con Lenguaje natural de forma masiva.

* ****Doble Codificación:**** Utiliza un codificador de imagen y uno de texto que trabajan en paralelo.

* ****Alineación semántica:**** Durante su entrenamiento se le presentan millones de pares (imagen, texto) extraídos de internet.

* ****Espacio Latente:**** Proyecta ambos tipos de datos a un mismo espacio matemático para que la foto de un gato y la palabra "gato" tengan coordenadas similares.

****P. 15.2 El aprendizaje contrastivo es la clave de su eficiencia porque:****

1. ****Simplifica la tarea:**** En lugar de predecir la palabra exacta de una descripción (lo que es muy difícil), el modelo solo debe distinguir qué texto corresponde a qué imagen entre un grupo de opciones.

2. ****Atracción y repulsión:**** El algoritmo optimiza la red para que los pares correctos se "atraigan" (distancia mínima) y los pares incorrectos se "repelan" (distancia máxima) en el espacio vectorial.

3. ****Zero-shot learning:**** Gracias a esto, CLIP puede reconocer un objeto en específico sin un entrenamiento previo en específico, simplemente entendiendo la descripción textual.

****P.18****

****18.1****

Los modelos de IA no son racistas o sexistas por sí mismos, son espejos de los datos con los que se entrenan.

* ****Datos históricos:**** Si el dataset (imágenes y texto de internet) contienen más imágenes de hombres en roles de medicina y mujeres en enfermería, el modelo aprenderá esta correlación como una regla estadística.

* ****Falta de Representatividad:**** Un desequilibrio en la cantidad de ejemplos para ciertos grupos refuerza estereotipos.

* ****Anotación Humana:**** Si las personas que etiquetaron los datos tenían prejuicios, estos se transfieren al modelo.

****18.2****

Para construir una IA más justa, podemos aplicar estas estrategias:

1. ****Curación de Datasets:**** Auditar y balancear los datos de entrenamiento para asegurar una representación equitativa de géneros en todas las profesiones.

2. ****Data augmentation ético:**** Generar artificialmente ejemplos que rompan el sesgo, crear más datos de enfermeros hombres o doctoras mujeres.

3. ****Limpiar Embeddings:**** Aplicar técnicas matemáticas para limpiar el espacio vectorial, eliminando las correlaciones no deseadas entre género o profesión.

4. ****Métricas de equidad:**** Evaluar el modelo no solo por su precisión general, sino cómo se comporta ante diferentes grupos demográficos.