

Inteligencia Artificial

Tema 5 Percepción artificial, lenguaje, visión y ética

Dra. Jessica Sarahi Méndez Rincón

2. Objetivo de la Unidad

- Identificar las etapas de la percepción artificial y su relación con la cognición humana.
- Comprender las técnicas modernas de procesamiento de lenguaje (NLP) y visión computacional.
- Analizar la importancia de la ética, la privacidad y la explicabilidad (XAI) en el desarrollo de IA.

Presentación de la Unidad

Uno de los grandes avances de la Inteligencia Artificial contemporánea es su capacidad para **percibir e interpretar el mundo**, emulando —de manera parcial y abstracta— procesos cognitivos humanos como el lenguaje, la visión y la toma de decisiones. A diferencia de los primeros sistemas de IA, que se limitaban a reglas explícitas, los sistemas actuales incorporan mecanismos que les permiten **procesar información sensorial**, identificar patrones complejos y generar respuestas adaptativas en contextos dinámicos. La percepción es el puente entre el mundo físico y la inteligencia. No se trata solo de recibir señales, sino de interpretarlas para generar conocimiento. En esta unidad final, exploraremos cómo la IA procesa el lenguaje y las imágenes, cómo integra múltiples sentidos (multimodalidad) y, lo más importante, cómo debemos gestionar el impacto ético de estas tecnologías en la sociedad

Este tema integra los fundamentos de la **percepción artificial**, el **Procesamiento de Lenguaje Natural (NLP)**, la **Visión Computacional**, los **sistemas multimodales** y culmina con una reflexión crítica sobre la **ética en Inteligencia Artificial**. El objetivo es que el estudiante comprenda no solo **cómo funcionan estos sistemas**, sino también **qué implicaciones sociales, éticas y humanas conlleva su uso**.

El objetivo analizar cómo la Inteligencia Artificial abstrae la percepción humana a través del lenguaje y la visión, comprendiendo sus aplicaciones modernas y reflexionando sobre sus implicaciones éticas y sociales.



¿Qué es la percepción desde la cognición?

Desde la perspectiva cognitiva, la percepción es el proceso mediante el cual los seres humanos **reciben, organizan e interpretan estímulos sensoriales** provenientes del entorno. No se trata únicamente de captar información, sino de **construir significado** a partir de ella, integrando experiencia previa, contexto y expectativas.

En IA, la percepción se modela como una **abstracción computacional** de este proceso cognitivo, permitiendo que los sistemas interpreten señales del mundo real de manera automatizada.

Percepción como proceso

Tanto en humanos como en sistemas artificiales, la percepción puede entenderse en tres etapas fundamentales:

1. Captura

Recepción de señales mediante sensores (cámaras, micrófonos, sensores de proximidad, etc.).

2. Representación

Transformación de las señales en estructuras internas manejables (vectores, símbolos, embeddings).

3. Interpretación

Asignación de significado: reconocer objetos, entender texto, identificar emociones o acciones.




FIGURE 2.37 Primary sensory and motor cortex and surrounding association cortex. The blue regions show the primary cortical receiving areas of the ascending sensory pathways and the primary output region to the spinal cord. The secondary sensory and motor areas are colored pink. The remainder is considered association cortex.

Diferencias entre la percepción humana vs. la artificial

Mientras los humanos poseen una percepción contextual y holística, la IA actual destaca en la precisión estadística, aunque a menudo carece del "sentido común" biológico.


Percepción humana	Percepción artificial
Biológica y adaptativa	Computacional y algorítmica
Altamente contextual	Dependiente de datos y modelos
Flexible y general	Especializada por tarea
Integra emociones y experiencia	Carece de conciencia

Sensores vs sentidos humanos

Los **sentidos humanos** (vista, oído, tacto, etc.) son sistemas biológicos complejos, mientras que los **sensores artificiales** capturan señales físicas específicas. La IA actúa como el puente que transforma esas señales en información interpretable.

Este punto conecta directamente el estudio del cerebro humano con los sistemas perceptuales artificiales.

Figura 4: Capacidades de los sistemas de Inteligencia Artificial (IA)



Fuente PwC

Inteligencia Artificial

Procesamiento de Lenguaje Natural

Dra. Jessica Sarahi Méndez Rincón

¿Para ti qué es el procesamiento de lenguaje natural?

¿Cuál es el objetivo del procesamiento de lenguaje natural?




Introducción al procesamiento de lenguaje natural

- El lenguaje es la capacidad de todos los seres humanos para comunicarse mediante signos con la finalidad de expresar sus sentimientos o pensamientos.
- El lenguaje natural es el lenguaje utilizado diariamente por los individuos para comunicarse entre sí por medio de idiomas como el inglés, el español o el ruso. El uso del lenguaje ha evolucionado conforme pasan las generaciones, provocando que las reglas que los rigen cambien con el paso del tiempo.
- Uno de los objetivos del procesamiento del lenguaje natural es buscar que las computadoras realicen tareas que utilicen el lenguaje, por ejemplo, comunicar a una computadora con una persona, tal y como se ejemplifica con el agente conversacional HAL 9000 en la película 2001: Odisea del espacio de Stanley Kubrik; tareas que mejoren la comunicación hombre a hombre o simplemente realizar un procesamiento adecuado de texto a voz.

Introducción al procesamiento de lenguaje natural

El Procesamiento del Lenguaje Natural es el campo de conocimiento de la **Inteligencia Artificial** que se ocupa de la investigación la manera de comunicar las máquinas con las personas mediante el uso de lenguas naturales, como el español, el inglés o el chino.

Su objetivo es comprender y manipular el lenguaje humano a través de la inteligencia artificial. Aplicaciones actuales: chatbots, traducción automática, análisis de sentimientos, entre otros



Procesamiento de Lenguaje Natural (NLP)

El Procesamiento de Lenguaje Natural es el área de la IA que permite a las máquinas comprender, analizar y generar lenguaje humano.

Fundamentos de NLP

- El texto se modela como una señal simbólica.
- Procesos básicos:
 - Tokenización (dividir texto en unidades)
 - Normalización
 - Representaciones vectoriales
- El lenguaje humano es ambiguo y dependiente del contexto, lo que representa uno de los mayores retos del NLP.

Procesamiento de Lenguaje Natural (NLP)

Categorización de texto y extracción de información

Principales tareas:

- **Clasificación de texto**

Asignación de categorías (temas, emociones, intención).

- **Análisis de sentimientos**

Identificación de opiniones positivas, negativas o neutras.

- **Extracción de entidades (NER)**

Detección de personas, lugares, fechas, organizaciones.

Aplicaciones:

- Redes sociales
- Análisis de documentos legales y médicos
- Sistemas de atención automatizada

La evolución del Procesamiento de Lenguaje Natural

- Fase 1: Reglas gramaticales y búsqueda de patrones (1950-1980)
- Fase 2: Métodos estadísticos y aprendizaje automático (1980-2000)
- Fase 3: Avance en el aprendizaje profundo y redes neuronales (2000-actualidad)
- Fase 4: Integración de NLP con otras tecnologías emergentes (IoT, realidad virtual, etc.)

Introducción al procesamiento de lenguaje natural

Fase 1: Reglas gramaticales y búsqueda de patrones

- Enfoque inicial en la creación de reglas y gramáticas para analizar el lenguaje
- Limitaciones: falta de flexibilidad y adaptabilidad para lenguajes complejos y ambigüedades

Fase 2: Métodos estadísticos y aprendizaje automático

- Uso de algoritmos de aprendizaje automático para analizar grandes cantidades de datos textuales
- Mejora en la capacidad de reconocer patrones y entender el contexto
- Ejemplos: clasificación de documentos, análisis de sentimientos, reconocimiento de entidades, etc

Fase 3: Avance en el aprendizaje profundo y redes neuronales (Contenido)

- Auge de las redes neuronales y modelos de aprendizaje profundo (como las redes neuronales recurrentes y las redes neuronales convolucionales)
- Mejoras significativas en tareas de NLP, como traducción automática y generación de texto
 - Ejemplos: modelos de lenguaje basados en transformers (BERT, GPT, etc.)

Fase 4: Integración de NLP con otras tecnologías emergentes (Contenido)

- Combinación de NLP con Internet de las cosas (IoT), realidad virtual, reconocimiento de voz, etc.
- Aplicaciones más interactivas e inmersivas del procesamiento de lenguaje natural
- Ejemplos: asistentes virtuales, traducción en tiempo real, chatbots avanzados

Introducción al procesamiento de lenguaje natural

- El procesamiento del lenguaje natural (PLN) resuelve tareas que permiten a las computadoras comprender nuestro lenguaje, por ejemplo, entender los sentimientos plasmados en un texto, reconociendo el habla o generando respuestas a preguntas específicas, entre otros.
- Actualmente, existen diferentes aplicaciones de cómputo que utilizamos diariamente y se han creado a partir del procesamiento del lenguaje natural:
 - 1.Corrección gramatical (editores de texto).
 - 2.Máquinas de búsqueda (Google, Bing, Yahoo! o Wolfram Alpha).
 - 3.Asistentes (Siri, Alexa).
 - 4.Clasificadores de correo no deseado (Gmail u Outlook).
 - 5.Procesadores de noticias (Google o Yahoo!).
 - 6.Traducción de textos (Google Translate).
 - 7.IBM Watson.
- Es posible definir al procesamiento del lenguaje natural como el modelado computacional del lenguaje humano; es esencialmente multidisciplinario y está fuertemente relacionado con la lingüística, que se ocupa del desarrollo de modelos de lenguaje, y la lingüística computacional que utiliza técnicas estadísticas para el mismo fin.

Introducción al procesamiento de lenguaje natural

- El lenguaje natural posee propiedades que pueden afectar el rendimiento de aplicaciones de cómputo construidas a partir de lenguajes formales, como los lenguajes de programación de computadoras. Estas propiedades son la **variación** y la **ambigüedad lingüística**. La primera se refiere a la posibilidad de usar diferentes palabras para comunicar una misma idea. La segunda sucede cuando una palabra o frase permite más de una interpretación. Ambas propiedades hacen que el procesamiento del lenguaje natural sea un problema complejo de resolver, ya que implican varios retos sintácticos, semánticos y pragmáticos.

Para comprender la evolución del procesamiento del lenguaje natural, es de suma importancia hacer un breve repaso histórico.

- Las raíces del PLN se remontan al periodo intelectualmente fértil que existió después de la Segunda Guerra Mundial y que también dio origen a la primera computadora. En la década de los 40 y hasta finales de 1950 se realizaron grandes trabajos sobre dos paradigmas fundamentales de PLN: el autómata y los modelos probabilísticos o teóricos de la información.

- El autómata surgió en la década de los 50, inspirado en el modelo de Turing (1936, 1950), considerado por muchos como la base de la informática moderna. El trabajo de Turing condujo primero a la neurona McCulloch-Pitts (1943), un modelo simplificado de la neurona como una especie de elemento informático que podría describirse en términos de lógica proposicional, y luego al trabajo de Kleene (1951, 1956) sobre autómatas finitos y expresiones regulares.

Introducción al procesamiento de lenguaje natural

- Trabajos pioneros de Shannon y Chomsky en la década de 1940 y 1950. Shannon aplicó modelos probabilísticos a autómatas para el lenguaje, mientras que Chomsky utilizó máquinas de estado finito para caracterizar gramáticas y lenguajes de estado finito. Estos enfoques condujeron al desarrollo de la teoría del lenguaje formal, que utiliza álgebra y teoría de conjuntos para definir los lenguajes formales como secuencias de símbolos. También se menciona la gramática libre de contexto, descubierta de forma independiente por Chomsky, Backus y Naur et al.
- Otro avance importante fue el desarrollo de algoritmos probabilísticos para el procesamiento del habla y el lenguaje, inspirados en la metáfora del canal ruidoso de Shannon. Shannon también introdujo el concepto de entropía para medir la capacidad de información de un lenguaje. En la década de 1950, se realizaron investigaciones fundamentales en fonética instrumental y se desarrollaron los primeros reconocedores de voz de máquina. Por ejemplo, Davis, Biddulph y Balashek construyeron un sistema estadístico para reconocer dígitos basado en los formantes de vocales.
- Hacia fines de la década de 1950 y principios de la década de 1960, el procesamiento del habla y del lenguaje se dividió en dos campos: el simbólico y el estocástico. El enfoque simbólico se centró en la teoría del lenguaje formal y la sintaxis generativa, así como en el análisis de algoritmos. El enfoque estocástico se basó en estadística e ingeniería eléctrica, aplicando métodos bayesianos y modelos probabilísticos. En el verano de 1956, se celebró un taller sobre inteligencia artificial (IA), donde se reunieron investigadores en algoritmos estocásticos y estadísticos. La IA se centró en el razonamiento y la lógica, y se destacaron los trabajos de Newell y Simon.

Introducción al procesamiento de lenguaje natural

- Durante los años 60, se desarrollaron modelos psicológicos del procesamiento del habla basados en la gramática transformacional. También se menciona el Corpus Brown, el primer corpus en línea que recopiló una amplia variedad de textos en inglés americano.
- Finalmente, se menciona que entre los años 1970 y 1983 se observó un aumento exponencial en la investigación del procesamiento del habla y del lenguaje, así como el desarrollo de cuatro paradigmas de investigación dominantes en el campo.
- El **paradigma estocástico** tuvo un papel muy importante en el desarrollo de algoritmos de reconocimiento de voz en este periodo, en particular el uso del modelo oculto de Markov y las metáforas del canal ruidoso y la decodificación, desarrollado de forma independiente por Jelinek, Bahl, Mercer y otros colegas en el centro de investigación Thomas J. Watson de IBM, y por Baker en la universidad de Carnegie Mellon. Los Laboratorios Bell de AT&T también realizaron trabajos de investigación en el reconocimiento y síntesis de voz.
- El **paradigma lógico** se inició con el trabajo de Colmerauer (1975) y sus colegas, sobre los sistemas Q y las gramáticas de metamorfosis (Colmerauer, 1970), los precursores de Prolog y las gramáticas de cláusulas definidas por Pereira y Warren (1980). De forma independiente, Kay (1979) trabajó sobre gramática funcional y, poco después, Bresnan y Kaplan (1982) sobre gramática léxico-funcional, estableciendo la importancia de la unificación de las estructuras de las características del lenguaje.

Introducción al procesamiento de lenguaje natural

- El paradigma de la **comprensión del lenguaje natural** comenzó con el sistema *SHRDLU* de Terry Winograd (1972), que simulaba un robot incrustado en un mundo de bloques de juguete en 1972. El programa era capaz de recibir comandos de texto en lenguaje natural, por ejemplo, mover un bloque rojo y colocarlo encima de un bloque verde más pequeño. También fue el primero en intentar construir una gramática extensa del inglés, basada en la gramática sistémica de Halliday. El modelo de Winograd dejó en claro que el problema del análisis sintáctico estaba lo suficientemente bien entendido y comenzó a centrarse en la semántica y en los modelos del discurso.
- Roger Schank (1972), sus colegas (1977, 1981) y sus estudiantes (llamados la Escuela de Yale) crearon una serie de programas de comprensión del lenguaje que se centraron en el conocimiento conceptual humano, como guiones, planes, metas y la organización de la memoria humana hacia finales de los años 70. Los paradigmas lógico y de comprensión del lenguaje natural se unificaron en sistemas que utilizaban la lógica de predicados como representaciones semánticas. Un ejemplo de ello es el sistema de preguntas y respuestas LUNAR en 1973.

Introducción al procesamiento de lenguaje natural

- El paradigma del **modelado del discurso** se centró en cuatro áreas clave. Grosz (1977) y sus colegas (1986) introdujeron el estudio de la subestructura en el discurso y el enfoque del discurso. En 1978, varios investigadores comenzaron a trabajar en la resolución de referencia automática en 1979 y 1980. Perrault colaboró con dos investigadores, primero con Cohen (1979) y posteriormente con Allen (1980) y desarrollaron un marco de referencia con base en la lógica sobre los actos del habla.
- De 1983 a 1993 renacen el empirismo y los modelos de estado finito *Redux*, dos modelos que habían perdido popularidad a finales de los años 50 debido a ciertos argumentos teóricos en contra, como la revisión de Chomsky (1959) al *Comportamiento verbal* de Skinner. La primera clase fueron los modelos de estados finitos que comenzaron a recibir atención nuevamente después del trabajo sobre fonología y morfología de estados finitos de Kaplan y Kay (1981) y modelos de sintaxis de estados finitos de Church (1980).
- La segunda tendencia en este periodo fue lo que se conoció como el “retorno del empirismo”; lo más notable aquí fue el surgimiento de modelos probabilísticos utilizados para el procesamiento del habla y del lenguaje (Brown et. Al, 1990), fuertemente influenciados por los trabajos sobre modelos probabilísticos de reconocimiento de voz, desarrollados en el Centro de Investigación Thomas J. Watson de IBM. Estos métodos probabilísticos y otros enfoques basados en datos se utilizaron en procesamiento del habla, etiquetado de las partes de una oración, el análisis sintáctico y la ambigüedad del lenguaje. Además, durante este periodo se desarrollaron varios trabajos sobre la generación del lenguaje natural.

Introducción al procesamiento de lenguaje natural

- Durante los cinco años previos al año 2000, el campo del PLN estaba cambiando. Primero, los modelos probabilísticos y basados en datos se habían vuelto un estándar en el procesamiento del lenguaje natural. Los algoritmos para el análisis sintáctico, el etiquetado de las partes de una oración, la resolución de referencias y el procesamiento del discurso comenzaron a incorporar probabilidades y a emplear metodologías de evaluación tomadas del reconocimiento de voz y la recuperación de información.
- En segundo lugar, los incrementos en la velocidad y la memoria de las computadoras habían permitido la explotación comercial en varias subáreas del procesamiento del habla y del lenguaje, en particular el reconocimiento del habla y la revisión ortográfica y gramatical. Los algoritmos de procesamiento del habla y lenguaje comenzaron a aplicarse a la comunicación aumentativa y alternativa (CAA).
- Finalmente, el surgimiento de la web enfatizó la necesidad de recuperar y extraer información basada en el lenguaje.

Introducción al procesamiento de lenguaje natural

- Las tendencias empiristas que iniciaron a finales de los años 90 se aceleraron a un ritmo asombroso entre los años 2000 y 2007. Esto fue impulsado en gran medida por tres tendencias que hicieron sinergia. Primero, y gracias a los auspicios del Consorcio de Datos Lingüísticos (LDC) y otras organizaciones similares, se puso a disponibilidad de la población una gran cantidad de material hablado y escrito entre los que destacan *Penn Treebank*, *Prague Dependency Treebank*, *Penn Discourse Treebank* y *TimeBank* que son fuentes de texto estándar con varias formas de anotaciones sintácticas, semánticas y pragmáticas.
- La existencia de estos recursos promovió la tendencia de proyectar problemas tradicionales, como el análisis sintáctico y semántico en problemas de aprendizaje automático supervisado. Estos recursos también promovieron el establecimiento de evaluaciones competitivas para el análisis sintáctico, la extracción de información, la desambiguación del sentido de las palabras y la contestación de preguntas.
- Segundo, este interés en el aprendizaje automático llevó a una mayor interacción en la comunidad científica. El uso de varias técnicas se convirtió en una práctica estándar en la lingüística computacional, por ejemplo, las máquinas de vectores de soporte (SVM, por sus siglas en inglés), la regresión multinomial y los modelos gráficos bayesianos. En tercer lugar, la amplia disponibilidad de sistemas informáticos de alto rendimiento facilitó la formación y el despliegue de sistemas que no podrían haberse imaginado una década antes.
- Al final de este periodo comenzaron a recibir especial atención las técnicas estadísticas no supervisadas. Se vieron avances en traducción automática en el año 2003 y el modelado de tópicos donde se demostró que es posible construir sistemas entrenados sin la necesidad de integrar datos anotados. Además, el costo generalizado y la dificultad de producir *corpus* anotados de manera confiable se convirtieron en un factor limitante en el uso de técnicas supervisadas en muchos problemas, así que es muy probable que la tendencia apunte hacia un incremento en el uso de técnicas no supervisadas en la resolución de problemas.

Introducción al procesamiento de lenguaje natural

El procesamiento del lenguaje natural es importante para muchas aplicaciones que utilizamos en nuestra vida diaria de las que es posible resaltar:

- Búsqueda y clasificación de información.
- Interfaces en lenguaje natural con tecnologías de voz.
- Traducción automática de textos.

Desde el punto de vista técnico, el procesamiento del lenguaje natural es una tarea difícil de resolver, dada la propia complejidad del lenguaje y que implica un gran reto en ingeniería en términos de obtener mayor conocimiento en sistemas lingüísticos, aprendizaje automático, análisis morfológico, sintáctico y semántico, así como el tratamiento de la ambigüedad del lenguaje.

La conexión entre el lenguaje y el pensamiento ha colocado a la tecnología de procesamiento del habla y del lenguaje en el centro del debate, aun sobre las máquinas inteligentes. Además, la investigación sobre cómo las personas interactúan con medios digitales complejos indica que la tecnología de procesamiento del habla y del lenguaje será fundamental en el desarrollo de tecnologías futuras.

La tecnología del habla y del lenguaje se basa en modelos formales o representaciones del conocimiento del lenguaje en los niveles de fonología, fonética, morfología, sintaxis, semántica, pragmática y discurso y, para capturar este conocimiento, se utilizan máquinas de estado, sistemas de reglas formales, lógica y modelos probabilísticos.

¿Qué ejemplos de aplicaciones de PLN conocen?

¿Cómo suponen que se desarrollaron?



¿Qué es recurso léxico?

¿Qué es un corpus?



- El siglo XXI se ha caracterizado por la automatización de sistemas y dispositivos y por un incremento en el uso de computadoras. A lo largo del día es posible interactuar con varios productos automatizados: televisores, apagadores de iluminación, Alexa, Siri, entre otros. De estos últimos hay una característica común, pueden comunicarse con la persona que tienen enfrente gracias al procesamiento de lenguaje natural y la inteligencia artificial.
- El procesamiento del lenguaje natural usa grandes colecciones de datos lingüísticos que se utilizan para una amplia variedad de análisis y aplicaciones como las descritas anteriormente.

•Recursos léxicos

- Un recurso léxico o, simplemente, léxico, es una colección de palabras y/o frases que contienen información asociada al texto, como partes de la oración (*Parts of the Speech, POS*) o acepciones de palabras. Los recursos léxicos son secundarios a los textos y, por lo general, se crean y enriquecen con la ayuda de textos. Por ejemplo, es posible definir un texto cualquiera y a partir de él, acceder al vocabulario (palabras utilizadas en el texto) o contabilizar la frecuencia con la que cada palabra aparece en el texto. Tanto el vocabulario como la frecuencia de palabras son recursos léxicos.

Recursos léxicos

El trabajo práctico en el procesamiento de lenguaje natural generalmente requiere de una gran cantidad de datos, de un corpus. Según Dictionary.com (s.f.), el **corpus** se define como:

- Una colección grande o completa de escritos: *todo el corpus de poesía inglesa antigua*.
- El cuerpo de una persona o animal, especialmente cuando está muerto.
- Anatomía. Un cuerpo, masa o parte que tiene un carácter o función especial.
- Lingüística. Un cuerpo de enunciados, como palabras u oraciones, que se supone que son representativos y se usan para análisis léxico, gramatical u otro análisis lingüístico.

Recursos léxicos

- De manera simple, un corpus (en plural, corpora) es una colección de textos que se han recopilado con algún fin. Un corpus balanceado está formado por textos de varios géneros (periódicos, ficción, libros de texto, informes parlamentarios, recetas de cocina, artículos científicos, etc.).
- Los corpora se dividen en tres categorías según McEnery (2003): monolingües, comparables y paralelos. Los primeros, contienen información en un solo idioma. El corpus comparable incluye una variedad de corpus monolingües en diferentes idiomas, con un nivel similar de balance y representatividad. Los corpora paralelos incluyen textos originales en un idioma con traducciones de esos textos en uno o más idiomas diferentes. Se pueden utilizar corpus paralelos para entrenar sistemas de traducción.
- Para comprender y modelar el funcionamiento del lenguaje, se requiere evidencia empírica y los corpus la proporcionan. Estos son necesarios en el procesamiento de lenguaje natural por dos razones, en primer lugar, porque se requiere evaluar algoritmos en lenguaje real; en segundo lugar, los corpus son la fuente de datos para muchas técnicas de aprendizaje automático.
- Adicional a las expresiones lingüísticas, un corpus incluye metadatos, es decir, información sobre el idioma, el autor, la fecha, el tema y la publicación. Un tipo especial de corpus es el que contiene anotaciones lingüísticas, notas de expertos que han leído el texto y han marcado categorías o estructuras que describen su sintaxis y/o significado.

Recursos léxicos

El Consorcio de Datos Lingüísticos (Linguistics Data Consortium, LDC) es un consorcio de universidades, bibliotecas, corporaciones y laboratorios de investigación gubernamentales cuya función inicial fue ser un repositorio y punto de distribución de recursos lingüísticos. Actualmente, se ha convertido en una organización que crea y distribuye una gran cantidad de recursos del lenguaje. El LDC está alojado en la Universidad de Pennsylvania y estos son algunos ejemplos de corpus alojados en él (Linguistics Data Consortium, s.f.):

- Brown: 500 textos, 1 millón de palabras en 15 géneros. Etiquetado de las partes de oración (POS).
- SemCor: 234,000 palabras, etiquetadas con acepciones de WordNet.
- WSJ: 6 años de *Wall Street Journal*; posteriormente se utilizó para crear Penn Treebank, PropBank y otros. Traducido al checo para el banco de árboles de dependencia checo-inglés de Praga.
- ECI: *European Corpus Initiative*, multilingüe.
- BNC: 100 millones de palabras, es una selección equilibrada de géneros escritos y hablados.
- Secoyas: Treebank alineado con una gramática de amplia cobertura en varios géneros.
- Gigaword: 1 billón de palabras de textos de noticias.
- AMI: Multimedia (video y audio, transcripciones sincronizadas).
- N-gramas de Google Books: 5 millones de libros, 500 mil millones de palabras (361 mil millones en inglés).
- Flickr 8K: imágenes con subtítulos en lenguaje natural.
- Genoma visual en inglés: imágenes y cuadros delimitadores con descripciones en lenguaje natural.

Recursos léxicos

El Natural Language Toolkit (NLTK) fue creado en 2001 como parte de un curso de lingüística computacional del Departamento de Ciencias de la Computación e Información en la Universidad de Pennsylvania. Como lo puedes ver en la tabla 1, NLTK está compuesto de varios módulos que corresponden al tipo de tarea de procesamiento de lenguaje que resuelve.

Tarea de procesamiento de lenguaje	Módulo NLTK	Funcionalidad
Acceso a corpus	corpus	Interfaces estandarizadas para corpus y léxicos
Procesamiento de cadenas de texto	tokenize, stem	División de cadenas de texto (<i>tokenizadores</i>) y extracción de raíces de palabras (<i>stemmers</i>)
Descubrimiento de colocación	collocations	Prueba t, chi-cuadrada, información mutua puntual
Etiquetado POS (partes de la oración)	tag	n-gramas, HMM, In1, backoff
Aprendizaje automático	classify, cluster, tbl	Árboles de decisión, máxima entropía, Bayes, k-means
Fragmentación	chunk	Expresiones regulares, n-gramas y entidades nombradas
Analizadores sintácticos	parse, ccg	Gráficos, basados en características, unificación, probabilísticos y dependencias
Interpretación semántica	sem, inference	Validación de modelos, lógica de primer orden y cálculo lambda
Métricos de evaluación	metrics	Precisión y recall
Probabilidad y estimaciones	probability	Distribuciones de frecuencias y distribuciones de probabilidad
Aplicaciones	app, chat	Chatbots, navegador WordNet, analizadores sintácticos
Lingüística	toolbox	Manipulación de datos en formato Toolbox de SIL

Tabla 1. Tareas de procesamiento de lenguaje y sus módulos correspondientes en NLTK.

¿Conocen alguna librería de software para PLN?



Datos escondidos a plena vista

The image shows a screenshot of the Twitter profile of Enrique Peña Nieto (@EPN). The profile header includes a circular profile picture of him, a banner image of the Mexican flag, and statistics: 5,446 Tweets, 313 Siguiendo (Following), 7.28 M Seguidores (Followers), and 168 Me gusta (Likes). The 'Siguiendo' and 'Seguidores' counts are circled in red. Callout boxes point to various elements: 'Red Social' points to the Twitter logo; 'Autor' points to the profile picture; 'Descripción' points to the bio; 'Ubicación' points to the location 'México'; 'Tweet' points to a tweet; 'Tópicos' and 'Sentimiento' point to the tweet's content; 'Tiempo' points to the tweet's timestamp; and 'Popularidad' points to the tweet's engagement metrics.

Red Social

Autor

Descripción

Ubicación

Tweet

- Tópicos
- Sentimiento

Tiempo

Popularidad

Profile Data:

- Tweets: 5,446
- Siguiendo: 313
- Seguidores: 7,28 M
- Me gusta: 168

Profile Info:

- Enrique Peña Nieto @EPN
- Presidente de los Estados Unidos Mexicanos. facebook.com/EnriquePN Instagram.com/epn
- México
- presidencia.gob.mx
- Se unió en marzo de 2007

Tweets:

- Tweet 1:** Enrique Peña Nieto @EPN · 20 h. Felicitó a @IvanDuque por su investidura como nuevo Presidente de la República de Colombia. Los lazos entre nuestros países son sólidos y hemos logrado que nuestra relación estratégica se traduzca en beneficios concretos para nuestros pueblos. (263 replies, 496 retweets, 2.5K likes)
- Tweet 2:** Enrique Peña Nieto @EPN · 3 ago. Con 341 preseas (132 de oro, 118 de plata y 91 de bronce), México concluyó su participación en @BQuilla2018 como líder del medallero. Muchas felicidades a las y los deportistas de nuestra delegación, son #OrgulloMexicano. (398 replies, 1.7K retweets, 6.0K likes)

Followers:

- Andrés Manuel
- Felipe Calderón
- Joaquín López-D

Trends: México

Que se puede hacer con datos textuales?

- Encontrar, identificar y extraer información relevante
- Clasificar documentos
- Búsqueda de documentos relevantes
- Análisis de sentimientos
- Agrupamiento de documentos
- Identificación de tópicos

A continuación, vemos algunos de los componentes del procesamiento del lenguaje natural. No todos los análisis que se describen se aplican en cualquier tarea de PLN, sino que depende del objetivo de la aplicación.

1.Análisis morfológico o léxico. Consiste en el análisis interno de las palabras que forman oraciones para extraer lemas, rasgos flexivos, unidades léxica compuestas. Es esencial para la información básica: categoría sintáctica y significado léxico.

2.Análisis sintáctico. Consiste en el análisis de la estructura de las oraciones de acuerdo con el modelo gramatical empleado (lógico o estadístico).

3.Análisis semántico. Proporciona la interpretación de las oraciones, una vez eliminadas las ambigüedades morfosintácticas.

4.Análisis pragmático. Incorpora el análisis del contexto de uso a la interpretación final. Aquí se incluye el tratamiento del lenguaje figurado (metáfora e ironía) como el conocimiento del mundo específico necesario para entender un texto especializado.

Construcciones primitivas en texto

- Oraciones / cadenas de entrada
- Palabras o tokens
- Caracteres
- Documentos, archivos mas grandes

Trabajando con texto en Python

```
>>> texto1 = "Por mi raza hablará el espíritu, revela la  
vocación humanística con la que fue concebida"  
>>> len(texto1)  
92  
>>> texto2 = texto1.split(' ')  
>>> len(texto2)  
15  
>>> texto2  
>>> ['Por', 'mi', 'raza', 'hablará', 'el', 'espíritu,',  
'revela', 'la', 'vocación', 'humanística', 'con', 'la',  
'que', 'fue', 'concebida']
```

Buscando palabras específicas

- **Palabras que tienen mas de 3 letras en texto2**

```
>>> [w for w in texto2 if len(w) > 3]
['raza', 'hablará', 'espíritu,', 'revela', 'vocación',
'humanística', 'concebida']
```

- **Palabras con la primera letra en mayúsculas en texto2**

```
>>> [w for w in texto2 if w.istitle()]
['Por']
```

- **Palabras en texto2 que terminan en 'a'**

```
>>> [w for w in texto2 if w.endswith('a')]
['raza', 'revela', 'la', 'humanística', 'la', 'concebida']
```

Los n-gramas

Las convenciones utilizadas en la escritura a veces no reflejan la organización lógica de los símbolos textuales, por ejemplo, algunos signos de puntuación se escriben antes de cierta palabra y otros después, aunque no formen parte de ella y esto depende del lenguaje y del estilo de escritura.

En ocasiones, en una cadena de caracteres o texto no están claros los límites lógicos entre las palabras o símbolos de puntuación y eso puede complicar el análisis de textos escritos.




Los n-gramas

En general, el **n-grama** se puede definir como la secuencia de N elementos de una muestra determinada de texto o voz. Los elementos pueden ser letras o palabras.

Algunos autores consideran que un **n-grama** es una secuencia de N palabras y un **q-grama** una secuencia de Q caracteres (incluidas las letras).

Si el n-grama está formado solo por una palabra se llama **unigrama**, si está compuesto por dos, **bigrama**, y si está formado por tres elementos, **trigrama**.

What even is an n-gram?



La **entropía** es una medida de incertidumbre asociada a una distribución o fuente de información (Gray, 2011). Se considera como la cantidad de información promedio necesaria para representar una variable aleatoria (texto en nuestro caso) y se calcula utilizando probabilidad. Las secuencias de caracteres con menor probabilidad son las que aportan más información, por ejemplo, palabras frecuentes como “de” o “que” aportan poca información, a diferencia de “comiendo” o “automóvil”, que son menos frecuentes en algún texto, por lo que aportan una mayor cantidad de información.

La **perplejidad**, denotada por *PP* (palabra), es la métrica más común en modelos de lenguaje, mide qué tan bien predice el modelo a partir de una muestra, por lo que se considera una medida de incertidumbre. A menor valor, mejor evaluación del modelo. Se puede definir la perplejidad como la probabilidad inversa del conjunto de prueba, normalizada por el número de palabras.

.

Característica	En Árboles de Decisión (IA)	En Procesamiento de Lenguaje (PLN)
¿Qué mide?	El "desorden" o la impureza de las etiquetas en un nodo.	El grado de sorpresa o incertidumbre de que aparezca una palabra.
El objetivo	Minimizar la entropía para que las clases estén bien separadas (Ganancia de Información).	Cuantificar cuánta información aporta una palabra según su probabilidad (como dice tu texto).
Ejemplo	Si en un nodo todos son "Gatos", la entropía es 0 (orden total).	Una palabra muy común como "de" tiene probabilidad alta, por lo que su aporte de información es casi 0.

Palabra o **token** es la unidad mínima utilizada en procesamiento de textos y definirla depende de la tarea que se esté realizando.

Por lo general, cada palabra se define como una **unidad separada por espacios** o signos de puntuación, sin embargo, los signos de puntuación pueden estimarse o no como palabras.

Además, es posible considerar como palabras diferentes aquellas que inicien con mayúscula o no, así como aquellas que se escriben de forma incorrecta, incluso, es posible considerar a los plurales como palabras distintas o según el género, masculino o femenino.

Los **tokens** son, por tanto, la ocurrencia de las palabras en un texto y la **tokenización** es el proceso que permite encontrar todas las palabras dentro de él. El conjunto de todas las palabras posibles dentro de un texto se conoce como **vocabulario**.

Estimador bayesiano

- No sólo obtiene el valor de θ del máximo a posteriori, estima la distribución a posteriori completa

$$P(\theta|\mathcal{X}) = \frac{P(\mathcal{X}|\theta)P(\theta)}{P(\mathcal{X})}$$

- Dado un nuevo dato $\tilde{x}$, la distribución predictiva a posteriori está dada por

$$P(\tilde{x}|\mathcal{X}, \alpha) = \int_{\theta} P(\tilde{x}|\theta, \mathcal{X}, \alpha)P(\theta|\mathcal{X}, \alpha)d\theta = E_{\theta|\mathcal{X}, \alpha}[P(\tilde{x}|\theta)]$$

donde α son los hiperparámetros de la distribución a priori

Clasificador bayesiano ingenuo

- El clasificador bayesiano ingenuo modela la distribución conjunta de los atributos y las clases, esto es,

$$P(a_1, \dots, a_d, c | \theta_1, \dots, \theta_d, \theta_c) = \left(\prod_{j=1}^d P(a_j | c, \theta_j) \right) P(c | \theta_c)$$

donde θ_c es el parámetros de la distribución a priori sobre las clases y $\theta_j, j = 1, \dots, d$ son los parámetros de las distribuciones de los atributos dada la clase

- Para clasificar usamos teorema de bayes

$$P(c | a_1, \dots, a_d, c, \theta_1, \dots, \theta_d, \theta_c) \propto \left(\prod_{j=1}^d P(a_j | c, \theta_j) \right) P(c | \theta_c)$$

Estimador bayesiano

- N documentos representados como bolsas de palabras
 - Vectores $x^{(i)} = [a_1(i), \dots, a_d^{(i)}]$, $i = 1, \dots, N$
 - $a_j^{(i)} = 1$ si la palabra j ocurre en el documento i , 0 si no ocurre
 - d es el tamaño del vocabulario
- Presuposición

$$a_j \sim \text{Ber}(k; q_j), j = 1, \dots, d$$

- Para clasificar un nuevo documento $x = [a_1, \dots, a_d]$ se aplica el teorema de bayes para cada clase

$$P(c|a_1, \dots, a_d, q_1, \dots, q_d, q_c) \propto \left(\prod_{j=1}^d P(a_j|c, q_j) \right) P(c|q_c)$$

Las partes de una oración se definen en función de su relación gramatical con palabras vecinas o las propiedades morfológicas de sus afijos y pueden ser de cualquiera de dos clases: abiertas o cerradas.

Las clases cerradas son aquellas con membresía fija, como las preposiciones (es raro tener preposiciones nuevas) a diferencia de las clases abiertas que continuamente se crean, por ejemplo “iPhone”. Las palabras funcionales son de clase cerrada, tienden a ser cortas y ocurren con frecuencia, por ejemplo, las preposiciones simples “de, para, por” o las conjunciones subordinantes y coordinantes “pero, y, o, aunque”, entre otras (Thomas y McAlister, 2020). Los sustantivos, verbos, adjetivos, adverbios e interjecciones son de clase abierta.

El **adjetivo** describe las propiedades de los sustantivos, ya sea color, edad o valor. Un **adverbio** es un modificador y regularmente complementa a un verbo, adjetivo u otro adverbio y pueden ser direccionales, de lugar, de grado, de modo o temporales.

Las **interjecciones** forman enunciados exclamativos, incluyen saludos (hola y adiós) y contestaciones (sí, no, tal vez).

Las relaciones temporales o espaciales las definen las **preposiciones** y pueden ser literales o metafóricas. Una **partícula** es una entidad formada por una preposición o un adverbio combinada con un verbo, y a menudo tienen significados distintos a las preposiciones que incluyen.

Los **determinantes** pueden indicar el inicio de una frase (Esta historia...). Un **artículo** es un determinante que acompaña al sustantivo y son muy frecuentes.

Los **pronombres** actúan como una abreviatura para referirse a una entidad o evento. Un **pronombre personal** se refiere a personas o cosas (yo, tú, él), y un **pronombre posesivo** indica la posesión de algún objeto (mío, tuyo).

El **etiquetado de las partes de una oración** (Part-Of-Speech, POS, por sus siglas en inglés) es un proceso en el cual se identifica la clase morfosintáctica de cada palabra utilizando información léxica y contextual. Por ejemplo, la palabra “caminar” puede utilizarse como un verbo en “Yo camino 2 kilómetros diariamente” o como sustantivo en “Salí a caminar”. En casos como los anteriores, la etiqueta POS es útil para distinguir el sentido o significado de una palabra, se utiliza para explicar el rol sintáctico de la palabra, con lo que es posible inferir información semántica, por ejemplo, que los verbos tienen vínculos de dependencia con los sustantivos o que los pronombres posesivos regularmente están seguidos por un sustantivo.

El etiquetado POS requiere previamente de *tokenizar* las palabras, incluyendo signos de puntuación. El etiquetado es también una tarea de desambiguación, ya que el significado de las palabras es confuso y estas pueden ser etiquetadas en más de una parte de la oración.


Uno de los corpus con etiquetado POS más utilizados es el Penn Treebank para el idioma inglés (Marcus, Santorini y Marcinkiewicz, 1993). Las 36 etiquetas que lo conforman son las siguientes:

1. CC Coordinating conjunction
2. CD Cardinal number
3. DT Determiner
4. EX Existential there
5. FW Foreign word
6. IN Preposition or subordinating conjunction
7. JJ Adjective
8. JJR Adjective, comparative
9. JJS Adjective, superlative
10. LS List item marker
11. MD Modal
12. NN Noun, singular or mass
13. NNS Noun, plural
14. NP Proper noun, singular
15. NPS Proper noun, plural
16. PDT Predeterminer
17. POS Possessive ending
18. PP Personal pronoun
19. PP\$ Possessive pronoun
20. RB Adverb
21. RBR Adverb, comparative
22. RBS Adverb, superlative
23. RP Particle
24. SYM Symbol
25. TO to
26. UH Interjection
27. VB Verb, base form
28. VBD Verb, past tense
29. VBG Verb, gerund or present participle
30. VBN Verb, past participle
31. VBP Verb, non-third person singular present
32. VBZ Verb, third person singular present
33. WDT Wh-determiner
34. WP Wh-pronoun
35. WP\$ Possessive wh-pronoun
36. WRB Wh-adverb

Figura 1. Etiquetas POS de corpus Penn Treebank.

Secuencias

El objetivo del etiquetado de secuencias es asignar etiquetas a palabras, específicamente, asignar etiquetas discretas a elementos discretos en una secuencia. Las etiquetas discretas son categorías gramaticales.





La/DT acción/NN de/IN gran valor/JJ se-desplomó/VBD
durante/IN el/DT transcurso/JJ de/IN la/DT semana/NN

Un ejemplo de un etiquetado POS para la oración “La acción de gran valor se desplomó durante el transcurso de la semana”, utilizando las etiquetas de Penn Treebank queda como la imagen de arriba.

Un **etiquetador POS** procesa una secuencia de palabras y asigna una etiqueta POS a cada palabra. Para el ejemplo mostrado en la figura 2 se utiliza NLTK en Python y dada la variedad de recursos en NLTK para el idioma inglés, se usará ese idioma.

Cadenas de Markov



$$p_{31} p_{14} + p_{32} p_{24} + p_{33} p_{34} + p_{34} p_{44}$$

Matriz de transición

$$\begin{matrix} & \begin{matrix} C1 & C2 & C3 & C4 \end{matrix} \\ \begin{matrix} C1 \\ C2 \\ C3 \\ C4 \end{matrix} & \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \\ p_{41} & p_{42} & p_{43} & p_{44} \end{bmatrix} \end{matrix} = M_1$$

El modelo oculto de Markov se caracteriza por su doble proceso estocástico, uno oculto y otro observable, que genera una secuencia de estados óptima como salida. De la misma manera que el modelo de Markov, el modelo oculto responde a la propiedad de Markov donde la probabilidad de ocurrencia del estado siguiente depende del estado anterior.

Los componentes del modelo oculto de Markov son los siguientes:

- Conjunto de estados, S . Donde $|S| = N$ y N es el número total de estados. El conjunto de estados de un etiquetador POS está formado por las etiquetas.
- Conjunto de observaciones posibles, O . El conjunto de observaciones posibles de un etiquetador POS está formado por las palabras.
- Estado inicial, S_0 . El estado inicial de un etiquetador POS es el inicio de la oración.
- Matriz de probabilidades de transición, A . En un etiquetador POS un ejemplo de la matriz A sería la probabilidad de que la palabra actual tenga una etiqueta de verbo dado que la etiqueta de la palabra previa fue un sustantivo.
- Matriz de probabilidades de salida por cada estado, llamadas también de emisión, B . En un etiquetador POS un ejemplo de la matriz B sería la probabilidad de que la palabra sea Pedro dado que la etiqueta es un sustantivo.
- Vector de probabilidades iniciales, π .

El objetivo de utilizar el modelo oculto de Markov en el proceso de etiquetado es encontrar la secuencia de etiquetas óptima que corresponda a una secuencia dada de palabras.

En código se trabajar con los pasos iniciales para entrenar un etiquetador POS con el modelo oculto de Markov. Se utiliza el corpus treebank de NLTK y se generan dos conjuntos de datos, el de entrenamiento con 3000 datos y el de pruebas con 914.

El algoritmo de Viterbi

El proceso que determina los estados ocultos en un modelo oculto de Markov se conoce como decodificador. El objetivo de este proceso es encontrar una secuencia de etiquetas que maximice la probabilidad de ocurrencia de una secuencia de observaciones.

Formalmente, dadas las matrices de probabilidad A y B y una secuencia de observaciones $O = o_1, o_2, \dots, o_t$ se debe encontrar una secuencia de estados $Q = q_1, q_2, \dots, q_T$. En el caso de un etiquetador POS, la tarea es encontrar una secuencia de etiquetas t_1^n que maximice la probabilidad de ocurrencia de una secuencia de observaciones de n palabras w_1^n .

$$t_1^n = \max_{t_1^n} P(t_1^n | w_1^n) \approx \max_{t_1^n} \prod_{i=1}^n P(w_i | t_i) P(t_i | t_{i-1})$$

El algoritmo que funciona como decodificador en HMM es el algoritmo de Viterbi y su tarea es encontrar la secuencia de etiquetas POS con la mayor probabilidad de ocurrencia dada una oración; formalmente, a partir de un modelo λ y una secuencia de T , observaciones de O , obtiene la secuencia más probable de estados Q .

$$v_t(j) = \max_{q_1 \dots q_{t-1}} P(q_1 \dots q_{t-1}, o_1, o_2, \dots, o_t, q_t = j | (A, B))$$

En el ejemplo siguiente se construirá un modelo HMM utilizando la librería *pomegranate* de Python (Pomegranate, s.f.) y se utilizarán estados del tiempo y probabilidades de transición ficticias. Los estados a usar son soleado y lluvioso.

Un conjunto de textos se conoce como **corpus**. Los textos pueden ser tanto escritos como hablados y deben ser representativos y seleccionados con criterios bien especificados que permitan su análisis posterior. Los corpus se crean dependiendo del uso del que serán objeto, por ejemplo, análisis estilístico, morfológico o sintáctico, entre otros y también, en función del uso, algunos requerirán anotaciones muy precisas.

En el proceso de la anotación de un corpus, por ejemplo, etiquetar un texto con etiquetas POS con la finalidad de estimar el tiempo y los costos requeridos, estos podrían ser algunos de los criterios a considerar:

- Origen de los datos. Género y tamaño.
- Esquema de anotación. Complejidad y lineamientos.
- Personal a considerar. Experiencia y entrenamiento.
- Software de apoyo. Con interfaz gráfica.
- Procedimientos de control de calidad.

La anotación de un corpus es la práctica de agregar información lingüística interpretativa al corpus. Por ejemplo, agregar etiquetas que indiquen la clase de palabra o la categoría gramatical de una palabra, es un tipo de anotación que se conoce como etiquetado gramatical, etiquetado de las partes de una oración (*POS*) o etiquetado de clases de palabras.

Adicional al etiquetado gramatical, existen otro tipo de anotaciones para un corpus:

- Anotación fonética. Se agrega información sobre cómo se pronuncia una palabra en un corpus hablado. Incluye características prosódicas como acento, entonación o pausas (anotación prosódica) e información sobre cómo analizar sintácticamente una oración ya sea en frases o cláusulas.
- Anotación **semántica**. Se agrega información sobre la categoría semántica de la palabra.
- Anotación **pragmática**. Se agrega información sobre el acto del habla (el diálogo).
- Anotación del **discurso**. Se agrega información sobre referencias anafóricas en un texto.
- Anotación **estilística**. Se agrega información sobre la presentación del discurso y del pensamiento.
- Anotación **léxica**. Se agrega información sobre la identidad del lema de cada palabra en el texto, es decir, la forma base de la palabra.

Las ventajas de un corpus anotado son varias, entre ellas se pueden destacar:

- Extracción de información.** Las anotaciones hechas en un corpus se pueden extraer para utilizarlo en algún tipo de tarea, por ejemplo, el uso de etiquetado POS para la creación de diccionarios.
- Reusabilidad.** Un corpus etiquetado automáticamente alcanza una precisión de hasta el 97% (Garrido et al., 2021), para mejorarlo se requiere de trabajo manual y debe ser editado por un equipo de expertos. En la práctica, existen corpus que se ponen a disposición de la comunidad científica para complementar las anotaciones y/o mejorarlas.
- Multifuncionalidad.** Más allá de reutilizar el corpus, las anotaciones pueden ser multifuncionales, por ejemplo, un etiquetado POS puede utilizarse para análisis lexicográficos, sintácticos, listas de frecuencias, síntesis de voz u otras aplicaciones. Lo más interesante es que las propias anotaciones de un corpus pueden dar lugar a nuevos usos, sin embargo, no hay que olvidar que las anotaciones de los corpus fueron hechas para aplicaciones particulares.

Procesamiento Sintáctico

Gramática libre de contexto (CFG)

El **constituyente sintáctico** es una idea que considera que los grupos de palabras pueden comportarse como unidades individuales o constituyentes. Parte del desarrollo de una gramática implica el inventario de estos componentes del idioma o constituyentes.

Por ejemplo, el sintagma nominal o frase nominal, que es una secuencia de palabras formada por un sustantivo y sus modificadores directos y en ocasiones precedida por determinantes, aparecen juntas y generalmente en entornos sintácticos similares; las secuencias “aire acondicionado”, “banda ancha” o “caos vial” utilizadas en las oraciones “El aire acondicionado se descompuso”, “El Internet de banda ancha es suficiente” o “El caos vial es desesperante” sugieren que, en español, la frase nominal regularmente ocurre antes de un verbo, aunque también puede ser objeto directo.

Otro ejemplo de constituyente sintáctico es la frase “15 de agosto” y puede utilizarse de distintas formas dentro de una oración, “El 15 de agosto se festeja mi cumpleaños”, “Mi cumpleaños se festeja el 15 de agosto”, “Mi cumpleaños el 15 de agosto se festeja”. Nota que la frase puede colocarse en distintos lugares, no así alguna otra palabra de la oración.

El sistema formal más utilizado para modelar estructuras constituyentes es la **gramática libre de contexto (CFG**, por sus siglas en inglés) y está compuesta de un conjunto de **reglas** o **producciones** que expresan la forma en la que los símbolos deben agruparse y ordenarse, y de un **lexicón** o diccionario de símbolos y palabras.

Los símbolos utilizados en una CFG se dividen en dos clases: los **símbolos terminales** que corresponden a las palabras en el lenguaje; el lexicón contiene el conjunto de reglas que introducen estos símbolos terminales. Y los **no terminales**, que son los símbolos que expresan agrupaciones o generalizaciones.

Procesamiento Sintáctico

La gramática libre de contexto tiene cuatro componentes y se define formalmente como:

$$G = (N, T, P, S)$$

Donde:

N = Conjunto de símbolos no terminales.

T = Conjunto de símbolos terminales.

P = Conjunto de reglas de producción de la forma $A \rightarrow \beta$, donde $A \in N$ y $\beta \in (T \cup N)^*$.

S = Símbolo distinguido o axioma inicial que es un símbolo de inicio.

En cada regla o producción libre de contexto los elementos a la derecha de la flecha ($\rightarrow$) corresponden a una lista ordenada de símbolos terminales y no terminales, y del lado izquierdo, es un símbolo no terminal que expresa un agrupamiento o generalización.

Por ejemplo, las siguientes producciones expresan que una frase nominal (NP, por sus siglas en inglés) puede estar compuesta por un nombre propio o un determinante seguido de un nominal que puede estar compuesto de uno o varios sustantivos.

$NP \rightarrow Det\ Nominal$


$NP \rightarrow NombrePropio$

$NP \rightarrow Sustantivo\ | \ Nominal$

Procesamiento Sintáctico

Reglas como las anteriores permiten construir cadenas de palabras, por ejemplo, a partir del símbolo no terminal *NP* puede **derivarse** la cadena "un vuelo", por lo que una gramática libre de contexto puede utilizarse para generar conjuntos de cadenas de palabras. Esta secuencia de expansiones de reglas se denomina **derivación** de cadena de palabras y es común utilizar árboles de derivación para representarla.

El **árbol de derivación** permite representar la derivación de cualquier cadena de palabras. Es un grafo formado por nodos y arcos, donde dos nodos distintos están conectados por arcos. Para la cadena de palabras "un vuelo" el siguiente sería un árbol de derivación:



Un lenguaje se define a través del concepto de derivación. Una cadena de palabras deriva a otra si puede reescribirse como la segunda, aplicando ciertas reglas. Formalmente, un lenguaje generado por una gramática es el conjunto de cadenas de palabras compuestas por símbolos terminales que derivan del símbolo de inicio o axioma inicial.

Procesamiento Sintáctico

Reglas gramaticales

Existen varias reglas de construcción de oraciones según el idioma; para el inglés son importantes particularmente cuatro: oración declarativa, imperativa, preguntas "sí-no" y preguntas "wh-" (Jurafsky y Martin, 2008).

Una oración se considera **declarativa** si contiene un sintagma nominal seguido de un sintagma verbal como en "Yo prefiero volar por las mañanas". Las oraciones con estructura **imperativa** a menudo comienzan con un sintagma verbal y no tienen sujeto, se utilizan, por lo general, para dar órdenes o recomendaciones como en "Muéstrame todos los vuelos del próximo domingo" y su regla es $S \rightarrow VP$.

Las oraciones con estructura de pregunta "sí-no" son utilizadas para cuestionar y comienzan con un verbo auxiliar, seguido de un sujeto NP y luego un VP, por ejemplo "¿Puede compartirme la misma información pero de la opción B?". La regla que define estas oraciones es $S \rightarrow Aux\ NP\ VP$.

También es importante conocer las reglas más comunes para la construcción de sintagmas nominales y verbales. El **sintagma nominal** tiene la regla $NP \rightarrow Det\ Nominal$ y, a su vez, el determinante $Det \rightarrow NP's$. El nominal puede estar definido por $Nominal \rightarrow Sustantivo$, $Nominal \rightarrow Nominal\ PP$ o $Nominal \rightarrow Nominal\ GerundioPP$.

El **sintagma verbal** está formado por un verbo y otros constituyentes según las reglas $VP \rightarrow Verbo$, $VP \rightarrow Verbo\ NP$, $VP \rightarrow Verbo\ NP\ PP$ o $VP \rightarrow Verbo\ PP$.

Las **frases coordinadas** están construidas a partir de dos sintagmas unidos por alguna conjunción, la regla gramatical es $NP \rightarrow NP\ and\ NP$, para el caso de la conjunción "y", por ejemplo.

¿Qué es un Embedding?

En Ciencias de la Computación, un **embedding** (incrustación) es una representación de datos discretos (como palabras, imágenes o usuarios) en un **espacio vectorial continuo de baja dimensión**.

En palabras simples: es la traducción del lenguaje humano (texto) a un lenguaje que la computadora puede "entender" y operar matemáticamente (números organizados en listas).

Características Clave:

1.Densidad: A diferencia del tradicional *One-Hot Encoding* (que genera vectores gigantes llenos de ceros), los embeddings son **vectores densos**. En lugar de tener una dimensión por cada palabra del diccionario, comprimimos el significado en, por ejemplo, 100 o 300 dimensiones.

2.Relación Semántica: La posición de los vectores en este espacio no es aleatoria. Si dos palabras tienen significados similares, sus vectores estarán cerca uno del otro.

1. *Ejemplo futbolístico:* El vector de "balón" y el de "pelota" tendrán una **distancia de coseno** muy pequeña.

¿Cómo se ve un Embedding?

Si tomamos nuestra analogía de fútbol, el embedding de la palabra "**Portero**" no sería una cadena de texto, sino algo parecido a esto:

"Portero" -> [0.12, -0.59, 0.88, ..., 0.01] (un vector de n dimensiones)

Donde cada número representa un "rasgo" abstracto aprendido por la máquina (aunque para nosotros esos números no tengan un nombre claro como "altura" o "agilidad", para el modelo representan patrones de uso).

¿Por qué son tan importantes hoy en día?

Sin los embeddings, la IA moderna no existiría tal como la conocemos. Permiten:

- Reducir la dimensionalidad:** Pasamos de un vocabulario de 1 millón de palabras a un espacio manejable de 300 números.
- Generalizar:** Si el modelo aprende que "gol" es algo bueno en una oración, gracias a los embeddings sabrá automáticamente que "anotación" también es algo bueno, aunque nunca haya visto esa palabra específica en ese contexto.
- Transfer Learning:** Podemos descargar embeddings pre-entrenados por Google o Facebook (que ya leyeron toda la Wikipedia) y usarlos en nuestros propios proyectos de clase sin tener que entrenar desde cero.

Preprocesamiento: De texto bruto a datos estructurados

Antes de aplicar cualquier modelo de Machine Learning, necesitamos "limpiar" el lenguaje humano, que es naturalmente ruidoso y ambiguo.

1. Tokenización: El arte de segmentar

Es el primer paso y consiste en dividir una cadena de texto en unidades mínimas con significado llamadas **tokens**.

•Tipos de Tokenización:

- Por palabra:** "La IA es asombrosa" → ["La", "IA", "es", "asombrosa"].
 - Por subpalabra (Subword):** Muy útil para manejar vocabulario desconocido. "Innegablemente" → ["In", "negable", "mente"].
 - Por oración:** Dividir un párrafo en enunciados completos.
- **Ejemplo práctico:** Si estamos analizando el sentimiento de una canción, la tokenización nos permite aislar cada palabra para evaluar su carga emocional individualmente.

Preprocesamiento: De texto bruto a datos estructurados

2. Normalización: Reduciendo la variabilidad

La normalización busca que palabras que significan lo mismo se vean iguales para la computadora. Esto reduce la dispersión de los datos y mejora el aprendizaje del modelo.

Técnicas clave:

- **Limpieza básica:** Pasar todo a minúsculas, eliminar signos de puntuación y *stopwords* (palabras comunes como "de" o "que" que aportan poca información).
- **Stemming (Truncamiento):** Cortar la palabra a su raíz cruda.
 - *Ejemplo:* "comiendo", "comió", "comerá" → com-
- **Lemmatization (Lematización):** Llevar la palabra a su forma de diccionario (lema) usando análisis morfológico.
 - *Ejemplo:* "mejores" → bueno; "fueron" → ser.

Preprocesamiento: De texto bruto a datos estructurados

3. Representaciones Vectoriales: Hablando el idioma de la máquina

Las computadoras no entienden palabras, entienden números. Necesitamos convertir esos tokens en vectores dentro de un espacio matemático.

• Modelos Clásicos (Bolsa de Palabras / TF-IDF):

- Se basan en el conteo de frecuencias. Son útiles para clasificar documentos, pero pierden el contexto y el orden de las palabras.

• Word Embeddings (Vectores Densos):

- Aquí las palabras se representan como vectores en un espacio de muchas dimensiones (ej. Word2Vec, GloVe).
- **Propiedad mágica:** Palabras con significados similares terminan en coordenadas cercanas.
- *Ejemplo clásico:* Si restas el vector de "Hombre" a "Rey" y sumas "Mujer", el resultado matemático estará muy cerca del vector de "Reina".

Preprocesamiento: De texto bruto a datos estructurados

Ejemplo integrador

Imagina que queremos analizar los tweets del movimiento **8M** "***Día internacional de la mujer***":

1. **Texto original:** "¡Las mujeres marchamos hoy por la igualdad! #8M2020"
2. **Tokenización:** ["¡", "Las", "mujeres", "marchamos", "hoy", "por", "la", "igualdad", "!", "#8M2020"]
3. **Normalización (Limpieza + Lemmatización):** ["mujer", "marchar", "hoy", "igualdad"] (eliminamos puntuación y artículos).
4. **Representación Vectorial:** Convertimos esos lemas en vectores numéricos para que un algoritmo de Machine Learning pueda detectar, por ejemplo, que "marchar" y "protestar" tienen una relación semántica estrecha en ese contexto.

Procesamiento de habla

El reto del **ASR (Reconocimiento de voz)** y el **TTS (Texto a voz)** radica en los acentos y el ruido ambiental. Hoy, modelos como los de OpenAI y Google permiten una interacción fluida en asistentes virtuales.

- **ASR (Automatic Speech Recognition):** voz a texto
- **TTS (Text-to-Speech):** texto a voz

Retos principales:

- Ruido ambiental
- Variabilidad de acentos
- Diferencias entre lenguaje escrito y hablado

Aplicaciones:

- Asistentes virtuales
- Interfaces humano-máquina
- Accesibilidad

Aquí se conectan modelos modernos como ChatGPT y los asistentes inteligentes.

El procesamiento de lenguaje natural (PLN) utiliza diversos algoritmos para clasificar textos o palabras basándose en la "distancia" o similitud entre ellas. La elección del algoritmo depende de si se busca medir similitud léxica (ortográfica) o semántica (significado). Revisaremos los algoritmos y métricas más utilizados para clasificación por distancias de palabras.

1. Métricas de distancia basadas en edición (Léxicas - Distancias Sintácticas)

Estos algoritmos miden cuántos cambios (inserciones, eliminaciones, sustituciones) son necesarios para transformar una palabra en otra. Estos métodos son ideales para corrección ortográfica, búsqueda difusa (*fuzzy search*) y detección de plagio simple, calculando cuántos cambios se necesitan para transformar una cadena en otra.

- **Distancia Levenshtein:** Mide el número mínimo de operaciones (inserciones, eliminaciones o sustituciones), es decir, calcula el número mínimo de ediciones de un solo carácter para transformar una cadena en otra. Es fundamental para corrección ortográfica y detección de duplicados.
- **Distancia de Hamming:** Mide la cantidad de posiciones en las que los caracteres correspondientes son diferentes en dos cadenas de igual longitud.
- **Algoritmo Jaro-Winkler:** Variación de la distancia de edición que da más peso a las coincidencias al principio de la palabra, ideal para comparar nombres propios. Similar a Levenshtein, pero da mayor importancia a las coincidencias al principio de la cadena, siendo útil para comparar nombres propios.

2. Algoritmos de Similitud Vectorial (Distancias Semánticas - Basadas en contexto)

Transforman palabras o textos en vectores numéricos (embeddings) y calculan la distancia entre estos puntos en un espacio multidimensional. En otras palabras, estos algoritmos clasifican documentos comparando la "distancia" entre los vectores que representan el significado de las palabras (embeddings)

- **Similitud Coseno (Cosine Similarity o Distancia Coseno):** Mide el coseno del ángulo entre dos vectores. Es la métrica más utilizada en PLN para determinar la similitud semántica, ya que se enfoca en la orientación de los vectores más que en su magnitud (como Word2Vec o GloVe).
- **Distancia Euclidiana (L2):** Mide la distancia en línea recta entre dos puntos en un espacio vectorial.
- **Distancia Manhattan (L1):** Suma las diferencias absolutas de las coordenadas de los vectores

Clasificación con Machine Learning y Distancias

Una vez calculada la distancia entre textos, se utilizan algoritmos de clasificación supervisada para categorizarlos.

3. Técnicas de Clasificación basadas en distancia

Estos algoritmos utilizan las métricas anteriores para clasificar nuevos textos.

- **K-Nearest Neighbors (KNN)**: Clasifica un documento nuevo asignándole la clase más común entre sus k vecinos más cercanos, definidos por métricas como la similitud coseno.
- **Algoritmo Jaccard**: Mide la similitud entre dos conjuntos de palabras dividiendo el tamaño de la intersección por el tamaño de la unión de los conjuntos.
- **Modelos de Bolsa de Palabras (Bag-of-Words) + SVM**: Aunque no es una "distancia" directa, el uso de TF-IDF para crear vectores y luego clasificarlos con Support Vector Machines (SVM) es un estándar para clasificación de texto por frecuencia de palabras.

Resumen de Aplicaciones

Algoritmo/Métrica	Mejor uso
Levenshtein	Corrección ortográfica, fuzzy matching, detección de errores OCR.
Similitud Coseno	Análisis de sentimientos, sistemas de recomendación, clasificación temática.
KNN	Clasificación de documentos basada en la cercanía de sus características.
Jaccard	Comparación rápida de documentos basada en palabras compartidas.

En Python, la mayoría de estos algoritmos se pueden implementar utilizando librerías como scikit-learn para métricas vectoriales (`cosine_similarity`) o nltk y Levenshtein para distancias de cadenas

Word2Vec

1. ¿Qué es Word2Vec? El concepto de "Barrio"

La idea central es la **Hipótesis Distribucional**: *"Palabras que aparecen en contextos similares tienden a tener significados similares"*.

Si en miles de crónicas deportivas leemos:

- "El **delantero** anotó un gol."
- "El **atacante** anotó un gol."

El modelo entiende que "delantero" y "atacante" son semánticamente cercanos porque sus "vecinos" (contexto) son los mismos.

2. La analogía del campo de juego (**Embeddings**)

Imagina el campo de fútbol como un plano cartesiano. Si asignamos una posición técnica a cada palabra, Word2Vec colocaría a los jugadores según sus atributos:

• Cercanía por posición:

- "Portero" y "Arquero" estarían casi en el mismo punto.
- "Delantero" y "Extremo" estarían cerca entre sí, pero muy lejos de "Portero".


• Relaciones relacionales (**aritmética de vectores**): El modelo puede resolver "ecuaciones" de palabras:


- Messi - Argentina + Portugal = Cristiano Ronaldo
- Guardiola - entrenador + jugador = Xavi (o algún jugador que personifique su estilo).



¿Qué animal es más similar a un capibara?

Podríamos analizar los valores uno por uno y realizar los cálculos para hacer esa evaluación, pero visualizar los datos como puntos en un espacio bidimensional hace que encontrar la respuesta sea muy intuitivo.

El gráfico nos muestra que el animal más cercano al capibara es el oso panda (nuevamente, en términos de su tamaño y ternura subjetivos). Una forma de calcular qué tan "separados" están dos puntos es encontrar su *distancia euclidiana*.







3. Arquitecturas: ¿Cómo aprende el modelo?

Existen dos formas de entrenar Word2Vec, y podemos verlas como jugadas de pizarrón:

A. CBOW (Continuous Bag of Words)

El objetivo: Predecir el jugador central basado en sus compañeros que lo rodean.

•**Contexto:** [Casemiro, Kroos, _____, Vinícius]

•**Predicción:** "Modric".

•**Uso:** Es más rápido y funciona bien con palabras frecuentes.

B. Skip-gram

El objetivo: Dado un jugador, predecir quiénes suelen estar a su alrededor.


•**Input:** "Pele"

•**Predicción (Contexto):** [Santos, Brasil, Mundial, Gol].


•**Uso:** Funciona mejor con conjuntos de datos pequeños y representa mejor las palabras poco frecuentes.

Word2vec

CBOW



Skip-gram



4. Ejemplo en Código (Python + Gensim)

Para que los alumnos vean la "magia" en la terminal, usaríamos la librería gensim. Imaginemos que ya entrenamos el modelo con noticias de la Liga MX o de la Champions:

40_UNAM_AI_Actividad_Laboratorio_5_11_algoritmos_clase.ipynb ☆

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

mandos + Código + Texto ▶ Ejecutar todo

Word2Vec

Ejemplo en Código (Python + Gensim)

Usaríamos la librería gensim. Imaginemos que ya entrenamos el modelo con noticias de la Liga MX o de la Champions:

```
[8]
✓ 2 s
1 from gensim.models import Word2Vec
2
3 # Un 'corpus' de ejemplo (muy simplificado)
4 entrenamiento_futbol = [
5     ["el", "delantero", "pateó", "al", "arco"],
6     ["el", "atacante", "pateó", "al", "marco"],
7     ["el", "portero", "detuvo", "el", "balón"],
8     ["el", "arquero", "atajó", "la", "pelota"]
9 ]
10
11 # Entrenamos el modelo
12 modelo = Word2Vec(sentences=entrenamiento_futbol, vector_size=100, window=2, min_count=1)
13
14 # 1. Encontrar similitud
15 similitud = modelo.wv.similarity('delantero', 'atacante')
16 print(f"Similitud entre delantero y atacante: {similitud:.2f}")
17
18 # 2. ¿Cuál no encaja en la alineación?
19 no_encaja = modelo.wv.doesnt_match(["delantero", "atacante", "arquero", "pizza"])
20 print(f"El infiltrado es: {no_encaja}")
```

*** WARNING:gensim.models.keyedvectors:vectors for words {'pizza'} are not present in the model, ignoring these words
Similitud entre delantero y atacante: -0.16
El infiltrado es: atacante

© 2026 UNAM Facultado de Ciencias – Todos los derechos reservados

5. ¿Por qué es mejor que la Distancia de Palabras?

Mientras que la distancia de **Levenshtein** diría que "Messi" y "Massa" se parecen (porque solo cambia una letra), **Word2Vec** diría que no tienen nada que ver.

En cambio, Word2Vec entendería que "Balón d'Or" y "Trofeo" son primos hermanos, aunque no compartan ni una sola letra. Para los proyectos de Inteligencia Artificial, esto es el paso previo a modelos más grandes como los Transformers o GPT.

En el mundo del procesamiento de lenguaje natural (NLP), **Word2Vec** fue el "delantero estrella" que inició la revolución de los embeddings, pero después surgieron otros modelos que perfeccionaron la técnica o resolvieron sus limitaciones.

1. GloVe (Global Vectors for Word Representation)

Si Word2Vec aprende "jugada por jugada" (mirando ventanas locales de palabras), **GloVe** mira "todo el torneo completo" (estadísticas globales del corpus).

- Cómo funciona:** Construye una matriz gigante de co-ocurrencia que cuenta cuántas veces aparece cada palabra junto a todas las demás en todo el dataset. Luego, reduce esa matriz a vectores.
- La ventaja:** Es muy bueno capturando relaciones semánticas globales. Mientras Word2Vec es un modelo predictivo, GloVe es un modelo basado en conteo y estadística.
- Analogía de fútbol:** Word2Vec es como analizar cómo se mueve un jugador en relación con los que tiene a 5 metros; GloVe es analizar el mapa de calor y las estadísticas de pases de toda la temporada.

En el mundo del procesamiento de lenguaje natural (NLP), **Word2Vec** fue el "delantero estrella" que inició la revolución de los embeddings, pero después surgieron otros modelos que perfeccionaron la técnica o resolvieron sus limitaciones.

2. FastText (El modelo de "Sub-palabras")

Este fue creado por Facebook y es, posiblemente, la evolución más directa y útil de Word2Vec, especialmente para idiomas como el español.

- **El problema de Word2Vec:** Si la palabra no está en el vocabulario (ej. un error de dedo como "gool" o un neologismo), el modelo no sabe qué hacer.
- **La solución de FastText:** No solo vectoriza palabras completas, sino también **n-gramas de caracteres** (pedacitos de palabras).
 - Para la palabra "delantero", FastText también aprende de "delant", "ante", "tero".
- **Por qué es mejor:** Puede generar un vector para una palabra que nunca ha visto antes basándose en sus raíces o sufijos. Es excelente para manejar errores ortográficos o conjugaciones verbales complejas.
- **Analogía de fútbol:** Word2Vec solo reconoce a "Messi". FastText reconoce que cualquier persona con el apellido "Messi" o que use la camiseta "10" probablemente tiene algo que ver con la misma familia o rol, aunque no lo conozca personalmente.

En el mundo del procesamiento de lenguaje natural (NLP), **Word2Vec** fue el "delantero estrella" que inició la revolución de los embeddings, pero después surgieron otros modelos que perfeccionaron la técnica o resolvieron sus limitaciones.

3. ELMo y BERT (Embeddings Contextuales)





Aquí es donde pasamos de la "vieja escuela" a la IA moderna. Word2Vec, GloVe y FastText tienen un defecto grave: **el vector de una palabra siempre es el mismo.**

- **El problema de la polisemia:** En Word2Vec, la palabra "**Planta**" tiene el mismo vector si hablas de una "planta botánica" o de la "planta del pie".
- **La evolución (BERT/ELMo):** Estos modelos usan arquitecturas más complejas (Transformers). El vector de la palabra **cambia según el contexto.**
 - "El defensa se **planta** bien en el área" vs "Esa **planta** necesita agua". El vector resultante para "planta" será distinto en cada oración.
- **Analogía de fútbol:** Word2Vec es como tener un cromó de un jugador fijo. BERT es como ver al jugador en vivo: su "significado" en el campo cambia totalmente si está defendiendo un tiro de esquina o si está cobrando un penal.

Modelo	Unidad Mínima	Principal Ventaja
Word2Vec	Palabra	Rápido, eficiente y simple de entender.
GloVe	Palabra + Estadística	Captura mejor las relaciones globales del texto.
FastText	N-gramas (letras)	Maneja palabras fuera del vocabulario y errores.
BERT	Tokens en contexto	Entiende el significado exacto según la oración.

Se sugiere empezar con **FastText** si van a trabajar con textos de redes sociales (por las faltas de ortografía) o **BERT** si buscan la máxima precisión académica.

BERT



GPT


BERT

Claude

Gemini



Idioma



Procesamiento



Razón



Multimodal

Comparativa de modelos de IA

Maqueta de LLM




Figure 1: The Transformer - model architecture.

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu


Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer,

<https://bbycroft.net/llm>



Algoritmos de PNL

Distancia de Levenshtein

Algoritmo Formal

Sea Σ un alfabeto finito. Dadas dos cadenas $A = a_1, a_2, \dots, a_n$ y $B = b_1, b_2, \dots, b_m$ sobre Σ donde $|A| = n$ y $|B| = m$.

La **Distancia de Levenshtein** $L(A, B)$ se define como el costo del camino de costo mínimo en un grafo de ediciones, o bien, mediante la siguiente relación de recurrencia:

- $D(i - 1, j) + 1$ (**Eliminación**): Miramos el costo de la celda de arriba y sumamos 1.
- $D(i, j - 1) + 1$ (**Insertión**): Miramos el costo de la celda de la izquierda y sumamos 1.
- $D(i - 1, j - 1) + 1_{a_i \neq b_j}$ (**Sustitución**): Miramos la diagonal. Aquí entra en juego la **función indicadora**:
 - Si los caracteres son diferentes ($a_i \neq b_j$), sumamos **1** (costo de sustituir una letra por otra).
 - Si los caracteres son iguales ($a_i = b_j$), sumamos **0** (no hay costo porque la letra ya es la correcta).

Distancia de Levenshtein

1. El Objetivo

La función $D(i, j)$ representa la distancia mínima para transformar el prefijo de la primera palabra (de longitud i) en el prefijo de la segunda palabra (de longitud j).

2. Los Casos Base (Condiciones de Frontera)

Si $j = 0$: Para convertir una palabra de longitud i en una cadena vacía, necesitamos i eliminaciones.

Si $i = 0$: Para convertir una cadena vacía en una palabra de longitud j , necesitamos j inserciones.

Esto es lo que llena la primera fila y la primera columna de nuestra matriz.

3. El Corazón del Algoritmo (Inducción)

Cuando estamos comparando caracteres en cualquier otra posición, la fórmula busca el **mínimo** de tres caminos posibles, lo que garantiza que siempre tomamos la ruta más eficiente.

4. ¿Por qué es una "Recurrencia"?

Se llama así porque el valor de un estado actual (i, j) depende directamente de los valores de los estados anteriores (sus vecinos en la matriz). Es la esencia de la **Programación Dinámica**: dividimos un problema complejo (comparar dos palabras largas) en subproblemas más pequeños (comparar letras individuales) y reutilizamos los resultados ya calculados.

En resumen: Es la regla lógica que dicta cómo se debe llenar cada celda de la matriz de distancias para encontrar el camino más corto entre dos cadenas de texto.

Especificación del Algoritmo (Wagner-Fischer)

Este algoritmo computa la distancia en una estructura de datos matricial M de dimensiones $(n+1) \times (m+1)$.

Pasos Formales:

1. Inicialización de Casos Base:

- $\forall i \in \{0, \dots, n\} : M[i, 0] \leftarrow i$ (Representa la transformación de una cadena de longitud i a una cadena vacía).
- $\forall j \in \{0, \dots, m\} : M[0, j] \leftarrow j$ (Representa la transformación de una cadena vacía a una de longitud j).

2. Iteración de Estados:

- Para cada fila i desde 1 hasta n :
 - Para cada columna j desde 1 hasta m :
 - Si $A[i] = B[j]$, el costo de sustitución $W \leftarrow 0$.
 - Si $A[i] \neq B[j]$, el costo de sustitución $W \leftarrow 1$.
 - $M[i, j] \leftarrow \min(M[i-1, j] + 1, \quad M[i, j-1] + 1, \quad M[i-1, j-1] + W)$.

3. Finalización:

- El valor de $L(A, B)$ se encuentra en $M[n, m]$.

La respuesta corta es que **Levenshtein es el concepto (la métrica)** y **Wagner-Fischer es la implementación (el algoritmo)**.

1. La Métrica (Vladimir Levenshtein, 1965)

Vladimir Levenshtein fue un matemático soviético que definió la **distancia** teórica entre dos secuencias. Él estableció la regla de qué operaciones se permiten (inserción, eliminación, sustitución) y la lógica de la función de recurrencia que acabas de ver. Sin embargo, su publicación original no se centraba en cómo una computadora debía calcularla de forma eficiente, sino en la teoría de códigos de corrección de errores.

2. El Algoritmo (Wagner y Fischer, 1974)

Robert Wagner y Michael Fischer fueron quienes tomaron esa definición matemática y desarrollaron el algoritmo de **Programación Dinámica** que utiliza la matriz $O(n \times m)$ para resolverlo en tiempo polinomial. Antes de ellos, calcular la distancia de Levenshtein de forma ingenua (por fuerza bruta o recursión simple) era extremadamente costoso (exponencial).

Diferencia clave :

- **Levenshtein:** Define *qué* estamos midiendo (la distancia de edición).
- **Wagner-Fischer:** Define *cómo* lo calculamos eficientemente (usando la matriz y programación dinámica).

Distancia de Levenshtein

Características matemáticas:

- **Métrica de identidad:** $d(a, b) = 0$ si y solo si $a = b$.
- **Simetría:** $d(a, b) = d(b, a)$.
- **Desigualdad triangular:** $d(a, c) \leq d(a, b) + d(b, c)$
- **Límites:** El valor siempre estará entre $|s| - |t|$ y $\max(|s|, |t|)$.

Métricas de complejidad

Para la implementación estándar usando una matriz:

- Complejidad **Temporal:** $O(n \times m)$, donde n y m son las longitudes de las dos palabras. Debemos recorrer cada celda de la matriz una vez.
- Complejidad **Espacial:** $O(n \times m)$ para almacenar la matriz de costos.

Nota: Es posible optimizar el espacio a $O(\min(n, m))$ si solo guardamos las dos filas anteriores, ya que el cálculo solo depende de los estados vecinos inmediatos.

Distancia de Levenshtein

Pseudocódigo

ALGORITMO DistanciaLevenshtein(cadena1, cadena2)

n <- longitud(cadena1)

m <- longitud(cadena2)

Crear matriz D de tamaño (n+1) x (m+1)

PARA i DESDE 0 HASTA n: D[i, 0] <- i

PARA j DESDE 0 HASTA m: D[0, j] <- j

PARA i DESDE 1 HASTA n:

PARA j DESDE 1 HASTA m:

costo <- (cadena1[i] == cadena2[j]) ? 0 : 1

D[i, j] <- MINIMO(

D[i-1, j] + 1, // Eliminación

D[i, j-1] + 1, // Inserción

D[i-1, j-1] + costo // Sustitución

)

RETORNAR D[n, m]

FIN ALGORITMO

```
40_UNAM_AI_Actividad_Laboratorio_5_11_algoritmos_clase.ipynb ☆
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

mandos + Código + Texto ▶ Ejecutar todo

installing collected packages: gensim
Successfully installed gensim-4.4.0

Algoritmo de Distancia de Levenshtein es un

[9] 0s
def levenshtein_futbol(palabra_a, palabra_b):
    """
    Calcula la distancia de edición entre dos términos.
    Ejemplo: 'Messi' vs 'Messi' (0), 'Gol' vs 'Gool' (1)
    """
    n = len(palabra_a)
    m = len(palabra_b)

    # 1. Crear la matriz inicializada en ceros
    matriz = [[0 for _ in range(m + 1)] for _ in range(n + 1)]

    # 2. Casos base: transformar cadena a vacío o viceversa
    for i in range(n + 1):
        matriz[i][0] = i
    for j in range(m + 1):
        matriz[0][j] = j

    # 3. Llenado de la matriz con programación dinámica
    for i in range(1, n + 1):
        for j in range(1, m + 1):
            # Si los caracteres son iguales, el costo es 0
            if palabra_a[i-1] == palabra_b[j-1]:
                costo = 0
            else:
                costo = 1

            # Buscamos el mínimo entre las 3 operaciones posibles
            matriz[i][j] = min(
                matriz[i-1][j] + 1, # Eliminación
                matriz[i][j-1] + 1, # Inserción
                matriz[i-1][j-1] + costo # Sustitución
            )

    return matriz[n][m]

# --- PRUEBA PARA CLASE ---
termino_busqueda = "Gool"
termino_real = "Gol"

distancia = levenshtein_futbol(termino_busqueda, termino_real)
print(f"La distancia entre '{termino_busqueda}' y '{termino_real}' es: {distancia}")
# Resultado esperado: 1

... La distancia entre 'Gool' y 'Gol' es: 1
```

Están desarrollando una app de resultados en vivo. El usuario escribe '**Leoneza**' pero en su base de datos tienen el equipo '**Leonesa**'. Gracias a Levenshtein (distancia = 1), el sistema puede clasificar esa entrada como un error tipográfico y mostrar los resultados correctos automáticamente. Este algoritmo es el que permite que los buscadores nos digan: *"¿Quisiste decir...?"*

Word2Vec

para **Word2Vec**, específicamente para la arquitectura **Skip-gram**, que es la más didáctica para entender cómo se generan los embeddings desde cero.

1. El Algoritmo “con palabras” (Lógica de Intuición)

Imagina que estamos en un entrenamiento de fútbol. Queremos saber qué tan "cercanos" son los jugadores por cómo se pasan el balón.

1.Deslizar la ventana: Caminamos por una oración (el corpus). En cada paso, elegimos una **palabra central** (el jugador con el balón) y miramos a sus **palabras de contexto** (los compañeros a los que puede pasarles el balón dentro de un radio de, por ejemplo, 2 metros).

2.El reto de la predicción: El algoritmo intenta predecir, dada la palabra central, cuáles son las palabras que probablemente aparecerán a su alrededor.

3.Ajuste de posiciones:

1. Si el modelo acierta (ej. "Messi" suele estar cerca de "Gol"), refuerza esa conexión acercando sus vectores en el espacio.
2. Si el modelo falla, aplica un castigo y aleja los vectores.

4.El resultado: Al final de miles de iteraciones, las palabras que "juegan en la misma zona" terminan con coordenadas (vectores) muy similares.

2. Algoritmo Formal (Skip-gram con Softmax)

Word2Vec no es una red neuronal profunda, sino una red de **una sola capa oculta** (denominada *projection layer*) que busca maximizar la probabilidad del contexto.

Función de Objetivo (Log-Verosimilitud)

Dado una secuencia de palabras de entrenamiento $w_1, w_2, \dots, w_T$, el objetivo es maximizar el promedio de la log-probabilidad:

$$J(\theta) = \frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$$

Donde c es el tamaño de la ventana de contexto.

La Función Softmax

La probabilidad $p(w_O | w_I)$ se define usando la exponencial del producto punto de los vectores:

$$p(w_O | w_I) = \frac{\exp(v_{w_O}'^\top v_{w_I})}{\sum_{w=1}^V \exp(v_w'^\top v_{w_I})}$$

- v_w y v_w' son las representaciones de entrada y salida de la palabra w .
- V es el número total de palabras en el vocabulario.

3. Métricas de Complejidad

- **Complejidad Temporal (Entrenamiento):** $O(E \times T \times c \times \log V)$.
 - E es el número de épocas, T el número de palabras en el corpus y V el tamaño del vocabulario. (Nota: El uso de *Hierarchical Softmax* o *Negative Sampling* reduce el costo de V a $\log V$).
- **Complejidad Espacial:** $O(V \times D)$, donde D es la dimensionalidad del embedding (típicamente 100-300). Necesitamos almacenar dos matrices de pesos: una para los vectores de entrada y otra para los de salida.

4. Pseudocódigo

ALGORITMO **Word2Vec_SkipGram**(corpus, dimension, ventana, tasa_aprendizaje)

Vocabulario <- Obtener_Palabras_Unicas(corpus)

V <- longitud(Vocabulario)

// Inicializar matrices de pesos con valores aleatorios pequeños

W_entrada <- Matriz_Aleatoria(V, dimension)

W_salida <- Matriz_Aleatoria(dimension, V)

PARA epoca DESDE 1 HASTA N_epocas:

PARA CADA palabra_central EN corpus:

contexto <- Obtener_Ventana(palabra_central, ventana)

PARA CADA palabra_contexto EN contexto:

// Forward pass

h <- W_entrada[indice_central]

u <- h * W_salida

y_pred <- Softmax(u)

// Calcular error (e = y_pred - y_real)

error <- Calcular_Error(y_pred, palabra_contexto)

// Backpropagation (Gradiente Descendente)

Actualizar W_salida usando error y h

Actualizar W_entrada usando error y W_salida

RETORNAR W_entrada

FIN ALGORITMO

Word2Vec Algoritmo desde Cero

```
[10]
✓ 0 s ▶ 1 import numpy as np
2
3 def softmax(x):
4     e_x = np.exp(x - np.max(x))
5     return e_x / e_x.sum(axis=0)
6
7 class Word2VecSimplified:
8     def __init__(self, vocab_size, embed_dist):
9         self.n = embed_dist # Dimensiones
10        self.v = vocab_size # Tamaño vocabulario
11        # Inicialización de pesos (He initialization)
12        self.w1 = np.random.randn(self.v, self.n)
13        self.w2 = np.random.randn(self.n, self.v)
14
15    def forward(self, x):
16        # x es un vector one-hot o el índice de la palabra
17        h = self.w1[x]
18        u = np.dot(h, self.w2)
19        y_c = softmax(u)
20        return y_c, h, u
21
22    def backward(self, e, h, x):
23        # Gradientes para actualizar los pesos
24        dw2 = np.outer(h, e)
25        dw1 = np.dot(self.w2, e.T)
26
27        # Actualización simple (tasa de aprendizaje 0.01)
28        self.w2 = self.w2 - (0.01 * dw2)
29        self.w1[x] = self.w1[x] - (0.01 * dw1.T)
30
31 # Ejemplo de uso conceptual:
32 # 1. Definimos vocabulario: {'gol': 0, 'messi': 1, 'futbol': 2}
33 # 2. Si entra 'messi' (index 1) y el contexto es 'gol' (index 0)
34 modelo = Word2VecSimplified(vocab_size=3, embed_dist=2)
35 y_pred, h, u = modelo.forward(1)
36
37 # El error es (predicción - real) donde real es un one-hot del contexto
38 error = y_pred.copy()
39 error[0] -= 1
40
41 modelo.backward(error, h, 1)
42 print("Vector actualizado de 'Messi':", modelo.w1[1])
```

... Vector actualizado de 'Messi': [0.67723212 0.00856268]

Inteligencia Artificial

Visión computacional y sistemas multimodales


Dra. Jessica Sarahi Méndez Rincón

El propósito principal de la **visión computacional** es obtener información de los píxeles existentes en una imagen digitalizada. Desde el punto de vista biológico, facilita la obtención de modelos computacionales del sistema visual de los seres humanos. Desde la perspectiva en ingeniería, permite construir sistemas autónomos que puedan realizar algunas de las tareas que ejecuta el sistema visual humano.


Para los humanos, la obtención de información de una imagen es un proceso trivial. Cualquier persona puede describir con facilidad lo que ve en una fotografía, reconocer un rostro aun cuando solo lo ha visto una vez, incluso los niños pueden platicar de una película al haberla visto también una vez. Para realizar estas tareas, los seres humanos utilizan la retina, el nervio óptico y el córtex visual. Con la finalidad de replicar este comportamiento, en la visión computacional se cuentan con cámaras, datos y algoritmos que son capaces de obtener la información de una imagen. En 1966, Seymour Papert del MIT (Instituto Tecnológico de Massachusetts, por sus siglas en inglés) inició un proyecto denominado “*Summer Vision Project*” cuyo objetivo era construir un sistema que permitiera analizar e identificar objetos en una imagen (Papert, 1966). Este proyecto de verano es pionero en el campo de visión computacional. Más adelante, en los años 70, David Marr propone los fundamentos de la visión computacional, basándose en estudios del hipocampo, cerebelo y el córtex en procesos de percepción humana. Actualmente David Marr es conocido como el padre de la visión computacional moderna (Marr, 2010).

En el contexto de la visión computacional, los datos son considerados como una función que depende de una o más variables independientes. Por ejemplo, el audio se considera como un conjunto de datos unidimensionales (1D) que dependen del tiempo (variable independiente) y puede ser representado como la función $A(t)$. De la misma manera, una imagen puede ser representada con datos en dos dimensiones (2D) que dependen de coordenadas espaciales x y y , $I(x,y)$. El video se representa como una función que depende de 3 variables, dos coordenadas espaciales y una temporal, $V(x, y, t)$.

La formación de imágenes se debe a la reflexión de rayos de luz que inciden sobre la superficie de un objeto como se muestra en la figura 1. El objeto refleja luz en todas las direcciones.



Eventualmente estos rayos son reflejados en la dirección del ojo humano y se proyectan en la retina (ver figura 2), la superficie interna del



Proyección en la retina.

El funcionamiento del ojo puede ser descrito utilizando la cámara estenopeica, un modelo simple de cámara compuesta de una caja, un pequeño agujero y una superficie fotosensible. La luz reflejada por un objeto viaja en línea recta a través del orificio de la cámara y “golpea” la superficie fotosensible. El uso de lentes ópticos es un truco físico para agrandar el orificio y obtener más luz.

Es posible medir la energía electromagnética donde los rayos de luz inciden en la retina. Dichas medidas, en función de la posición en la retina, proporcionan una representación de la imagen. Asumiendo que la retina es un plano y todas las posiciones en ella se dan por coordenadas, se define una función cuyo valor en la posición de la retina (el plano de imagen o dominio de imagen) es proporcional a la cantidad de energía medida.


Los datos existen en la naturaleza de forma continua. Las escenas dinámicas que observas a tu alrededor cambian continuamente en tiempo y espacio. Si se desea representar digitalmente la información, es necesario cambiar de una función continua a una función discreta, es decir, una función que solo se define para ciertos valores de la variable independiente. Este proceso se conoce como discretización o digitalización y es el primer paso a realizar en cualquier aplicación de procesamiento de imágenes digitales. Al discretizar una imagen definida en coordenadas espaciales continuas (x, y) , los valores de la función discreta correspondiente están definidos en valores enteros de $f(x,y)$, conocidos como píxeles, los cuales representan un elemento de la imagen.

Una muestra está formada por un valor o un conjunto de valores de una función continua $f(t)$ en valores específicos de la variable independiente t . El muestreo es el proceso por el cual se extraen una o más muestras de una señal continua $f(t)$ para obtener una señal discreta $f(t)$. De tal manera que una imagen estará formada por una cuadrícula regular de muestras puntuales y un pixel representa cada muestra puntual.

Una señal analógica o continua puede tomar cualquier valor de precisión infinita. Sin embargo, al convertirla a una señal digital está representada por un conjunto limitado de valores, esto es, se asigna un rango de valores de la señal analógica a un valor digital. Dicho proceso se conoce como cuantización, mientras que la diferencia entre el valor original de una señal y su representación digital se conoce como error de cuantización.


La representación de imágenes se hace por medio de coordenadas. En matemáticas, se tiene la costumbre que el eje x va de izquierda a derecha y el eje y de abajo hacia arriba con el origen ubicado en la esquina inferior izquierda. Sin embargo, para una imagen digital $f(x,y)$ es distinto.

Con el objetivo de comprender la representación de una imagen, se deben identificar los ejes con las coordenadas a lo largo de esos ejes y los índices en la matriz que contiene todas las muestras.




Los puntos muestra se encuentran en el centro de cada cuadrado (no pixeles) y se puede ver que el origen se encuentra en la esquina superior izquierda. El eje coordenado x va de izquierda a derecha y el eje coordenado y de arriba hacia abajo.

Las imágenes a color están representadas a partir de múltiples canales, por lo general, rojo, verde y azul (RGB, por sus siglas en inglés). En la figura 5 se muestra la forma de una matriz de una imagen a color que es $M \times N \times 3$. Cada plano de la función $f(x,y,z)$, donde c es 0, 1 o 2, corresponde a un plano de color R, G o B, y puedes acceder a ellos de forma independiente como se muestra en la segunda imagen de la figura 5. En este caso puedes utilizar el canal del color verde para tener una buena aproximación de la luminancia.




(373, 373, 3)




Color y operadores de puntos

Para entender el color es necesario comprender la forma en la que el cerebro humano lo percibe. El color no puede ser definido solo en función de las propiedades físicas del estímulo, debe considerarse, además, la forma en la que el sistema visual humano observa la energía electromagnética (la luz). Los objetos no tienen color, el color es la percepción de lo que ve el ojo humano. La colorimetría es una ciencia que considera una descripción psicofísica del color y busca reducir el papel del observador a juzgar sobre la equivalencia de colores.




Un rayo de luz que incide en las celdas fotosensibles de la retina se caracteriza por su distribución espectral t en función de la longitud de onda λ . $t(\lambda)d\lambda$ es la energía en el haz de luz, cuyas longitudes de onda se encuentran en el intervalo $[\lambda, \lambda + d\lambda]$. En colorimetría se estudian los haces de colores, es decir, los colores asociados a los haces de luz. No hay que confundir lo anterior con los colores de los objetos, que son los colores asociados a los objetos que reflejan la luz de una fuente de iluminación. Por ejemplo, cuando se ilumina una fresa con un haz de luz blanca, la fresa solo refleja los componentes rojos de la luz y, por lo tanto, se percibe una fresa de color rojo. Si se ilumina la misma fresa con un haz de luz que no tenga componente rojo, la fresa se percibirá de color negro, ya que no hay color rojo que reflejar. Por consiguiente, al iluminar algún objeto con cierto tipo de luz, puede cambiar completamente la percepción del color que se tenga de él.

La luz es radiación electromagnética que tiene una longitud de onda específica dentro de cierto rango. Los fotorreceptores en la retina son sensibles a las ondas electromagnéticas cuya longitud de onda se encuentra entre 400 y 700 nm como se observa en la figura.



Un haz de luz y, por tanto, su color, está definido por su función de distribución espectral o espectro. Debido a que el espectro en función de la longitud de onda es una función definida para números reales, el espacio espectral es de dimensión infinita.

Dentro de la retina existen dos tipos de fotorreceptores: bastones y conos. Los primeros se utilizan en condiciones de poca iluminación y no son capaces de distinguir colores, solo detectan la diferencia entre claro y oscuro. Los conos se concentran en el centro del campo visual (la fovea) y existen tres tipos, los cuales contienen pigmentos fotosensibles con diferentes absorciones espectrales. En la figura 7 se muestran las curvas de sensibilidad ocular correspondientes a tres funciones de sensibilidad conocidas como curvas de sensibilidad S, M y L (longitudes de onda corta, media y larga, por sus siglas en inglés).




Los operadores de puntos permiten realizar operaciones matemáticas para modificar imágenes pixel a pixel (el punto). Estas operaciones son básicamente sumas y restas ampliamente utilizadas en procesamiento de imágenes: mezclado alfa (α -Blending), enmascaramiento de enfoque (unsharp masking) y umbralización de imágenes (thresholding).

Sean f y g dos imágenes a color definidas en el mismo dominio espacial. La secuencia de imágenes que muestra la transición de f a g es $h_\alpha = (1 - \alpha)f + \alpha g$, donde $\alpha = [0,1]$; dicho proceso se conoce como mezclado alfa. α -Blending es un proceso donde se superpone una imagen de primer plano sobre una imagen de fondo. Nota que para poder operar las matrices que contienen los datos de las imágenes estas deben ser de la misma dimensión.

Para hacer la mezcla alfa, es posible hacerlo con la función *addWeighted*. Para que observes el efecto de la operación, se recomienda que utilices distintos valores de alfa en el rango especificado.

El enmascaramiento de enfoque es un tipo de mezclado alfa y es posible hacerlo también con la función *addWeighted* de *openCV*.



Operadores geométricos

Las transformaciones geométricas son técnicas de procesamiento de imágenes que tienen muchas aplicaciones. Un caso de uso sencillo, por ejemplo, es la modificación de la escala del contenido gráfico de una imagen al mostrarse en una computadora o en un teléfono celular.

El objetivo de un operador de imagen es transformar una imagen. Los operadores de procesamiento de imágenes se pueden clasificar en cuatro categorías: operadores de puntos, geométricos, locales y globales. Los operadores de puntos trabajan al nivel de píxeles modificando sus valores. Los operadores geométricos, por el contrario, desplazan píxeles a nuevas posiciones.

Deformación

Las transformaciones geométricas son de las operaciones más comunes que se encuentran en cualquier tarea de procesamiento de imágenes. Modifican las imágenes manteniendo los colores, pero colocando los píxeles en lugares distintos. Regularmente se utilizan para crear efectos artísticos o corregir algún tipo de distorsión al momento de tomar la imagen, ya sea por rotación de la cámara o distorsión de la perspectiva. También se usan para deformar proyectivamente una imagen en otro plano de imagen. Por ejemplo, ver una imagen desde una perspectiva distinta a la vista frontal. Así que una transformación geométrica o un operador geométrico permiten cambiar la forma de las imágenes, crear copias de la misma y proyectarlas en un nuevo sistema coordenado.

Los operadores geométricos son rotación, traslación y escalamiento, y se conocen como transformaciones geométricas afines. En la siguiente sección se presentará el fundamento de estas transformaciones. Desde el punto de vista geométrico, la rotación es el movimiento circular de un objeto alrededor de un punto y se caracteriza por el ángulo de rotación (la amplitud de rotación), el centro de rotación (un punto de referencia) y el sentido de la rotación. El plano geométrico a lo largo del cual ocurre la rotación se conoce como plano de rotación y la línea imaginaria perpendicular a este, eje de rotación.

La manera más sencilla de ejecutar la rotación de imágenes es utilizando la librería openCV. La función que realiza la rotación es `getRotationMatrix2D` y requiere de tres parámetros: el centro de rotación, el ángulo de rotación y la escala. El origen del sistema coordenado se encuentra en la esquina superior izquierda de la imagen y los valores positivos del ángulo de rotación implican giros en sentido contrario a las manecillas del reloj.

La **traslación** es un movimiento de desplazamiento. Geométricamente, es una transformación que desplaza los puntos de una figura a una cierta distancia en una dirección específica. En visión computacional, la traslación de una imagen implica desplazar la imagen una cierta cantidad de píxeles a lo largo de alguno de los ejes x , y del plano cartesiano.

Para llevar a cabo la traslación de una imagen se debe definir previamente la matriz de transformación y ejecutarla como se muestra en la figura 3. Nota que previamente se carga la imagen en la memoria, de la misma manera que el ejemplo anterior de rotación.

La transformación de **escalamiento** aumenta o disminuye la extensión espacial de la imagen. Para modificar el tamaño de la imagen se requiere escalarla a lo largo de cada uno de sus ejes (alto y ancho), según el factor de escala especificado. Si, por ejemplo, la imagen fuera escalada por un factor de 2, entonces usaría el doble de píxeles en cada dimensión para contener la información.

Considera que al modificar las dimensiones de una imagen se debe tomar en cuenta la relación de aspecto original (proporción entre el ancho y alto original). Si la imagen se reduce, será necesario volver a muestrear los píxeles. Si por el contrario, la imagen crece, será necesario reconstruir la imagen interpolando nuevos píxeles.

En la figura 4 se muestra el proceso de reducción. Nota la escala en cada imagen para que puedas comparar las dimensiones de las imágenes que se muestran. La primera es la imagen original, cuya dimensión es de 600 x 407 píxeles y la reducción es de 294 x 200 píxeles para mantener la relación de aspecto. En los dos ejemplos previos, la transformación se hizo especificando las dimensiones a las que se deseaba llevar la imagen original. Una desventaja de este método es ser susceptible a la relación de aspecto en caso de no calcular las nuevas medidas de forma adecuada.

Coordenadas homogéneas

0D
POINT
zero-dimensional



1D
LINE
one-dimensional



2D
PLANE
two-dimensional



3D
SOLID
three-dimensional



Operadores geométricos

Las primitivas geométricas constituyen los bloques de construcción básicos para describir figuras en el espacio. Por el momento, nos enfocaremos en el plano, figuras definidas en dos dimensiones.

Las coordenadas homogéneas permiten describir un punto en el espacio y convierten el punto cartesiano a una representación homogénea, utilizando tres parámetros (Juarez y Díaz, 2017). Estas coordenadas facilitan la representación de las ecuaciones utilizadas en las transformaciones geométricas, usando multiplicaciones de vectores y matrices.

Previamente se vio que para realizar la rotación de una imagen cualquiera se requiere de una matriz de rotación. La matriz de rotación es una matriz de transformación que se utiliza para realizar rotaciones en el espacio euclidiano (espacio fundamental de la geometría clásica que cumple los axiomas y postulados de Euclides, donde los puntos se representan por coordenadas). La operación de rotación se obtiene a partir de la siguiente operación matricial:

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

Donde la matriz de rotación R se define como:

$$R(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Básicamente, la matriz de rotación es una función que mapea un punto (x,y) en el espacio a otro punto(x',y') que se ha girado. La representación matemática se generaliza de la siguiente forma:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

La operación de traslación está definida por la matriz:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & T_x \\ 0 & 1 & T_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

El escalamiento de una imagen se define por:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} S_x & 0 & 0 \\ 0 & S_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$


a. Imágenes Digitales:

Una imagen digital es una representación bidimensional de un objeto o escena que se descompone en pequeños elementos llamados píxeles.



Cada píxel tiene un valor numérico que representa su color o intensidad de luz.

Las imágenes en escala de grises tienen un valor por píxel (de 0 a 255), mientras que las imágenes en color usan combinaciones de valores en los canales RGB (rojo, verde y azul).

Imagen original





30 x 30 píxeles



b. Procesamiento de Imágenes:

•El procesamiento de imágenes es el paso inicial en la visión computacional y consiste en aplicar transformaciones matemáticas (rotación, traslación y escalamiento principalmente) a las imágenes para extraer información útil.



Fuente: f7a6.gif <https://images.app.goo.gl/MAb8cYcG2d7apoVV7>

Los operadores geométricos mueven los píxeles a ubicaciones nuevas dentro de la imagen en lugar de alterar la intensidad de cada píxel.

Los operadores más comunes se definen a partir de transformaciones afines y con ellas es posible modificar las dimensiones de una imagen, girarla, desplazarla o inclinarla. Las matrices proporcionan un marco formal para trabajar con problemas geométricos en visión computacional.

Operadores lineales

Formalmente, un operador lineal se distribuye sobre una suma ponderada de imágenes, sean las imágenes f y g y los escalares a y b , el operador lineal L es:

$$L(af + bg) = aLf + bLg$$

Los operadores lineales incluyen a la convolución y correlación.

El filtrado mejora una imagen eliminando el ruido existente en ella. El **ruido** es provocado, generalmente, por una mala cámara o compresión de la imagen y da lugar a imágenes borrosas. El objetivo del filtrado es obtener imágenes más nítidas.

Los **filtros** de **suavizado** promedian los píxeles en el vecindario de un píxel y se conocen como filtros pasabajos. El **kernel** (matriz utilizada para operaciones de enfoque, realce, detección de bordes, etc.) promedia los puntos en un vecindario para obtener el suavizado.

El **desenfoque Gaussiano** se logra con la función *GaussianBlur* que convoluciona la imagen original con el kernel gaussiano especificado. Filtra el ruido, pero conserva mejor los bordes. Los parámetros del filtro son la imagen de entrada, el tamaño del kernel y las desviaciones estándares del kernel en la dirección del eje X y del eje Y (σ_X y σ_Y , respectivamente). Un valor mayor de sigma dará una imagen más borrosa. Para obtener una imagen más nítida se necesita realizar un suavizado y calcular sus derivadas.

Los bordes de una imagen se pueden identificar donde cambian de intensidad los pixeles. El gradiente de una función facilita la obtención de la razón de cambio y es posible obtener una aproximación con la convolución. Uno de los métodos para calcular el gradiente es el **detector de bordes de Sobel** que combina varias convoluciones y calcula la magnitud del resultado final.

Los **filtros de la mediana** encuentran la mediana de todos los pixeles debajo del área del kernel y el elemento central se reemplaza con este valor de mediana. Pueden utilizarse en imágenes normales para mejorar la segmentación (dividir la imagen en partes constituyentes con el fin de aislar regiones de interés).

Operadores morfológicos

Hay dos tipos de operadores morfológicos que se utilizan para eliminar ruido en imágenes: erosión y dilatación. La erosión adelgaza ciertas áreas de la imagen. La dilatación, por el contrario, expande ciertas regiones de la imagen.

Las operaciones de apertura, cierre y gradiente son variantes de los operadores morfológicos.

En la **erosión**, el grosor de los objetos en primer plano disminuye y es útil para eliminar ruido blanco.

El operador de **dilatación** tiene el efecto contrario a la erosión y aumenta el grosor de los objetos en primer plano (la región blanca)

Cuando se tiene una erosión y después una dilatación se conoce como **apertura** y se utiliza para eliminar el ruido en las imágenes. El **cierre** es una dilatación seguida de una erosión.

https://docs.opencv.org/4.5.1/d9/d61/tutorial_py_morphological_ops.html



Suavizado gaussiano

Los filtros de suavizado tienen el objetivo de eliminar detalles en la segmentación de objetos dentro de una imagen; eliminan ruido y provocan que una imagen se vea más borrosa (OpenCV, 2020).

Al observar imágenes, incluso aquellas que contienen representaciones abstractas de cosas que no se han visto antes, la atención se centra en ciertas características locales: puntos, líneas, bordes, cruces, esquinas, etc. Es posible describir una imagen como un conjunto de estos “prototipos de imagen” o elementos locales, incluso agruparlos con la finalidad de reconocerlos y utilizarlos como base del proceso de percepción.

Los parches de imagen (grupo de píxeles en la imagen) donde se encuentran estas estructuras locales pueden ser de distintos tamaños, ya que por lo regular los objetos que se encuentran más lejos de la cámara o del ojo humano se muestran con un menor tamaño en la imagen.

Suavizado gaussiano

En la fotografía de la izquierda de la figura podrás notar que las cabezas de las personas se ven mucho más pequeñas que la catarina de la fotografía de la derecha. En caso de que no se cuente con información previa de la escala de la imagen será necesario analizarla a diferentes niveles de escala. Por lo tanto, para identificar las estructuras locales de una imagen debe definirse el alcance de la palabra “local” (tamaño del vecindario) y la noción de “estructura” (elemento local a manipular).



Una aplicación utilizada para mejorar imágenes donde se selecciona la escala del vecindario local (puntos dentro de una región de la imagen) para enfocar regiones donde se pretende identificar los bordes (estructura local) es el suavizado gaussiano. Esta técnica asocia el tamaño del vecindario con el parámetro sigma. El filtro detecta los píxeles donde hay cambios de intensidad de forma brusca (bordes) y los suaviza (reduce la variación de ese cambio de intensidad).

En la figura 2, se muestra la preparación del espacio de trabajo y la carga de la imagen. En la figura 3, con el uso de la librería SciPy se aplicará el suavizado gaussiano. Los coeficientes del kernel (matriz utilizada para operaciones de enfoque, realce, detección de bordes, etc.) utilizado con este filtro siguen una distribución Gaussiana donde el valor máximo aparece sobre el píxel de referencia y va reduciéndose en función de la varianza. Las figuras 2 y 3 muestran el resultado del suavizado para diferentes escalas: 1, 3, 7 y 11. El suavizado de la imagen original utiliza una función Gaussiana que es básicamente la convolución de la imagen con esta función. El tamaño del vecindario local se determina por la escala de la función Gaussiana.




figura 2





figura 3

El filtrado gaussiano da diferentes pesos a los valores de píxeles en diferentes posiciones de la imagen. Cuanto más cercana sea la distancia, mayor será el peso de los puntos. Cuanto mayor sea la distancia, menor será el peso del punto. El valor de sigma indica el grado de dispersión de los datos. Un valor pequeño de sigma indica que la región central de la distribución Gaussiana es más concentrada por lo que el efecto de suavizado es peor. Un valor de sigma mayor mejora el suavizado de la imagen dado que la región central de la distribución Gaussiana es mayor. Este tipo de filtro le da mayor importancia a los píxeles cercanos al centro de la región de la imagen que se está manipulando.

Los resultados del suavizado gaussiano son disminución de la nitidez de la imagen, imagen más borrosa o difusa (debido que se difuminan los bordes) y pérdida gradual de detalles.

El filtrado bilateral utiliza el filtro gaussiano para remover el ruido en una imagen sin perder detalle de los bordes. En la figura 5 se muestra un ejemplo de este tipo de filtrado utilizando openCV. Nota que la imagen se difumina, pero los bordes no se pierden. No olvides consultar los parámetros en la documentación de *openCV*



Espacio de escala

El espacio de escala es un marco de referencia de la representación de una imagen (o señal) que permite la representación de múltiples escalas de forma simultánea, es decir, generar una familia de imágenes derivadas de una particular a varios niveles de escala.

El espacio de escala es útil en operaciones de procesamiento de imágenes en tareas de detección y clasificación de atributos, descriptores de movimiento, señales, entre otras. Un espacio de escala no es más que un conjunto ordenado de imágenes que se difuminan con núcleos gaussianos cada vez más grandes.

¿Qué sentido tiene la representación de una imagen en el espacio de escalas cuando la imagen en si tiene toda la información de esta? Primero, eliminar los detalles que pueden ser innecesarios en ciertas tareas de procesamiento, segundo, ser utilizado como un elemento de preprocesamiento en algoritmos de tratamiento de imágenes, como la eliminación de ruido, por ejemplo.

Al construir una representación en el espacio de escalas, es importante hacerlo a partir de una escala fina hacia una mayor con la finalidad de simplificar los detalles de las imágenes. Los espacios de escala se pueden utilizar en tareas de segmentación de imagen, suavizamiento de imagen, suavizamiento manteniendo bordes de imágenes, borrado de detalles en imágenes y detección de esquinas.

Detección del punto de interés

En procesamiento de imágenes, un atributo o característica de imagen es un fragmento de información sobre el contenido de esta. Por lo general esta información es sobre si una determinada región de la imagen contiene ciertas propiedades. Los atributos o características pueden ser estructuras específicas como puntos, bordes, esquinas u objetos en particular, así como también pueden ser el resultado de una operación hecha sobre una vecindad de puntos.

La transformación de características invariantes de escala (SIFT) es un algoritmo de detección en visión computacional. Permite identificar características locales dentro de una imagen conocidas como puntos de interés. Los puntos de interés son invariantes a la escala y rotación. La principal ventaja de esta transformación es que las características obtenidas no se ven afectadas por el tamaño de la imagen o su orientación, lo que significa que independientemente de si la imagen es girada o modificada en escala, se encontrarán los mismos puntos de interés.



De la figura 1 se puede esperar que los puntos de interés de la imagen de la izquierda correspondan con los puntos de interés de la imagen de la derecha. Si se comparara con una tercera imagen con una rotación diferente o escala mayor o menor, estos puntos deberían coincidir también en ella.

El proceso para la identificación de estos puntos de interés se divide en cuatro etapas (Lowe, 2004):

1.Construcción del espacio de escala. Se identifican la ubicación y escalas de las características que se pueden reconocer de forma repetida desde diferentes perspectivas en el mismo objeto o escena. Se asegura que las características sean independientes a la escala.

2.Localización de puntos interés. Ajusta un modelo para determinar la ubicación y escalas de las características seleccionando puntos clave en función de una medida de estabilidad.

3.Asignación de la orientación. Se asegura de que los puntos de interés sean invariantes a la rotación. Se calculan las mejores orientaciones para cada región que contiene puntos de interés.

4.Descriptor del punto de interés. Asigna una “huella digital” única a cada punto de interés. Se utilizan degradados de imagen en la escala y rotación seleccionada para describir cada región que contiene puntos de interés.

El resultado del proceso anterior permite realizar la identificación de los puntos de interés en distintas perspectivas o escalas de una misma imagen.

La **construcción del espacio de escala** se hace a partir de la identificación de las características potenciales dentro de una imagen sin tener en cuenta el ruido, es importante asegurarse que tales puntos de interés no dependan de la escala.

Se utiliza el desenfoque Gaussiano para eliminar el ruido en la imagen. Por cada píxel en la imagen, el filtro Gaussiano calcula un valor según su vecindario. Este filtro elimina texturas y detalles mínimos manteniendo la forma y los bordes de la imagen.

Después de aplicar el filtrado, es necesario asegurarse que las características identificadas no dependan de la escala. Para ello se requiere crear un espacio de escalas a partir de la imagen original, reduciendo la escala a la mitad y generando nuevas imágenes “borrosas” o difuminadas a distintas escalas. La cantidad de imágenes a escalas diferentes con sus imágenes difuminadas asociadas se realizan a partir de octavas y deben ser cuatro, por cada octava se recomienda obtener un conjunto de cinco imágenes borrosas o difuminadas con una desviación estándar σ inicial de 1.6 (Lowe, 2004).

Una vez que se han obtenido las imágenes a escalas múltiples (distintos valores de σ) y aplicado desenfoque Gaussiano con el objetivo de reducir el ruido en la imagen, se utiliza la diferencia de Gauss (**DoG**) para mejorar la identificación de características.

DoG es un algoritmo de mejora de características en las imágenes que implica la sustracción de una versión borrosa o difuminada de una imagen original de otra versión menos borrosa de la misma imagen. Se crea un nuevo conjunto de imágenes por cada octava restando cada imagen de la previa en la misma escala como se muestra en la figura 2. Este nuevo conjunto de imágenes se utiliza para la identificación de los puntos de interés relevantes.




Figura 2. Conjunto de imágenes generadas a partir de la Diferencia de Gauss. Se utilizan imágenes con σ distintos.
Fuente: Lowe, D. (2004). Distinctive Image Features from Scale-Invariant Keypoints. *International Journal of Computer Vision*, 60(2).

Con los resultados anteriores, el paso siguiente es **localizar los puntos de interés** relevantes en la imagen que puedan ser utilizados para hacer coincidir características similares. La idea es encontrar máximos y mínimos locales dentro de la imagen.

Para determinar los máximos y mínimos locales, se recorre cada píxel en la imagen y se compara con los píxeles vecinos. El vecindario utilizado no solo abarca aquellos píxeles que rodean al analizado sino, además, los 9 píxeles de las imágenes previa y siguiente en la octava dando un total de 26 píxeles con los que se compara el píxel original con la finalidad de encontrar un mínimo y un máximo local.

En la figura 3, se muestran tres imágenes de la primera octava. El píxel marcado con “X” se compara con sus vecinos y se selecciona como un punto de interés potencial si es el mayor o el menor con respecto a sus vecinos. Con lo anterior, se asegura que los puntos de interés son invariantes a la escala.




Figura 3. Conjunto de imágenes generadas a partir de la Diferencia de Gauss. Se utilizan imágenes con σ distintos.
Fuente: Lowe, D. (2004). Distinctive Image Features from Scale-Invariant Keypoints. *International Journal of Computer Vision*, 60(2).

La selección final de los puntos de interés se obtiene eliminando del conjunto anterior aquellos que tienen bajo contraste. Para tal fin, se utiliza una expansión en series de Taylor del espacio de escalas para obtener una ubicación más precisa de los extremos, si la intensidad en estos extremos es menor que un valor de umbral de 0.03, se rechaza el punto (Lowe, 2004). Por último, se identifican los puntos cercanos a los bordes utilizando una matriz Hessiana de segundo orden. De igual manera, estos puntos de interés son eliminados dando lugar al conjunto de puntos de interés definitivo.

Utilizando el conjunto de puntos de interés definitivo, se asigna una orientación a cada punto con el fin de hacerlo invariante a la rotación. El proceso de **asignación de la orientación** se divide en dos etapas: el cálculo de la magnitud y la orientación, y la creación de un histograma para la magnitud y orientación. A partir de un vecindario alrededor del punto de interés a una escala específica, se calcula la magnitud de la gradiente (intensidad del píxel) y su dirección (orientación del píxel) en esa región. El histograma de orientación se construye con 36 barras cuyos ángulos de cobertura van de 10° en 10° cubriendo 360° y permite identificar cuántos píxeles tienen un cierto ángulo.

Descriptor de imagen

El último paso en el algoritmo SIFT es obtener el descriptor del punto de interés. Hasta ahora, se tienen puntos de interés estables que son invariantes en la escala y en la rotación. Se utilizan los píxeles vecinos, sus orientaciones y magnitud, para generar una huella digital única para cada punto de interés llamado "descriptor". Se considera un vecindario de 16x16 píxeles alrededor del punto de interés que se subdivide en 16 subbloques de 4x4 píxeles. Se calcula un histograma de 8 barras utilizando magnitud y orientación para cada subbloque, obteniendo un total de 128 barras disponibles que se representan como un vector para formar el descriptor de puntos de interés en la imagen.

En la figura 4, se muestra la obtención de los puntos de interés y descriptores utilizando openCV en Python. Nota los círculos que indican cada punto de interés identificado con la función *sift.detect()*. Cada círculo se muestra con la función *drawKeyPoints()* y cuando se indica el parámetro *flags=cv.DRAW_MATCHES_FLAGS_DRAW_RICH_KEYPOINTS* se muestra la orientación de cada punto.



En la figura 5, se muestra la carga de dos imágenes sobre el mismo objeto en diferente perspectiva y escala. Utilizando SIFT, se obtendrán las coincidencias de características entre ellas, según el procedimiento mostrado en la figura 6.



Se obtienen los puntos de interés y los descriptores para después establecer el mapeo entre ellos. Nota las líneas que indican la coincidencia entre los puntos de interés obtenidos en ambas imágenes. En el ejemplo se muestran las primeras 50 coincidencias de las 307 posibles para este caso.

Importancia

Este campo no solo permite avances tecnológicos impresionantes, sino que también está transformando industrias, desde la salud hasta el retail, y nos ayuda a resolver problemas de manera más eficiente y precisa.


La visión computacional es esencial porque facilita que las máquinas realicen tareas que, para los humanos, son intuitivas.

A medida que mejoran los algoritmos y el hardware, las aplicaciones seguirán expandiéndose, haciendo que la visión computacional sea un componente clave de las tecnologías del futuro.



Automóviles autónomos

Los autos sin conductor utilizan visión computacional para 'ver' y analizar el entorno, identificar obstáculos, señales de tránsito y peatones, permitiendo que el vehículo tome decisiones en tiempo real.




Reconocimiento facial

Este sistema, ya muy común en dispositivos móviles, permite desbloquear teléfonos o verificar identidades de manera rápida y segura. Empresas y gobiernos lo usan en seguridad, vigilancia y autenticación.



Diagnóstico médico

En la medicina, los algoritmos de visión computacional ayudan a los médicos a detectar enfermedades como cáncer, analizar imágenes de resonancias magnéticas y realizar diagnósticos más precisos basados en imágenes médicas.




Comercio y entretenimiento

En plataformas de comercio electrónico, la visión computacional permite a los usuarios realizar búsquedas por imagen, recomendando productos visualmente similares. En el entretenimiento, mejora experiencias en videojuegos, realidad aumentada y reconocimiento de gestos.

Avances recientes con Deep Learning


AlexNet



Fuente: AlexNet: A Revolutionary Deep Learning Architecture - viso.ai
<https://images.app.goo.gl/2Etw6r99TRgEy7zG9>


Redes Convolucionales

Arquitectura de Redes Neuronales Convolucionales – CNN




Fuente: Desarrolla una red neuronal convolucional en Keras con Python <https://images.app.goo.gl/fNbSrVGjTqnDa7x7>

Transferencia de Aprendizaje



Fuente: Viewnext - El transfer learning y las redes convolucionales
<https://images.app.goo.gl/dqLVCgHVpmVcb8CVA>

Detección de objetos en tiempo real




Fuente: SSD: Single Shot MultiBox Detector (How it works)
<https://images.app.goo.gl/L5rgRXbZTS9tgkvi8>

Impacto de la Computación de Alto Rendimiento

Los avances en hardware, como el uso de **GPUs** (unidades de procesamiento gráfico) para entrenar redes neuronales profundas, han permitido que los sistemas de visión computacional procesen grandes cantidades de datos en tiempos razonables. Esto ha sido crucial para el rápido desarrollo de aplicaciones prácticas.

CPU



VS

GPU




c. Algoritmos Básicos:


•Detección de bordes:

Es uno de los primeros pasos en muchos sistemas de visión computacional. La detección de bordes implica identificar cambios bruscos en la intensidad de la imagen, lo que a menudo marca los límites entre diferentes objetos o regiones.

- **Algoritmo de Canny:** Funciona en varias etapas:
 - ❖ suaviza la imagen para eliminar el ruido
 - ❖ Calcula gradientes (para detectar cambios de intensidad)
 - ❖ Identifica los puntos donde los cambios son más pronunciados, marcando así los bordes.



Fuentes: Lo Que Necesitas Saber Sobre la Detección de Bordes - DataSmarts <https://images.app.goo.gl/7XuQVqjn59je7MBB6>




Fuente: CONTANDO OBJETOS (Aplicando detección de bordes con CANNY) en Python-OpenCV » omes-va.com
<https://images.app.goo.gl/3F7ZUbMXPdWBGZsD9>

c. Algoritmos Básicos:


Segmentación de imágenes:

La segmentación divide una imagen en diferentes regiones u objetos basados en características compartidas como el color, la textura o la intensidad. Es crucial para identificar qué parte de la imagen corresponde a qué objeto.

•**K-means clustering:** Este algoritmo agrupa los píxeles de la imagen en "clusters" o grupos según su similitud, lo que ayuda a segmentar objetos.




Fuente: Servicios y soluciones de visión por computadora | Shaip <https://images.app.goo.gl/8t55Tsv9rjXB7gon7>



Fuente: Deep Learning en Visión Artificial - Blog CARTIF <https://images.app.goo.gl/JWDfV7REk6MhNFKQ8>

Computer Vision Tasks





Fuente: Qué es la visión por computadora: Descripción general, aplicaciones, beneficios y cómo aprenderla - Brita Inteligencia Artificial <https://images.app.goo.gl/KHYyXbhd78m9WGjL8>

2. Visualización de procesos

2.1 Imagen original vs. imagen procesada:

Ejemplo gráfico: Una imagen de un autobús en avenida. Primero, se muestra la imagen original; luego, después de aplicar la detección de bordes, los contornos del autobús y otros objetos como los autos o edificios se hacen visibles. Finalmente, en la segmentación, el autobús y los otros objetos se diferencian en colores distintos.




2. Visualización de procesos

2.2 Segmentación con K-means:

- Muestra cómo los colores de una imagen se agrupan en regiones. Como es de esperar, el nivel de detalle aumenta en proporción al número de *clusters*.

Imagen original



K-means de 3 clusters o grupos



K-means de 6 clusters o grupos




3. Otros algoritmos básicos

Transformada de Hough: Se utiliza para la detección de formas geométricas, como líneas o círculos, dentro de las imágenes. Es especialmente útil en aplicaciones como la detección de carriles en vehículos autónomos.



Fuente: Hough Transform - Basic Shape Detection - FIVEKO
<https://images.app.goo.gl/Qqndx8MfSSnZPuy6>




Fuente: Hough Transform using OpenCV | LearnOpenCV
<https://images.app.goo.gl/BEr5Sxn5TZTcyQJu6>

3. Otros algoritmos básicos

Filtros de convolución (usados en CNNs)

Un filtro de convolución es una pequeña matriz de números que se mueve sobre la imagen, aplicando operaciones para detectar patrones como bordes, texturas o características más complejas.




Fuente: Redes Neuronales Convolucionales <https://images.app.goo.gl/joycEqTxjZ6yicvr5>

Aplicaciones prácticas de la Visión Computacional


1. Ejemplos de Aplicaciones

a. Redes Sociales:

•**Reconocimiento facial:** Una de las aplicaciones más conocidas de la visión computacional es en el reconocimiento facial, utilizado por plataformas como Facebook e Instagram para etiquetar automáticamente a personas en fotos. También se emplea para desbloquear dispositivos móviles (como Face ID en iPhones) y autenticar usuarios de manera segura.



Fuente: face-api.js — JavaScript API for Face Recognition in the Browser with tensorflow.js | by Vincent Mühler | ITNEXT <https://images.app.goo.gl/HiA1521ay1b9fwFv8>




Fuente: Facebook Messenger ahora incluirá reconocimiento facial en su app <https://images.app.goo.gl/7PkJpCPZZvd72ZSP7>

1. Ejemplos de Aplicaciones

b. Medicina:

- **Diagnóstico asistido por IA:** La visión computacional ha revolucionado la medicina mediante el análisis automatizado de imágenes médicas. Herramientas como las que se usan para analizar radiografías, tomografías computarizadas o resonancias magnéticas pueden detectar anomalías, como tumores o fracturas, con alta precisión. Estas herramientas ayudan a los médicos a diagnosticar enfermedades como el cáncer en etapas tempranas.



Fuente: <https://blog.google/technology/health/ai-model-cough-disease-detection/>

1. Ejemplos de Aplicaciones

d. Industria y manufactura:

• **Inspección automatizada de calidad:** En el sector industrial, la visión computacional se utiliza para inspeccionar productos y asegurarse de que cumplan con los estándares de calidad. En fábricas de automóviles, por ejemplo, cámaras inteligentes pueden detectar defectos en piezas, como arañazos o fallas en el ensamblaje, en tiempo real.



Fuente: Las 10 mejores aplicaciones de visión artificial en la industria <https://images.app.goo.gl/AMf6th4pHiCRVJ9q8>

1. Ejemplos de Aplicaciones

e. Agricultura de precisión:


• **Monitoreo de cultivos:** La visión computacional, a menudo combinada con drones, se utiliza en la agricultura para monitorear el estado de los cultivos, detectar plagas y enfermedades o medir el crecimiento de las plantas. Estas herramientas permiten a los agricultores tomar decisiones informadas sobre el riego y el uso de fertilizantes.



Fuente: Principales diapositivas sobre IoT en la agricultura: PPT y PDF gratuitos <https://images.app.goo.gl/6wi5hTm7fzDWFGwr9>



Fuente: Cómo medir resultados con drones. | by Ingrid Palencia | Medium <https://images.app.goo.gl/aKzA6KEuKPDjxHLd7>



Fuente: Visión Artificial detección de Plantas y Malezas G&D Agricultura de Precisión <https://images.app.goo.gl/vF1TyLoHJC4K8jix8>

1. Ejemplos de Aplicaciones


Midjourney, Stable Diffusion o DALL-E



Fuente: Stable Diffusion vs Midjourney vs Dall-E 2 | Comparison Test <https://images.app.goo.gl/46LdbUHC9X6mw21BA>

2. Reflexiones de uso

¿Pueden pensar en otros ejemplos donde esta tecnología se aplique en su vida diaria?



Fuente: Cómo crear una casa inteligente? - Uxban
<https://images.app.goo.gl/toEc6orUK1tzx8B29>



Fuente: Cinco recursos digitales de realidad aumentada - Magisnet
<https://images.app.goo.gl/7DnqUQGgDsY8JKb5A>



Fuente: Qué es la realidad aumentada y 20 ejemplos de uso exitoso en empresas <https://images.app.goo.gl/263kWR6vbbBaRE9x9>

2. Reflexiones de uso

¿Qué creen que será lo próximo en el campo de la visión computacional?

¿Cómo podría mejorar o cambiar las industrias que conocen?



Fuente: Internet de las Cosas (IoT) en Gestión de Inventario de Activos - CPCON 2024 <https://images.app.goo.gl/ZkQehuct513Sbfs47>



Fuente: Los beneficios de IoT: Ejemplos del mundo real | Digi International <https://images.app.goo.gl/C3SCzH23pxBXi2qPA>




Fuente: Visión Artificial: La Tecnología que Cambia el Mundo <https://images.app.goo.gl/vrQ9G1NndfkW5X5i7>

Desafíos y Ética en Visión computacional

Problemas Actuales y Desafíos

a. Limitaciones técnicas:

- **Calidad de las imágenes:** Los sistemas de visión computacional dependen de la calidad de las imágenes que procesan. Factores como la iluminación, el ángulo de captura o la resolución de la cámara pueden afectar la precisión de los algoritmos. En situaciones de baja iluminación o con objetos parcialmente visibles, los resultados pueden no ser confiables.



Problemas Actuales y Desafíos

b. Generalización de los modelos:

- Los modelos de visión computacional suelen entrenarse con conjuntos de datos específicos, lo que significa que pueden tener dificultades para generalizar a nuevas situaciones. Un sistema entrenado para identificar objetos en una ciudad puede no funcionar bien en áreas rurales o en otros entornos no incluidos en su entrenamiento.



Fuente: Los coches autónomos reducirían un 90% las muertes en carretera <https://images.app.goo.gl/EJEQCui7rB37Z5ec8>


1. Problemas Actuales y Desafíos

c. Costos computacionales:


- El procesamiento de imágenes, especialmente en alta resolución o en tiempo real (como en los coches autónomos), requiere una gran cantidad de potencia computacional. Esto hace que algunos sistemas sean costosos de implementar y mantener, especialmente cuando se requiere alta precisión.



Fuente: Procesamiento GIF - Conseguir el mejor gif en GIFER
<https://images.app.goo.gl/8wkXy327DeQi95bD6>



Fuente: Cómo crear Red Convolutiva en Keras - Ander Fernández
<https://images.app.goo.gl/JEZKDWn2UjWyx9j7>



Fuente: Unit cpu GIF en GIFER - de Nuath <https://images.app.goo.gl/2jZ7o6krZRhvkEsu6>

2. Ética en la Visión Computacional

a. Privacidad:

•**Reconocimiento facial y vigilancia:** Una de las preocupaciones más importantes es el uso de la visión computacional para la vigilancia masiva, especialmente a través del reconocimiento facial. Empresas y gobiernos han implementado tecnologías que pueden seguir a las personas en espacios públicos sin su consentimiento, lo que genera preocupaciones sobre la privacidad.



Fuente: Sistemas de reconocimiento facial: así se extiende el uso de esta controvertida tecnología
<https://images.app.goo.gl/JU68t7cDwUbAq7sX6>


2. Ética en la Visión Computacional

b. Sesgo en los algoritmos:

• **Discriminación algorítmica:** Muchos algoritmos de visión computacional están entrenados en conjuntos de datos que pueden ser sesgados. Si los datos de entrenamiento no son representativos de la diversidad de la población (por ejemplo, imágenes de personas de diferentes etnias), los resultados pueden ser inexactos o incluso perjudiciales. Esto puede llevar a errores en el reconocimiento de personas de ciertas razas o géneros, lo que se conoce como "sesgo algorítmico."



Fuente: Tu cara es tu boleto: una comodidad espeluznante - La Tercera
<https://images.app.goo.gl/7ktmUXu4Dzh77qo28>




Fuente: Comprender el Sesgo y la Equidad en los Sistemas de IA
<https://images.app.goo.gl/kDgQm7fAm9ftczoq6>

2. Ética en la Visión Computacional

c. Uso indebido de la tecnología:

- Las herramientas de visión computacional también pueden ser mal utilizadas, como en el caso de la manipulación de imágenes para difundir desinformación o la creación de videos falsos conocidos como "deepfakes".

Estos videos pueden ser empleados para dañar la reputación de una persona o difundir información falsa.



Fuente: Deepfakes: cómo los medios combaten la desinformación más sofisticada — Revista de Innovación en Periodismo
<https://images.app.goo.gl/A4CM6tisN5UTWwzS8>

Inteligencia Artificial

Fundamentos de IA multimodal

Dra. Jessica Sarahi Méndez Rincón


1. Definición de IA multimodal y su importancia

La IA multimodal integra y procesa simultáneamente múltiples tipos de datos o modalidades, como texto, imagen, audio y video, para obtener una comprensión más rica y completa.

- Permite que los modelos aprendan relaciones cruzadas y contextos que no se capturan usando una sola modalidad.

Su importancia crece con la disponibilidad masiva de datos heterogéneos y la necesidad de aplicaciones que entiendan entornos complejos

Multimodal Generative AI



. Modalidades comunes en IA multimodal

- Texto: lenguaje natural, etiquetas, descripciones.
- Imagen: fotografías, diagramas, contenido visual.
- Audio: voz, música, sonidos ambientales.
- Video: secuencias temporales que combinan imagen y audio, esenciales en vigilancia, entretenimiento o interacción.

Cada modalidad aporta información diferente y complementaria


Casos de uso reales

- Salud: diagnóstico asistido combinando imágenes médicas (radiografías) con reportes textuales y datos del paciente.
- Educación: plataformas que utilizan video, texto y audio para personalizar el aprendizaje y evaluación.
- E-commerce: búsqueda visual y textual integradas para mejorar la experiencia de compra, recomendaciones y atención al cliente.

Arquitecturas básicas de modelos multimodales


- Modelos que procesan modalidades por separado y luego fusionan las representaciones en etapas:
 - Early fusion:** combina datos de todas las modalidades al inicio para un procesamiento conjunto.
 - Late fusion:** procesa cada modalidad por separado y combina las salidas al final.
 - Hybrid fusion:** combinación intermedia de los anteriores, integrando representaciones en varios puntos.

Redes basadas en Transformers se adecuan bien para integrar información diversa, además de arquitecturas específicas combinando CNNs y RNNs



Técnicas de fusión de datos multimodales

- Early Fusion:
 - Combina las características de diferentes modalidades (texto e imagen) en las primeras capas del modelo.
 - Permite interacción temprana entre modalidades, pero puede ser complejo por diferencias en escala y formato.
- Late Fusion:
 - Procesa cada modalidad de forma independiente y combina los resultados (por ejemplo, scores o embeddings) al final.
 - Más simple y modular, pero puede no capturar interacciones profundas entre modalidades.
- Hybrid Fusion:
 - Combina ambos enfoques, integrando representaciones en varios puntos de la arquitectura para balancear complejidad y riqueza semántica.




Codificación conjunta de embeddings visuales y textuales

- El objetivo es representar texto e imagen en un espacio latente compartido, permitiendo comparaciones semánticas.
- Se usan modelos por separado para cada modalidad: CNNs o Vision Transformers para imágenes, Transformers para texto.
- Embeddings visuales y textuales se alinean mediante entrenamiento conjunto usando pérdidas contrastivas o multitarea.

Modelos de referencia multimodales

- ViLBERT:
 - Extiende BERT para manejar texto e imágenes simultáneamente con dos flujos que interactúan mediante bloques de atención cruzada.
 - Aprende representaciones conjuntas para tareas como VQA y recuperación imagen-texto.



Codificación conjunta de embeddings visuales y textuales

- El objetivo es representar texto e imagen en un espacio latente compartido, permitiendo comparaciones semánticas.
- Se usan modelos por separado para cada modalidad: CNNs o Vision Transformers para imágenes, Transformers para texto.
- Embeddings visuales y textuales se alinean mediante entrenamiento conjunto usando pérdidas contrastivas o multitarea.


Modelos de referencia multimodales

- ViLBERT:
 - Extiende BERT para manejar texto e imágenes simultáneamente con dos flujos que interactúan mediante bloques de atención cruzada.
 - Aprende representaciones conjuntas para tareas como VQA y recuperación imagen-texto.
- LXMERT:
 - Similar a ViLBERT, pero con un diseño modular que integra codificadores para texto, imagen y relaciones espaciales.
 - Optimizado para tareas de comprensión multimodal.

Modelos preentrenados multimodales

1. CLIP (Contrastive Language–Image Pretraining)


- Desarrollado por OpenAI, CLIP aprende a relacionar texto e imágenes mediante aprendizaje contrastivo.
- Utiliza grandes cantidades de pares imagen-texto para entrenar dos codificadores independientes (una red para imágenes y otra para texto) que proyectan ambas modalidades en un espacio latente compartido.
- Capaz de realizar tareas zero-shot (sin ajuste específico) como clasificación, búsqueda de imágenes y generación de descripciones.



<https://arxiv.org/pdf/2410.02746>


2. BLIP (Bootstrapping Language-Image Pretraining)

- Modelo más reciente que combina aprendizaje contrastivo con generación de lenguaje para fortalecer la alineación multimodal.
- Integra tareas de preentrenamiento generativo y discriminativo, mejorando la calidad de generación de leyendas y comprensión conjunta.
- Ofrece mejor rendimiento en tareas como Visual Question Answering (VQA) y generación de texto a partir de imágenes.



3. Flamingo de DeepMind y otras arquitecturas emergentes

- Flamingo introduce un enfoque para aprendizaje multimodal que maneja secuencias arbitrarias de imágenes y texto.
- Se distingue por su capacidad para realizar multitarea y few-shot learning multimodal, adaptándose a nuevas tareas con poca información.
- Otras arquitecturas incluyen modelos multimodales escalables que integran mejor audio, video y texto, potenciando aplicaciones en interacción avanzada.



Aplicaciones prácticas: matching imagen-texto y búsqueda semántica

- Matching imagen-texto: encontrar la imagen más relevante dado un texto y viceversa, usado en buscadores visuales, etiquetado automático y sistemas de recomendación.
- Búsqueda semántica: mejora la recuperación de información permitiendo consultas más naturales y contextuales combinando texto e imágenes.
- Utilización en comercio electrónico, gestión de activos digitales, sistemas de asistencia y accesibilidad.

Generación de imágenes a partir de texto

1. Introducción a modelos generativos: DALL·E, Midjourney, Stable Diffusion

- DALL·E (OpenAI): modelo generativo basado en Transformer que crea imágenes originales a partir de descripciones textuales. Combina comprensión de lenguaje natural y generación visual.
- Midjourney: plataforma independiente que utiliza IA para crear arte digital a partir de prompts textuales, popular en creatividad y diseño.
- Stable Diffusion: modelo de difusión que genera imágenes detalladas a partir de texto, diseñado para ser eficiente y abierto al público.

Estos modelos impulsan la creatividad asistida por IA y abren nuevas posibilidades en diseño gráfico, publicidad y entretenimiento.

2. Prompt engineering para control de resultados

- El prompt engineering consiste en diseñar cuidadosamente las entradas textuales para guiar la generación hacia resultados deseados.
- Técnicas incluyen: uso de palabras clave específicas, descripciones detalladas, estilo artístico, composición, colores y emociones.
- Es fundamental para mejorar calidad, coherencia y evitar resultados ambiguos o irrelevantes.

3. Ejemplos prácticos con generación controlada

- Uso de interfaces (APIs, plataformas web) para probar variaciones en prompts y observar efectos.
- Ajuste de parámetros como ruido inicial, pasos de difusión o escala de guía para controlar la diversidad y fidelidad.

Generación de texto a partir de imágenes

1. Descripción automática de imágenes (Image Captioning)

- Tecnología que genera descripciones en lenguaje natural a partir de imágenes, facilitando accesibilidad, organización y búsqueda.
- Combina visión computacional para extraer características visuales y modelos de lenguaje para producción textual coherente.
- Aplicaciones en asistentes para personas con discapacidad visual, indexación multimedia y robótica.

2. Modelos principales: Show and Tell y transformers visuales

- Show and Tell: modelo clásico que usa una CNN para extraer características de imagen y un LSTM para generar texto palabra por palabra. Fue pionero en Image Captioning.
- Transformers visuales: modelos como ViT + Transformer decoder o modelos multimodales que usan mecanismos de atención para relacionar regiones visuales y palabras, mejorando calidad y precisión.
- Modelos preentrenados como Oscar, VinVL o versiones adaptadas de BERT para imágenes y texto son ejemplos actuales.

3. Tareas de Visual Question Answering (VQA)

- VQA es una tarea multimodal donde el modelo recibe una imagen y una pregunta en lenguaje natural, y debe generar una respuesta relevante.
- Combina comprensión visual y procesamiento de lenguaje para interacción avanzada.
- Ejemplos incluyen preguntas sobre objetos presentes, acciones, contexto o detalles específicos

Evaluación y explicabilidad de modelos multimodales

1. Desafíos de evaluación en tareas multimodales

- Los modelos multimodales combinan modalidades heterogéneas (texto, imagen, audio), lo que dificulta evaluar su desempeño de forma integral.
- Métricas deben capturar tanto la precisión individual en cada modalidad como la coherencia conjunta.
- Existen problemas como ambigüedad semántica, subjetividad en anotaciones y falta de datasets balanceados para evaluación exhaustiva.
- Algunos benchmarks integran múltiples tareas (captioning, clasificación, VQA) para medir desempeño global.

2. Métodos de interpretabilidad para modelos texto-imagen

- Métodos basados en saliencia que asignan importancia a tokens o píxeles.
- Explicaciones locales (LIME, SHAP) para ofrecer interpretaciones específicas a predicciones individuales.
- Modelos desmontables que facilitan comprensión mediante módulos independientes para cada modalidad.
- Uso de ejemplos contrafactuales para discernir comportamiento del modelo ante cambios de entrada.

3. Consideraciones éticas y de sesgo en IA multimodal

- Los modelos pueden amplificar sesgos presentes en datos textuales o visuales, afectando a grupos minoritarios o situaciones sensibles.
- Falta de transparencia y explicabilidad dificulta detectar y mitigar estos sesgos.
- Es esencial incorporar gobernanza responsable, auditorías y protocolos de control de calidad en proyectos multimodales.
- Además, proteger la privacidad y asegurar consentimiento en conjuntos de datos multimodales es crítico.

Algoritmos de Visión Computacional

Sobel

Concepto y Características Matemáticas

El operador de Sobel es un filtro de detección de bordes que utiliza una aproximación discreta del gradiente de la intensidad de una imagen. Se basa en la convolución de la imagen con dos kernels (máscaras) de 3x3 que calculan las derivadas parciales en las direcciones horizontal (G_x) y vertical (G_y).

Kernels:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

Magnitud del Gradiente (G): $G = \sqrt{G_x^2 + G_y^2}$

Dirección del Gradiente (θ): $\theta = \arctan\left(\frac{G_y}{G_x}\right)$

Sobel

Algoritmo (en lenguaje natural)

- 1.Carga:** Leer la imagen en escala de grises.
- 2.Preparación:** Añadir un marco (padding) a la imagen para manejar los bordes durante la convolución.
- 3.Convolución:** Deslizar las máscaras G_x y G_y sobre cada píxel.
- 4.Cálculo:** Calcular el gradiente resultante combinando ambos resultados (magnitud).
- 5.Normalización:** Asegurar que los valores de intensidad estén en el rango $[0, 255]$.
- 6.Salida:** Generar la imagen resultante con los bordes resaltados

Sobel

Algoritmo Formal

Entrada: Imagen I de dimensiones $M \times N$.

Salida: Imagen E (bordes).

1. Para cada píxel (i, j) en I :
2. Calcular $G_x(i, j) = \sum_{a=-1}^1 \sum_{b=-1}^1 I(i+a, j+b) \cdot G_x(a+1, b+1)$
3. Calcular $G_y(i, j) = \sum_{a=-1}^1 \sum_{b=-1}^1 I(i+a, j+b) \cdot G_y(a+1, b+1)$
4. $E(i, j) = \sqrt{G_x(i, j)^2 + G_y(i, j)^2}$
5. Si $E(i, j) > \text{umbral}$, marcar como borde.
6. Métricas de Complejidad

Métricas de Complejidad

- **Complejidad Temporal:** $O(M \times N)$, donde M y N son las dimensiones de la imagen. Por cada píxel, realizamos un número constante de operaciones (9 multiplicaciones y sumas por kernel).
- **Complejidad Espacial:** $O(M \times N)$ para almacenar las derivadas parciales y la imagen resultante.

Sobel

Pseudocódigo:

Función Sobel(imagen):

 filas, cols = dimensiones(imagen)

 resultado = matriz(filas, cols)

 Para i de 1 a filas-2:

 Para j de 1 a cols-2:

 gx = convolucion(imagen, i, j, kernel_x)

 gy = convolucion(imagen, i, j, kernel_y)

 resultado[i, j] = raiz_cuadrada(gx² + gy²)

Retornar normalizar(resultado)

Sobel

40_UNAM_AI_Actividad_Laboratorio_5_11_algoritmos_clase.ipynb ☆

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Comandos + Código + Texto ▶ Ejecutar todo ▼

▼ Sobel

```
[1]
✓ 0 s

1 import numpy as np
2
3 def sobel_filter(image):
4     # Kernels de Sobel
5     Gx = np.array([[ -1,  0,  1], [ -2,  0,  2], [ -1,  0,  1]])
6     Gy = np.array([[ 1,  2,  1], [ 0,  0,  0], [ -1, -2, -1]])
7
8     rows, cols = image.shape
9     output = np.zeros((rows, cols))
10
11     # Aplicar padding simple para evitar errores en bordes
12     padded_img = np.pad(image, (1, 1), mode='constant')
13
14     for i in range(rows):
15         for j in range(cols):
16             region = padded_img[i:i+3, j:j+3]
17             gx = np.sum(region * Gx)
18             gy = np.sum(region * Gy)
19             output[i, j] = np.sqrt(gx**2 + gy**2)
20
21     # Normalización a 0-255
22     output = (output / output.max()) * 255
23     return output.astype(np.uint8)
```

40_UNAM_AI_Actividad_Laboratorio_5_11_algoritmos_clase.ipynb ☆ ☁

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Comandos + Código + Texto ▶ Ejecutar todo ▼

```
[2]
✓ 5 s

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from skimage import data, color
4
5 # 1. Cargar una imagen de muestra (ej. astronauta) y convertir a gris
6 image = color.rgb2gray(data.astronaut())
7
8 # 2. Aplicar la función sobel_filter que definimos anteriormente
9 # (Asegúrate de que la función sobel_filter esté definida en el mismo script)
10 bordes = sobel_filter(image)
11
12 # 3. Visualización comparativa
13 plt.figure(figsize=(10, 5))
14
15 plt.subplot(1, 2, 1)
16 plt.title("Imagen Original")
17 plt.imshow(image, cmap='gray')
18 plt.axis('off')
19
20 plt.subplot(1, 2, 2)
21 plt.title("Resultado: Operador de Sobel")
22 plt.imshow(bordes, cmap='gray')
23 plt.axis('off')
24
25 plt.tight_layout()
26 plt.show()
```



SIFT (Scale-Invariant Feature Transform).

Este es un algoritmo significativamente más complejo que Sobel; mientras Sobel es un operador local, SIFT es un descriptor de características diseñado para ser invariante a la escala, rotación y parcialmente a cambios en la iluminación.

Debido a su naturaleza robusta, SIFT no es una única convolución, sino un proceso de varias etapas.

Características Matemáticas y Conceptuales

SIFT opera sobre la premisa de extraer puntos clave (keypoints) que se mantienen estables bajo diferentes transformaciones.

- **Espacio de Escala:** Se utiliza el **Diferencial de Gaussianas (DoG)** para detectar puntos de interés en diferentes escalas, aproximando el Laplaciano de Gaussiano (LoG).

$$DoG(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

- **Orientación:** Se asigna una orientación dominante a cada punto clave basándose en los gradientes locales, logrando **invariancia a la rotación**.

- **Descriptor:** Se crea un vector de 128 dimensiones que describe la región alrededor del punto clave, garantizando **invariancia a la escala y robustez a cambios de iluminación**.

SIFT (Scale-Invariant Feature Transform).

Algoritmo (en lenguaje natural)

- 1.Detección de Extremos en Escala:** Construir una pirámide de imágenes desenfocadas (Gaussianas) y restar niveles adyacentes para hallar el DoG. Identificar máximos/mínimos locales.
- 2.Localización de Puntos Clave:** Refinar la posición de los puntos y eliminar aquellos con bajo contraste o que estén sobre bordes.
- 3.Asignación de Orientación:** Calcular gradientes en una vecindad alrededor del punto; crear un histograma de orientaciones y asignar la dirección dominante.
- 4.Generación de Descriptores:** Dividir la vecindad en una cuadrícula de 4X4 subregiones, calculando histogramas de gradiente para cada una, resultando en un vector de $4 \times 4 \times 8 = 128$ elementos.

SIFT (Scale-Invariant Feature Transform).

Algoritmo formal:

Entrada: Imagen I .

Salida: Conjunto de descriptores $\{D_1, D_2, \dots, D_n\}$.

1. $DoG \leftarrow$ Diferencia de Gaussianas en octavas.
2. $K \leftarrow$ Extremos locales en espacio-escala (DoG).
3. Para cada punto $p \in K$:
 - a. Calcular gradiente $m(x, y)$ y ángulo $\theta(x, y)$.
 - b. Asignar orientación dominante O_p .
 - c. Generar descriptor D_p normalizado.

Métricas de Complejidad

• **Complejidad Temporal:** $O(N)$ donde N es el número de píxeles, pero con una constante muy alta debido a la construcción de la pirámide Gaussiana y el cálculo de los 128 descriptores. Es computacionalmente costoso en comparación con Sobel.

• **Complejidad Espacial:** $O(N \times S)$, donde S es el número de escalas, debido al almacenamiento de la pirámide de imágenes

SIFT (Scale-Invariant Feature Transform).

Pseudocódigo:

Función **SIFT**(imagen):

```
piramide = ConstruirPiramideGaussiana(imagen)
dog = CalcularDiferenciaGaussianas(piramide)
puntos_clave = DetectarExtremos(dog)
descriptores = []
```

Para p en puntos_clave:

```
    orientacion = CalcularOrientacionDominante(p)
    desc = CrearDescriptor128D(p, orientacion)
    descriptores.agregar(desc)
```

Retornar descriptores

SIFT (Scale-Invariant Feature Transform).

SIFT

```
1 import cv2
2 import numpy as np
3 from skimage import data, color, img_as_ubyte # Importamos esta utilidad
4
5 def extraer_caracteristicas_sift(imagen_uint8):
6     sift = cv2.SIFT_create()
7     kp, des = sift.detectAndCompute(imagen_uint8, None)
8     return kp, des
9
10 # 1. Cargar imagen
11 image_float = color.rgb2gray(data.astronaut())
12
13 # 2. CORRECCIÓN: Convertir de float (0.0-1.0) a uint8 (0-255)
14 image_uint8 = img_as_ubyte(image_float)
15
16 # 3. Ahora sí, ejecutar
17 kp, des = extraer_caracteristicas_sift(image_uint8)
18
19 print(f"Puntos clave encontrados: {len(kp)}")
20 print(f"Dimensión del descriptor: {des.shape}") # Nota: des es una matriz completa
```

... Puntos clave encontrados: 1100
Dimensión del descriptor: (1100, 128)

40_UNAM_AI_Actividad_Laboratorio_5_11_algoritmos_clase.ipynb ☆ ☁

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

ando + Código + Texto ▶ Ejecutar todo

... Dimensión del descriptor: (1100, 128)

```
[7]
✓ 0s
1 import cv2
2 import matplotlib.pyplot as plt
3 # (Asume que ya tienes 'image_uint8', 'kp', and 'des' de la ejecución anterior)
4
5 # 1. Dibujar los puntos clave sobre la imagen original
6 # Usamos DRAW_MATCHES_FLAGS_DRAW_RICH_KEYPOINTS para que dibuje
7 # la orientación y el tamaño de cada punto (la "riqueza" de SIFT).
8 imagen_con_sift = cv2.drawKeypoints(image_uint8, kp, None,
9                                     flags=cv2.DRAW_MATCHES_FLAGS_DRAW_RICH_KEYPOINTS)
10
11 # 2. Visualización
12 plt.figure(figsize=(10, 10))
13 plt.imshow(imagen_con_sift)
14 plt.title(f"SIFT: Se detectaron {len(kp)} puntos clave invariantes")
15 plt.axis('off')
16 plt.show()
```

... SIFT: Se detectaron 1100 puntos clave invariantes



Inteligencia Artificial

Ética en Inteligencia Artificial

Dra. Jessica Sarahi Méndez Rincón



¿Qué es la Moral? (El "código fuente" o las reglas locales)

Origen: Proviene del latín *moralis*, que significa costumbre.

La moral es el conjunto de normas, reglas, costumbres y tabúes que un grupo específico de personas (una sociedad, una religión, una época) acepta como "lo correcto".

- **La analogía:** La moral es como el sistema operativo o las reglas de una aplicación específica. Cambia según la región y la época.


- **Ejemplo:** En algunas culturas es moralmente aceptable tener varias esposas; en la nuestra no. En la pandemia, era un deber moral usar cubrebocas para cuidar al otro; hoy ya no es una norma social activa.

- **Moral religiosa:** Basada en los dogmas y mandamientos de una fe (ej. la moral cristiana).

- **Moral laica:** Independiente de doctrinas religiosas, basada en principios cívicos y de derechos humanos.

- **Moral social:** Normas impuestas por un grupo o comunidad.

- **Moral individual:** Las convicciones y valores propios de cada persona



¿Qué es la Ética? (La “arquitectura de software” o la filosofía crítica)

La ética no es lo mismo que la moral; la ética es la **reflexión filosófica y científica sobre la moral**. Es preguntarse *¿por qué esto es bueno?, ¿tiene sentido esta regla?, o ¿a quién daña?*. La ética busca principios universales que apliquen a todos los seres humanos, sin importar su cultura.

- **La analogía:** La ética es el programador senior que revisa el código fuente (la moral) para ver si es eficiente, justo y si no tiene "bugs" que dañen a los usuarios.

- **Ejemplo:** La moral de una empresa puede decir: *"Debes maximizar las ganancias a toda costa"*. La ética del científico interviene y dice: *"No, porque el algoritmo que diseñé para maximizar ganancias discrimina a las mujeres (como vimos en el laboratorio)"*.



*Piensen en la **pandemia**. Cuando estábamos encerrados, el gobierno o la escuela nos pusieron reglas (Moral). Algunas tenían sentido y otras parecían absurdas. El ejercicio que hacían en su mente de decir 'esta regla no sirve para nada' o 'esta regla sí cuida a mi abuelito', **eso es hacer Ética**. Vamos a aprender a usar esa misma capacidad crítica, pero aplicada a las líneas de código y a los algoritmos que ustedes van a programar mañana.*

¿Qué son los Valores? (Las “variables de configuración” o prioridades)

Los valores son aquellas cualidades o conceptos que una sociedad o individuo consideran altamente valiosos, deseables y que guían sus acciones. Son los motores de nuestras decisiones.

•*Ejemplos:* La honestidad, la libertad, la lealtad, el éxito económico, la empatía.

•**Ojo:** Los valores no siempre son éticos. Alguien puede tener como valor supremo el "éxito económico" o el "poder" y pasar por encima de los demás para conseguirlo.



¿Qué son los Principios Morales? (Las "Leyes de la Termodinámica" del comportamiento)

Son leyes o directrices universales, fundamentales e inmutables que sirven para garantizar la dignidad humana y la convivencia pacífica. No cambian con la moda.

•*Ejemplos:* No hacer daño al inocente (No maleficencia), tratar a los demás con igualdad, respetar la autonomía de las personas.



¿Cuáles son "Buenos" y cuáles son "Malos"? (El criterio objetivo)

A las personas les cuesta el relativismo de *"lo que para ti es bueno para mí es malo"*. Necesitan un criterio sólido. En ética moderna, la brújula para definir qué es bueno o malo no se basa en la religión ni en la ideología, sino en **la dignidad humana y el bienestar colectivo**.

Los Principios y valores “buenos” (Constructivos)

Son aquellos que expanden la vida, protegen la dignidad humana, buscan la justicia y disminuyen el sufrimiento.

- **Justicia / Equidad:** Tratar a las personas con igual consideración, evitando sesgos arbitrarios.
- **Responsabilidad (*Accountability*):** Hacerse cargo de las consecuencias de lo que uno construye (crucial para un programador).
- **Autonomía:** Respetar la capacidad de las personas de tomar sus propias decisiones (por ejemplo, que un usuario decida si quiere que la IA use sus datos o no).
- **Beneficencia:** Diseñar tecnología que activamente ayude a la sociedad.

Los "Malos" (Destructivos o Antivalores)

Son aquellos que cosifican a las personas (las tratan como simples herramientas o números), generan daño deliberado, destruyen la confianza social o promueven la opresión.

- **Maleficencia:** Diseñar sistemas sabiendo que van a engañar, manipular (como los algoritmos adictivos de redes sociales) o dañar a alguien.
- **Discriminación / Injusticia:** Crear o perpetuar sistemas que excluyen a grupos por características que no pueden controlar (género, raza, edad).
- **Opacidad / Engaño:** Ocultar el funcionamiento de un sistema para manipular la opinión pública o robar datos (los algoritmos de "caja negra" abusivos).
- **Irresponsabilidad técnica:** Lanzar un software al mercado sabiendo que tiene fallos graves de seguridad o sesgos que pueden arruinar vidas.



CLASIFICACIÓN DE LOS VALORES



· QUÉ SON LOS VALORES ·

Los valores son principios, creencias o cualidades de una persona que guían su comportamiento y decisiones, marcando sus propios límites

· TIPOS & CLASIFICACIÓN DE VALORES ·

EJEMPLOS DE VALORES

- Respeto
- Empatía
- Solidaridad
- Humildad
- Tolerancia
- Paciencia
- Sinceridad
- Honestidad

VALORES FAMILIARES

VALORES ESPIRITUALES

VALORES SOCIOCULTURALES

VALORES ORGANIZACIONALES

VALORES PERSONALES

VALORES MATERIALES

VALORES ÉTICOS & MORALES

VALORES AMBIENTALES

Valores Personales y de Autorrealización (El desarrollo del individuo)

Tienen que ver con el crecimiento interno, la salud mental y la estructura del carácter de cada estudiante.

- **Honestidad:** Actuar y hablar con base en la verdad, la transparencia y la rectitud, asegurando que lo que pienso, digo y hago esté alineado.
- **Salud:** Valorar el bienestar integral (físico, mental y emocional) como el soporte básico y la condición necesaria para poder realizar cualquier otro proyecto de vida.
- **Conocimiento:** El deseo continuo de comprender el mundo, descubrir la verdad y adquirir herramientas intelectuales a través del estudio, la ciencia y la experiencia.
- **Humildad:** Virtud que consiste en el conocimiento de las propias limitaciones y debilidades y en obrar de acuerdo con este conocimiento.
- **Disciplina:** La capacidad de coordinar el esfuerzo, la constancia y el orden para cumplir metas a largo plazo, por encima de los impulsos o la flojera del momento.
- **Libertad:** La facultad y el derecho humano de elegir la propia forma de actuar, pensar y construir la vida, asumiendo con madurez las consecuencias de esas elecciones.
- **Paz:** Un estado de armonía, tranquilidad y equilibrio (tanto interno como en el entorno) que resulta de la ausencia de conflictos destructivos y de la resolución justa de las diferencias.
- **Espiritualidad:** La búsqueda de sentido trascendente a la existencia, la conexión con algo más grande que uno mismo y el cultivo de la paz interior (no necesariamente ligada a una religión).
- **Diversión:** La necesidad humana de recreación, juego, risa y esparcimiento para liberar tensión y disfrutar del presente de forma lúdica.

Valores Relacionales y Sociales (El software de la convivencia)

Son los que regulan cómo nos conectamos, cuidamos y vinculamos con los demás. Sin ellos, cualquier sociedad (o red social) colapsa.

- **Amor:** La fuerza o disposición afectiva que nos impulsa a buscar el bienestar, el desarrollo y la felicidad de otra persona (o de nosotros mismos). Es el pegamento humano por excelencia.
- **Respeto:** El reconocimiento del valor inherente y la dignidad de los demás, aceptando sus diferencias sin intentar cambiarlos o vulnerarlos.
- **Empatía:** La capacidad cognitiva y emocional de sintonizar con la realidad del otro ("ponerse en sus zapatos") para comprender su sufrimiento o su alegría.
- **Amistad:** Un vínculo afectivo voluntario basado en la reciprocidad, la confianza mutua, el compañerismo y el apoyo incondicional a lo largo del tiempo.
- **Familia:** El valor que se le da al núcleo de apoyo primario (sea de sangre o elegido), caracterizado por el sentido de pertenencia, refugio seguro y cuidado mutuo.
- **Lealtad:** El compromiso de fidelidad y respaldo hacia una persona, causa o principio, especialmente en los momentos difíciles o de crisis.
- **Paciencia:** Capacidad de padecer o soportar algo sin alterarse.

Valores Instrumentales y de Estatus (Los recursos y el reconocimiento externo)

Ojo aquí: estos valores no son "malos" por sí mismos, pero en la subasta suelen generar debate porque son herramientas o consecuencias, no fines éticos últimos.

- Dinero:** Un recurso de intercambio económico que representa seguridad material, estabilidad y acceso a bienes o servicios. Es un valor instrumental (sirve como medio para conseguir otras cosas).
- Éxito:** La consecución de las metas u objetivos propuestos en la vida (académicos, profesionales o personales) que genera una satisfacción por el logro alcanzado.
- Poder:** La capacidad, influencia o autoridad para dirigir, controlar situaciones o tomar decisiones que impactan el entorno o las acciones de los demás.
- Fama:** El reconocimiento público masivo y la notoriedad de la que goza una persona en la sociedad debido a sus logros, talento o exposición.
- Reconocimiento:** La validación, el respeto y la aprobación que recibimos de nuestros pares, profesores o la sociedad por nuestro esfuerzo y valía.

Actividad por Equipo: Subasta de Valores

*Chicas y chicos, no hay respuestas incorrectas en la subasta, pero miren esto: si un programador pone como su valor supremo el **Dinero** o el **Poder**, es muy probable que diseñe una IA adictiva que robe datos para maximizar ganancias. Pero si ese mismo programador compra **Empatía** y **Respeto**, su código buscará no dañar a los usuarios. Sus valores personales configuran directamente el software que programan.*

- ACM/IEEE-CS Joint Task Force. (s.f.). *Ingeniería de Software: Código de Ética y Práctica Profesional (Versión 5.2)*. Association for Computing Machinery.
 - La versión 5.2 sigue siendo el estándar vigente: Este código, adoptado originalmente a finales de los años 90, continúa siendo el marco ético fundamental y específico para la **Ingeniería de Software**. No ha habido una "versión 6.0" que reemplace estos ocho principios.
 - **Actualización del Código General de la ACM (2018):** Es importante notar que la ACM actualizó su **Código de Ética y Conducta Profesional general** en **2018**. Aunque no es exclusivo para ingenieros de software (**es para todos los profesionales de la computación**), es el documento más reciente y robusto en términos de ética digital moderna, incluyendo temas contemporáneos que el código de 1999 no detallaba tan profundamente.
 - El código general más reciente, esta es la referencia:
 - **Association for Computing Machinery. (2018). *Código de ética y conducta profesional de la ACM: Afirmando nuestra responsabilidad profesional*. <https://www.acm.org/about-acm/code-of-ethics-in-spanish>**

Según el código, el bienestar social es prioridad. El interés social es central.



Ingeniería de Software Código de Ética y Práctica Profesional 5.2

Versión corta

PREÁMBULO

La versión corta del código resume las aspiraciones a un alto nivel de abstracción; las cláusulas que se incluyen en la versión completa proporcionan ejemplos y detalles acerca de cómo estas aspiraciones modifican nuestra manera de actuar como profesionales de la ingeniería de software. Sin las aspiraciones los detalles pueden convertirse en tediosos y legalistas; sin los detalles las aspiraciones pueden convertirse en altisonantes pero vacías; juntas, las aspiraciones y los detalles forman un código cohesivo.

Los ingenieros de software deberán comprometerse a convertir el análisis, especificación, diseño, implementación, pruebas y mantenimiento de software en una profesión respetada y benéfica. De acuerdo a su compromiso con la salud, seguridad y bienestar social, los ingenieros de software deberán sujetarse a los ocho principios siguientes:

1. **Sociedad.** Los ingenieros de software actuarán en forma congruente con el interés social.
2. **Cliente.** y empresario. Los ingenieros de software actuarán de manera que se concilien los mejores intereses de sus clientes y empresarios, congruentemente con el interés social.
3. **Producto.** Los ingenieros de software asegurarán que sus productos y modificaciones correspondientes cumplen los estándares profesionales más altos posibles.
4. **Juicio.** Los ingenieros de software mantendrán integridad e independencia en su juicio profesional.
5. **Administración.** Los ingenieros de software gerentes y líderes promoverán y se suscribirán a un enfoque ético en la administración del desarrollo y mantenimiento de software.
6. **Profesión.** Los ingenieros de software incrementarán la integridad y reputación de la profesión congruentemente con el interés social.
7. **Colegas.** Los ingenieros de software apoyarán y serán justos con sus colegas.
8. **Personal.** Los ingenieros de software participarán toda su vida en el aprendizaje relacionado con la práctica de su profesión y promoverán un enfoque ético en la práctica de la profesión.

Ingeniería de Software Código de Ética y Práctica Profesional 5.2

Versión completa

PREÁMBULO

Las computadoras tienen un papel central cada vez mayor en el comercio, industria, gobierno, medicina, educación, entretenimiento, y sociedad. Los ingenieros de software son aquellos que contribuyen, mediante la participación directa o enseñanza, al análisis, especificación, diseño, desarrollo, certificación, mantenimiento y pruebas de sistemas de software. Debido a sus funciones en el desarrollo de sistemas de software, los ingenieros de software tienen suficientes oportunidades para causar beneficio o generar daño y para habilitar o influenciar a otros a causar daño o beneficio. Para asegurar, en la medida de lo posible, que sus esfuerzos se utilizarán para hacer el bien, los ingenieros de software deben comprometerse a hacer de la ingeniería del software una

Principios Fundamentales de la Ética en IA

Estos son los pilares universales que deben regir cualquier sistema inteligente. Son la base teórica indispensables para que se entienda el "deber ser".

- **Justicia y no discriminación (equidad):** Asegurar que los modelos no perpetúen ni amplifiquen los sesgos humanos (de género, raza, socioeconómicos, etc.) presentes en los datos de entrenamiento.

- **Transparencia y explicabilidad (XAI):** Romper el paradigma de la "caja negra". Un sistema ético debe ser capaz de justificar sus decisiones de una manera comprensible para los seres humanos, especialmente en áreas críticas como la salud, la justicia o las finanzas.

- **Privacidad y gobernanza de datos:** El respeto a la confidencialidad de la información. Los usuarios deben tener control sobre sus datos y saber cómo se utilizan para entrenar modelos.

- **Responsabilidad y rendición de cuentas (Accountability):** Definir quién es responsable cuando un sistema de IA falla o causa daño: ¿El desarrollador? ¿La empresa? ¿El usuario final?

Los Grandes Dilemas y Desafíos Críticos

Para conectar y despertar su sentido crítico, es ideal presentar los problemas actuales a los que se enfrenta la industria.

El sesgo Algorítmico y la Calidad de los Datos

Los algoritmos aprenden del pasado. Si un dataset histórico refleja discriminación estructural, el modelo automatizará y escalará esa discriminación.

Ejemplo de clase: Analizar cómo los sistemas de reconocimiento facial tienen mayores tasas de error en mujeres y personas de tez oscura, o cómo los filtros de currículums automatizados han sesgado la contratación de personal.

El Impacto Socioeconómico y la Automatización

La IA tiene el potencial de desplazar puestos de trabajo tradicionales. El debate ético aquí se centra en la transición justa, la re capacitación de la fuerza laboral y el aumento de la brecha de desigualdad tecnológica entre naciones y clases sociales.

Desinformación y Manipulación (Deepfakes y Contenido Sintético)

La capacidad de generar texto, imágenes y videos hiperrealistas plantea un desafío enorme para la verdad pública, la confianza en los medios y la seguridad democrática.

Marcos Regulatorios y gobernanza global

Es vital que los estudiantes conozcan que la ética ya se está transformando en leyes concretas a nivel mundial.

- **La Ley de Inteligencia Artificial de la Unión Europea (EU AI Act):** El primer marco jurídico integral en el mundo, que clasifica los sistemas de IA según su nivel de riesgo (mínimo, específico, alto y prohibido). Es excelente para enseñar cómo se evalúa el riesgo de un software en el mundo real.

- **Recomendación de la UNESCO sobre la Ética de la IA:** Un acuerdo global (adoptado por más de 190 países) que pone el foco en los derechos humanos, la dignidad y la sostenibilidad ambiental.

El uso de los datos personales

En diciembre de 2018, el **New York Times** obtuvo un conjunto de datos que contenía información sobre la localización de usuarios, la cual fue recolectada desde sus propios teléfonos móviles por medio de una aplicación que mostraba información simple, entre las cuales se encontraba el estado del tiempo y recomendaciones sobre restaurantes. El conjunto de datos contenía información precisa de la ubicación geográfica de cientos de millones de usuarios, misma que era actualizada al menos un centenar de veces al día.

Por lo regular, los compradores potenciales de este tipo de información también buscan información totalizada. Por ejemplo, una compañía que venda planes de inversión puede estar interesada en conocer la cantidad de personas que compran en cierta cadena de supermercados, con el fin de predecir los ingresos de las personas y construir un conjunto de clientes potenciales hacia donde orientar su oferta.

El uso de los datos personales

Retomando la historia, el New York Times pudo identificar a una maestra de 46 años llamada Lisa Magrin, quien diariamente viajaba 14 millas desde su casa hasta su centro de trabajo (una vez descubierta la identidad de una persona es posible aprender mucho más sobre ella). El Times siguió el rastro de los datos de Lisa hasta **Weight Watchers**, una compañía que ofrece planes de pérdida de peso, después la visita al consultorio de su dermatólogo y por último la casa de su exnovio. Al saber de la filtración de sus datos, Lisa declaró que lo que hizo el Times es una perturbadora “idea de que la gente descubra esos detalles íntimos que no quieres que la gente sepa” (Valentino, Singer, Keller y Krolik, 2018). Cuando una aplicación solicita permiso para acceder a datos de localización, la política de privacidad de las tiendas de aplicaciones indica que los datos deben ser recopilados de forma anónima. Del caso investigado por el New York Times, se reveló que no necesariamente es cierto y que el reporte encontró que la información se compartió con más de 40 compañías que la retuvieron por años.

Una práctica común en aplicaciones de tiendas es solicitar rastrear datos de localización a cambio de otorgar premios, descuentos o servicios personalizados a los usuarios que lo autoricen. Por ende, en el caso de Lisa, ella autorizó el acceso a sus datos de ubicación a una aplicación que registraba sus rutinas de trote.

No obstante, aun y con la autorización expresa de un usuario, es muy fácil compartir información sin notarlo. Por ejemplo, la aplicación GasBuddy ofrece, entre otras cosas, ubicar rápidamente gasolineras y mostrar los precios actualizados del combustible de más de 140,000 estaciones de carga, a cambio de utilizar información del usuario que le permita “analizar tendencias de la industria”.



El uso de los datos personales

La humanidad genera y explota los datos recopilados a distintas escalas y niveles. Cada día se obtiene una gran cantidad de información de usuario obtenida del historial de navegación en el Internet, así como del uso e interacción en sus redes sociales (inclusive de sensores conectados en objetos que utiliza). Por lo tanto, se estima que el volumen de datos almacenados en el mundo se duplica cada cuatro años. Por ejemplo, en el 2020, la humanidad había almacenado alrededor de 64.2 zettabytes de información digital (Holst, 2021).

Una práctica común es que los desarrolladores de aplicaciones vendan la información recopilada por medio de ellas u ofrezcan compartirlas con otras compañías, con la finalidad de colocar anuncios comerciales con base en la ubicación geográfica del usuario por un costo fijo. El New York Times deriva de su investigación que hay empresas que pagan entre medio y dos centavos de dólar por mes por la información de la ubicación de un usuario.

De la misma manera, Facebook o Google declaran recopilar información de usuario para mejorar la experiencia de este al utilizar sus servicios y ofrecer anuncios personalizados, pero que no la venden a terceros.

Asimismo, otras aplicaciones obtienen y rastrean la información de usuario para personalizar los servicios ofrecidos, por ejemplo, aplicaciones financieras que obtienen información sensible (no solo nombre, edad, sino monto de ingresos, deudas adquiridas, entre otras) y procesan con sus algoritmos para autorizar préstamos, por ejemplo.

En caso de continuar cediendo los datos a empresas, convirtiendo a cada usuario como un gran conjunto de datos con el objetivo de simplificar tareas o automatizar decisiones, se deben establecer límites con respecto al tipo de dato recopilado y el uso que se le da a esos, así como crear leyes y regulaciones, a la par de construir las instituciones y organizaciones que vigilen la aplicación de estos límites.


Sesgo en los modelos

Una modelo con alta precisión no necesariamente significa que es estable o que aprendió con precisión. El **sesgo** en los modelos es un fenómeno que ocurre cuando un modelo produce resultados que tienen prejuicios sistémicos debido a supuestos erróneos durante su construcción (proceso de aprendizaje).

Un modelo de aprendizaje automático depende de la calidad, objetividad y tamaño del conjunto de datos a partir del cual fue construido. Si el conjunto de datos es erróneo, pobre o está incompleto, el modelo generará predicciones erróneas. “*Garbage in, garbage out*” (Geiger et al., 2021) transmite la idea de que la calidad de la salida del sistema está determinada por la calidad de la entrada.

Durante el proceso de aprendizaje, el algoritmo tiende a aprender sistemáticamente información incorrecta al no considerar toda la información contenida en los datos de entrada, lo que puede provocar que un algoritmo pierda la relación relevante entre las entradas de datos (atributos o características de los datos) y las salidas (predicciones). En esencia, el sesgo aparece cuando un algoritmo no tiene la capacidad suficiente para aprender la información apropiada del conjunto de datos.

Un modelo puede generar decisiones sesgadas a causa de datos insuficientes, incompletos, inconsistentes o pobres durante la fase de desarrollo. Si bien estos sesgos pueden ser involuntarios, su existencia puede dar lugar a resultados desastrosos: una mala experiencia de usuario, un diagnóstico médico equivocado o una mala calificación para un crédito, por citar algunos ejemplos.



Sesgo en los modelos

Para evitar tales escenarios, se debe revisar cuidadosamente que los datos que se utilizan para entrenar modelos sean exhaustivos y no tengan algún tipo de sesgo cognitivo. Los datos deben ser representativos para diferentes razas, géneros, orígenes y culturas que podrían verse afectados de forma negativa. Es de suma importancia verificar que el modelo no esté sesgado, para ello puedes utilizar mecanismos de inspección, monitoreo, investigación y evaluación antes de ponerlo en producción.

Existen diferentes tipos de sesgo que pueden afectar un modelo generado por un algoritmo de aprendizaje:

Sesgo	Descripción
En el algoritmo	Ocurre cuando existe algún problema con el algoritmo que realiza los cálculos durante el proceso de aprendizaje.
Muestral	Este tipo de sesgo está asociado con los datos utilizados para entrenar el modelo. Puede ser que el conjunto de datos no sea lo suficientemente grande o representativo para poder enseñarle al algoritmo. Un ejemplo sería un conjunto de datos que incluya solamente información de alumnas, entrenando un algoritmo para predecir si los alumnos que se inscribirán en cierto curso serán hombres o mujeres. Como resultado, el modelo concluirá que todos los alumnos serán mujeres.
Cognitivo	Los datos utilizados para entrenar al sistema reflejan prejuicios, estereotipos o supuestos sociales incorrectos y, por lo tanto, esto se introduce en el modelo. Por ejemplo, utilizar un conjunto de datos de profesionales de la ingeniería que incluya solo como ingenieros de campo a hombres, mantendrá ese estereotipo dentro del modelo.
De medición	Se da por problemas subyacentes con la precisión de los datos y la forma en la que se midieron y evaluaron. Por ejemplo, utilizar un grupo de imágenes de jugadores de rugby que siempre están sonriendo para entrenar un algoritmo, podría sesgar el resultado si el modelo resultante se utiliza para medir el clima laboral de los equipos de rugby. Por otro lado, un sistema que se entrena para evaluar con precisión el peso de alguna variable estará sesgado si los pesos utilizados en los datos de entrenamiento están redondeados hacia su valor entero inmediato superior.
De exclusión	Resulta cuando ciertas instancias del conjunto de datos son excluidas durante el entrenamiento, sin considerar que pudieran ser importantes para el proceso en su totalidad.

Sesgo en los modelos

Otra fuente de error importante a considerar es la **varianza**, la cual se da cuando el algoritmo de aprendizaje genera suposiciones incorrectas en función de los datos de entrenamiento. A diferencia del sesgo, la varianza es una reacción a las variaciones reales dentro del conjunto de datos de entrenamiento. Sin embargo, no deberían tener un impacto en el modelo. La varianza representa una sensibilidad problemática a pequeñas variaciones del conjunto de datos de entrenamiento que pueden producir resultados inexactos.

La varianza y el sesgo están relacionados con la complejidad del modelo. Un modelo de baja complejidad implica alto sesgo y baja varianza, por el contrario, un modelo muy complejo implica bajo sesgo y alta varianza.


El término **desajuste** o ***underfitting*** se atribuye a un modelo cuando es muy simple, con sesgo grande y varianza baja, como resultado no puede capturar de forma correcta la tendencia de los datos y sus predicciones no son precisas, lo que significa que el modelo es incapaz de hacer coincidir los datos de entrada con los datos de destino. Un **sobreajuste** o ***overfitting*** es lo opuesto, el modelo es muy complejo y se ajusta mucho a un cierto conjunto de datos, por lo que sus predicciones sobre este mismo conjunto serán precisas, pero no así en datos no vistos, por lo que no podrá generalizar de forma correcta y tendrá sesgo bajo y alta varianza.

Sesgo en los modelos

Actualmente muchas compañías utilizan algoritmos de aprendizaje automático para analizar una gran cantidad de datos y utilizarlos en sus tomas de decisiones, desde la evaluación de solicitudes de crédito y digitalización de contratos legales para identificar errores hasta examinar las grabaciones de empleados en las comunicaciones con los clientes para identificar malas prácticas, entre otros ejemplos.

Mientras los algoritmos de aprendizaje automático generan modelos que permiten que las compañías tengan procesos de toma de decisiones más eficientes y automatizadas, estos son susceptibles al síndrome de “garbage in, garbage out”, derivado de conjuntos de datos sesgados. El sesgo es un fenómeno que carga el resultado de un algoritmo o modelo a favor o en contra de una idea.

Para evitarlo, es importante seleccionar un conjunto de datos de entrenamiento que sea representativo y lo suficientemente grande para contrarrestar los tipos más comunes de sesgo, el muestral y el cognitivo. De igual manera, en la medida que pasa el tiempo, se deben actualizar los conjuntos de datos de entrenamiento y reentrenar los modelos para que aprendan los nuevos patrones de datos que pudieran aparecer.



Si entra basura, sale basura.

Conjunto de datos anónimos

En 2012, el New York Times publicó una historia sobre la forma en que las empresas analizan la información recolectada de sus clientes con el fin de buscar ventajas publicitarias. El artículo reveló que Target Corporation en los Estados Unidos tenía un algoritmo capaz de determinar a partir de los patrones de compra si una mujer estaba embarazada y utilizar esa información para enviarle anuncios publicitarios y cupones de artículos relacionados con el bebé. El reporte incluía una anécdota sobre un hombre en Minneapolis que se había quejado porque la tienda le había enviado cupones de bebé a su hija adolescente, lo que el hombre etiquetó como “una sugerencia a embarazarse” y la realidad es que su hija ocultó su embarazo hasta que Target lo “descubrió”.



La promesa de uso de los modelos de aprendizaje automático es facilitar el entendimiento del mundo a partir de los datos, y en un mundo que vive la era del “*big data*” esa promesa es muy tentadora. Los argumentos que pudieran justificar la adopción de técnicas de aprendizaje automático y, por lo tanto, de recopilación, almacenamiento y uso de datos, van desde la mejora en el desempeño, efectividad y competitividad en el ámbito comercial hasta mejorar la seguridad de los ciudadanos como parte de una política pública.

Bajo ciertos escenarios, el uso de modelos puede percibirse como una *espada de doble filo*, por ejemplo, pueden ser utilizados para mejorar procesos de gobierno, la salud pública, crear ciudades inteligentes, reducir crímenes, etcétera. En el otro extremo, pueden utilizarse para espiar a las personas, enviar anuncios publicitarios no solicitados y controlar el comportamiento tanto de forma abierta como encubierta.

Conjunto de datos anónimos

El punto es que, al procesar una gran cantidad de información por medio de algoritmos y modelos de aprendizaje automático, es casi inminente que se tenga que trabajar con información que asocie cada instancia de datos con personas reales. Esta información se conoce como datos privados y hacen referencia a una persona identificable. Desde la perspectiva de privacidad, los datos pueden clasificarse en cuatro categorías:

1. Información de identificación personal.

- Están asociados directamente con las personas: nombres, número de seguro social, correo electrónico, etcétera.

2. Cuasi-identificadores.

- Datos que por sí solos pueden no ser útiles, pero al combinarse pueden ayudar a identificar al tipo de persona: género, código postal, edad, etcétera.

3. Información sensible.

- No son de identificación personal, pero sí es información delicada que en algún momento debe protegerse, como los ingresos económicos, información médica, de geolocalización, etcétera.

4. Información no sensible.

- Cualquier otro tipo de información que no esté en cualquiera de las otras tres categorías.

Conjunto de datos anónimos

Una práctica que fue común a inicio de la década del 2000 es que las organizaciones divulgaban y recibían datos de personas con todos los atributos o identificadores explícitos como el nombre, dirección, número de teléfono, entre otros datos.

El **control de la divulgación de la información** es una disciplina que se ocupa del uso de los datos privados y confidenciales sobre las entidades: personas, organizaciones, familias y demás, con el objetivo de evitar que terceros utilicen esa información para identificar a cada entidad en los datos, preservando así la publicación de los datos sensibles y confidenciales.

La divulgación puede ser de **identidad** o de **atributos**. La primera permite la identificación de una entidad de forma específica, ya sea persona o institución. Por ejemplo, “estos datos corresponden a Juan Pérez, INE 12345678”. Mientras que la segunda permite que se descubra algo nuevo o relevante de la persona en cuestión, por ejemplo, “Pedro tiene diabetes”.

El almacenamiento y tratamiento de los datos privados está regulado en muchas partes del mundo, en México, por la Ley Federal de Protección de Datos Personales en Posesión de los Particulares. Para evitar caer en alguna violación a estas regulaciones al utilizar esta información, es importante eliminar aquello que sea de identificación personal a través de un proceso llamado **anonimización**.

La anonimización de datos es el proceso por el cual se elimina o intercambia información sensible que identifica de forma directa a un individuo dentro de un conjunto de datos. Este proceso tiene la finalidad de convertir al individuo identificable en uno completamente anónimo.

Algoritmos y privacidad

La **k-anonimidad** es una métrica de anonimato para la publicación de datos. Se obtiene a partir de un proceso llamado k-anonimización, mediante el cual se generalizan, modifican o distorsionan los valores de los cuasi-identificadores para que ningún individuo sea identificable de forma única de un grupo de k instancias dentro de un conjunto de datos (Slijepčević et al., 2021). El parámetro **k** indica el grado de anonimidad. El objetivo principal de este proceso es proteger la privacidad de los individuos cuyos datos se encuentran recopilados y almacenados.

La k-anonimización implica la manipulación de cuasi-identificadores utilizando distintas estrategias. A continuación, se presentan las más comunes.

Además del uso de las técnicas descritas de anonimización de los datos privados, se debe evitar el proceso inverso, la **desanonimización**, que permite identificar la información anónima utilizando conjuntos de datos públicos disponibles. Para reducir el riesgo de desanonimización, se deben aplicar técnicas de cifrado o encriptación, tablas de mapeo, limitar el acceso no autorizado al personal que tiene contacto directo con este tipo de información y mecanismos de control organizacional, entre otras.

Técnica	Descripción
Supresión	Se elimina por completo la información asociada a ciertos atributos en los datos sensibles o de identificación personal, por ejemplo, el nombre.
Enmascaramiento de caracteres	Se ocultan ciertos caracteres de la información sensible o de identificación personal, por ejemplo, en el atributo nombre del conjunto de datos se reemplaza la palabra “Juan” por “xxxx” o “****”.
Seudonimización	Es el reemplazo de los datos sensibles o de identificación personal reales por datos inventados. Con el fin de evitar la vinculación de una persona entre conjuntos de datos, es recomendable no utilizar seudónimos persistentes para una persona en más de un conjunto de datos.
Intercambio	Es una mezcla aleatoria de valores en los conjuntos de datos con el fin de que no correspondan a la información original.
Generalización	Es el redondeo y reducción de la precisión de los datos. Por ejemplo, modificar los valores de la edad de las personas y generalizarlos a categorías o cambiar las coordenadas de ubicación exacta por el nombre de la ciudad.
Perturbación	Se modifican ligeramente los datos agregando ruido. Se usa sobre todo en identificadores numéricos, por ejemplo, multiplicar por 5 los valores de los números de casa en una dirección.
Datos sintéticos	Es la creación de conjuntos de datos sintéticos basados en los originales.

Seguridad en los datos

El concepto erróneo más común sobre la privacidad es que se trata de tener algo que ocultar; nada más alejado de la realidad. Por ejemplo, no hay nada de malo en querer guardar una carta en un sobre para enviarla a algún amigo o amiga.

No hay nada de malo en ir al baño o cantar en la regadera, buscar lugares alejados para tener un momento de reflexión o decidir no compartir con alguien las emociones que se pueden experimentar durante alguna situación.

La **privacidad** es un derecho humano inherente y un requisito para mantener la condición humana con dignidad y respeto. Se trata de elegir y tener el poder de controlar la forma en la que un individuo se presenta al mundo.

Al perder la privacidad, se pierde el control de cómo alguien se muestra ante la humanidad. Por ejemplo, si se dice algo en redes sociales y de forma accidental se comparte con el grupo incorrecto o cuando una entidad gubernamental recopila datos personales.

La pregunta que siempre se hace en circunstancias donde se pierde el control de la privacidad es la siguiente: ¿cómo se supo eso?

Las violaciones a la privacidad son intrusiones y no todas son iguales, es decir, el contexto importa. Hay una gran diferencia entre que una autoridad sepa sobre el uso de estupefacientes de una persona a que los amigos lo sepan.

De la misma manera, los daños ocasionados por esas violaciones a la privacidad no son iguales; quienes se encuentran en situaciones socioeconómicas marginales son los más afectados, ya sea por una condición racial, política, étnica o religiosa.

La privacidad de los individuos está bajo un constante escrutinio y comprender la forma en la que esto ocurre es entender lo que está en juego: la seguridad.

En la medida que la tecnología facilita la vida de las personas, también genera mayor preocupación sobre ataques informáticos y otras vulnerabilidades. ¿Es posible equilibrar el deseo de comodidad sin sacrificar la seguridad?

Las cámaras de los teléfonos reconocen los rostros de sus propietarios, los timbres en las casas tienen la habilidad de reconocer e interactuar con las personas que llaman a la puerta; desde un solo dispositivo es posible controlar la temperatura, condiciones de iluminación, audio, video y seguridad de una habitación.



Seguridad en los datos

Las comodidades que un usuario experimenta gracias a la tecnología son cada vez mayores y lo hacen feliz hasta que existe una brecha en la seguridad de sus datos, un incidente de seguridad informático o la exposición de su información personal. La pregunta clave es la misma: ¿es posible equilibrar el deseo de comodidad sin sacrificar la seguridad?

Según el reporte *2018 NortonLifeLock Cyber Safety Insights Report* (NortonLifeLock, 2019), el 85% de las personas en los Estados Unidos están preocupados por la privacidad de sus datos, y el 66% acepta que la privacidad de sus datos en línea conlleva riesgos con el objetivo de tener una vida más cómoda.

Es posible aprovechar las comodidades que ofrece la tecnología y también reducir el riesgo de exposición de los datos mediante acciones que fortalecen la seguridad de la información:

Número	Descripción
1	Reforzar las contraseñas de aplicaciones y dispositivos, al hacerlas más extensas, con al menos un número, una mayúscula y un carácter especial, así como utilizar una contraseña única para cada dispositivo o aplicación.
2	Agregar una capa adicional de protección habilitando la autenticación multifactor (MFA) o la autenticación de dos factores (2FA).
3	Revisar el nivel de privacidad seleccionada en cada aplicación o dispositivo.
4	No asumir que la configuración por defecto es la mejor para el usuario. Personalizar las alternativas ofrecidas por cada aplicación o dispositivo.
5	Conectar dispositivos de smart home en una red distinta a la utilizada por las computadoras personales, teléfonos o tabletas.
6	Reducir la cantidad de información personal que se comparte por medio de aplicaciones o dispositivos.

Seguridad en los datos

Las amenazas a la privacidad pueden derivarse de acciones de rastreo comercial, vigilancia gubernamental o rastreo de comportamiento en redes sociales. La solución al problema de la violación a la privacidad puede variar dependiendo si lo que se desea es mantener los datos privados en secreto, prevenir su mal uso o castigar el uso indebido de la información sensible y personal.

Privacidad diferencial

Para una organización que recopila, almacena y usa datos, cualquier momento en la vida de las personas se convierte en una instancia de análisis. Las aplicaciones que hoy procesan información utilizan algoritmos de aprendizaje automático que requieren de una gran cantidad de información. Por otro lado, los centros de investigación usan y comparten información confidencial de personas de manera frecuente.

La divulgación inadecuada de tales datos puede traer consecuencias adversas o fincar responsabilidades legales a quienes cometen alguna acción indebida.

En la era de la información, el mundo se enfrenta a muchas violaciones de datos masivos y es de suma importancia que gobiernos, organizaciones y empresas tomen acciones sobre la privacidad.

Target (el segundo minorista de almacenes en Estados Unidos) implementó, en el año 2012, una técnica en apariencia intuitiva para mejorar la experiencia de compra de sus clientes.

La idea era identificar a los clientes que tenían la mayor probabilidad de estar esperando un bebé para enviarles anuncios publicitarios y cupones de maternidad, según la probabilidad estimada.

El objetivo de esta acción se puede interpretar desde dos puntos de vista: el primero es combinar la información para analizar las tendencias de compra de las embarazadas. El segundo es aplicar un algoritmo para correlacionar los datos de los nuevos clientes con los patrones de compra de los clientes existentes y así determinar la probabilidad de que una mujer pueda estar embarazada.

Privacidad diferencial

La iniciativa de Target se mantuvo durante varias semanas en el centro de una discusión sobre la privacidad de las personas y no solo por la recopilación y almacenamiento de la información para fines mercadológicos, sino también por el uso que se le puede dar a información en manos de entidades gubernamentales o en redes sociales.

El desarrollo de modelos formales como el de la **privacidad diferencial** permite a las organizaciones y compañías proteger la información confidencial, ya sea de tipo personal, asociada a un usuario o de geolocalización.

La principal premisa de la privacidad diferencial es garantizar que las personas, cuya información personal se encuentra en alguna base de datos, no se vean afectadas de algún modo. Gracias a esta técnica, se pretende entrenar modelos de aprendizaje automático con los datos de los clientes sin que estos aprendan detalles sobre ellos.

Utilizando la privacidad diferencial, una consulta de información en un sistema regresará un conjunto de datos modificado, al que se le agrega un cierto nivel de ruido extraído de forma aleatoria a partir de una distribución generada con los datos originales.

Por ejemplo, realizar una consulta a una base de datos para identificar cuántas personas de entre 20 y 30 años compraron más de \$3,000 MXN el viernes de la semana pasada, no devolverá la cantidad real, sino un valor cercano a ella (sumando o restando un cierto valor).

Cuanto más ruido haya en los datos, más difícil será revelar el anonimato, pero una gran cantidad de ruido puede provocar que los datos ya no sean de utilidad.

Privacidad diferencial

Otro ejemplo del uso de la privacidad diferencial sería el siguiente: se están recopilando datos de personas en un estudio sobre las probables causas del cáncer de pulmón. El estudio llega a la conclusión de que fumar tiene una probabilidad muy alta de provocar cáncer de pulmón. Con la privacidad diferencial se garantiza que:

Inciso	Descripción
a.	Las personas que analizan la información no tengan acceso a los datos específicos del estudio. Por ejemplo, no se podría saber que “Juan Pérez es fumador”.
b.	Otras entidades comerciales, como la aseguradora que le vende a “Juan Pérez” su póliza de gastos médicos, no cambien en función de su participación en el estudio.

Privacidad diferencial

La privacidad diferencial tiene cuatro propiedades valiosas:

1. La cuantificación de la pérdida de privacidad.

- Tiene mecanismos que miden la pérdida de privacidad.

2. Composición.

- Permite diseñar algoritmos diferenciales complejos a partir de elementos más simples.

3. Privacidad grupal.

- Permite el control de la pérdida de privacidad de grupos (información de familias, por ejemplo).

4. Cerrada en postprocesamiento.

- Es inmune al postprocesamiento. No se puede vulnerar.

Privacidad diferencial

La seguridad en los datos implica un conjunto de procesos y prácticas diseñadas para proteger información crítica dentro de un ecosistema de tecnologías de información. Las organizaciones públicas y privadas tienen la obligación legal y moral de proteger la información de sus clientes o usuarios para que no caigan en manos equivocadas.

De la misma manera que las organizaciones implementan estrategias de seguridad de la información, cada persona debe ser consciente del riesgo que implica compartir información sensible en aplicaciones y dispositivos, con el fin de realizar las mejores prácticas orientadas a proteger su privacidad.

Actualmente, los bancos, gobiernos, hospitales, centros de investigación, entre otras entidades, recolectan una gran cantidad de información sensible de personas. El proceso de anonimizar esa información es muy complejo, por lo que se opta por una estrategia de añadir ruido para incrementar la privacidad de la información almacenada en una base de datos.

Esto se conoce como privacidad diferencial y define una manera sistemática de agregar ruido de forma aleatoria a un conjunto de datos para proteger la privacidad de las personas, preservando la utilidad de la información.

Privacidad, explicabilidad y equidad

La equidad es una característica humana que consiste en tratar a las personas de forma justa y por igual, teniendo un comportamiento imparcial, sin favoritismos ni discriminación. Un modelo predictivo justo es equitativo o equilibrado en sus decisiones, independientemente del cúmulo de valores en el conjunto de entrada. La forma más simple de ver el equilibrio cuando se trata de modelar es utilizando el concepto de paridad estadística, lo que implica que las entradas estén balanceadas.

Las entradas balanceadas presentan una cantidad de observaciones de un grupo idéntico al de cualquier otro, por ejemplo, si un conjunto de datos de entrada tiene dos grupos o categorías, para ser balanceado, el grupo de los hombres debe representar el 50% de los datos y el grupo de las mujeres el otro 50%.

De la misma forma, esa distribución debe mantenerse en el modelo predictivo, por ejemplo, si un modelo autoriza créditos al 20% de los hombres, entonces también debería autorizarlo al 20% de las mujeres.

Un algoritmo de aprendizaje, de manera simple, toma instancias de datos históricos (conjunto de entrenamiento) como entrada de un problema de decisión y genera una regla (o conjunto de reglas) de decisión o clasificador (modelo) que utilizará instancias de datos futuros para el problema. Los atributos de los datos, llamados también características y el conjunto de todos los posibles atributos, definen el espacio de características o de representación de los datos.

El algoritmo de aprendizaje está diseñado para identificar patrones estadísticos en los datos de entrenamiento. Si los datos de entrenamiento reflejan algún tipo de prejuicio social, es muy probable que el algoritmo incorpore ese prejuicio en el modelo que construya y esto provocaría decisiones menos ventajosas para este tipo de minorías. Si un predictor trata desigualmente a grupos definidos por atributos sensibles o protegidos, como la edad o la raza, se dice que el predictor es **injusto**.



Privacidad, explicabilidad y equidad

La discriminación es un tratamiento desigual a personas que pertenecen a ciertos grupos, privándolos de beneficios u oportunidades. Los grupos que comúnmente sufren de discriminación tienen que ver con la edad, el género, el color de piel, la religión, la raza, el idioma, la cultura, el estado civil o la condición económica.

La inequidad involuntaria que ocurre cuando una decisión tiene un resultado muy distinto para grupos diferentes se conoce como impacto dispar. Dado que los algoritmos de aprendizaje automático se utilizan con mayor frecuencia para tomar decisiones importantes, como la aprobación de préstamos, intereses de pago, incluso de libertad condicional, es un reto importante minimizar la discriminación involuntaria.

Existen múltiples causas que pueden provocar sesgos en las predicciones hechas por los modelos de aprendizaje automático:



Punto	Descripción
1. La idoneidad de los datos para representar a diferentes grupos.	Los patrones poco frecuentes o específicos pueden ser minimizados por el modelo al generalizar, por lo que esos registros, menores en cantidad, pueden descuidarse injustamente. La falta de datos no necesariamente se debe al tamaño del grupo que representa, sino a la metodología de recolección de datos que puede dar ventaja o excluir a ciertos grupos, por ejemplo, recopilación de datos en un solo idioma.
2. El sesgo inherente a los datos.	Aunque el conjunto de datos recopilado sea lo suficientemente grande para representar a cada grupo, los datos de entrenamiento pueden reflejar prejuicios y esto es complejo de eliminar. Se le conoce como legado negativo. Adicionalmente, la selección de los atributos que se utilizarán en el modelo también puede inducir prejuicios.
3. La idoneidad del modelo para describir a cada grupo.	La arquitectura del modelo puede describir mejor a un grupo sobre los otros. Por ejemplo, un modelo lineal puede ser adecuado para describir a un grupo específico, pero no a los demás dentro del conjunto de datos.

Privacidad, explicabilidad y equidad

Una estrategia para reducir la inequidad en los algoritmos de aprendizaje automático es incluir tal inequidad como una restricción o un término de penalización en la minimización de la pérdida de la predicción (penalización por una mala predicción). En el contexto del diseño ético de algoritmos se deben considerar las reglas de protección de datos y protección de la privacidad, aspectos legales, políticas de intercambio de datos, normas y protocolos, así como regulaciones que garanticen que los algoritmos respeten valores de los conjuntos de datos, particularmente para evitar la discriminación o la no inclusión. Para lograrlo, es importante entender a detalle la operación del algoritmo de aprendizaje utilizado y esto es en ocasiones difícil por el nivel de opacidad que presentan, lo que hace verlos como una “caja negra”. Se tiene la creencia de que los modelos más precisos de aprendizaje automático son naturalmente no interpretables y complicados.

En estos modelos de **caja negra** es muy difícil comprender cómo se combinan las variables para llevar a cabo las predicciones. Por el contrario, en modelos interpretables se facilita el entendimiento de la forma en que se realizan las predicciones.

Los humanos crean modelos internos para interpretar su entorno y cada modelo inicia con una hipótesis. La curiosidad impulsa al hombre a intuir que una cosa se relaciona con la otra. Si a partir de ciertas entradas un modelo obtiene las mismas salidas, el modelo es interpretable. Por ejemplo, “si una persona cena *fetuccini* con boloñesa, tendrá problemas para conciliar el sueño”, es una situación interpretable. La **interpretabilidad** implica que es posible determinar la causa y el efecto; se puede definir como el **grado en el que una persona puede comprender la causa de la decisión** o el grado en el que una persona puede predecir consistentemente el resultado de un modelo de aprendizaje automático. Cuanto mayor sea la interpretabilidad de un modelo, más fácil será comprender por qué se han tomado ciertas decisiones o predicciones.

El principio de **explicabilidad** de un algoritmo sostiene que cualquier decisión que se tome debe ser comprensible y accesible para que las personas involucradas en esta decisión puedan refutar los errores observados o los datos incorrectos.

Se explica el fundamento del proceso de la toma de decisiones, revela las fortalezas y debilidades del proceso y da una idea de cómo se puede comportar el algoritmo en el futuro. La explicabilidad se refiere a entender por qué un modelo produce un resultado particular sin necesidad de comprender los aspectos matemáticos del algoritmo.



Modelos éticos

Un modelo ético de aprendizaje debe contar con tres características: **preciso, explicable y justo**.

Imagina un modelo de recomendaciones como el utilizado en Netflix. Un modelo ético proporcionaría al usuario no solo resultados de las recomendaciones, sino también explicaciones para aclarar por qué se recomiendan tales elementos; ayudaría a crear mejores resultados para ellos, así como mejores resultados grupales al exponer los posibles sesgos del algoritmo utilizado.

Imagina que en cada recomendación hecha por el modelo exista un botón que al hacer clic te muestre el motivo por el cual te sugirió tal serie: “El algoritmo encontró que esta serie se ha visto muchas veces en colonias cercanas a la tuya (por el código postal), también la han visto personas con intereses similares a los tuyos y con quienes compartes amigos en Facebook y todos son mexicanos”.

Un usuario cuestionaría el uso del grupo racial al que pertenece para encontrar las recomendaciones, pero para ello, la aplicación podría dar la opción de desactivar ciertas funciones o características asociadas al perfil de usuario (como la raza o grupo étnico) y seguramente mejorarían los resultados grupales a partir de acciones individuales convirtiendo el modelo de caja negra en uno transparente. Un modelo transparente genera resultados que pueden ser explicados y entendidos por los seres humanos.

Modelos éticos

El uso de modelos transparentes está encaminado a clarificar los siguientes aspectos:

La forma en la que el algoritmo entrenó al modelo para tomar las decisiones.

El tipo de información que el modelo consideró para su toma de decisiones.

La forma en la que se ponderaron y trataron los parámetros del algoritmo de entrenamiento.

El tipo de operaciones realizadas durante el entrenamiento.

La inteligencia artificial explicable (XAI, por sus siglas en inglés) es una nueva rama de la inteligencia artificial que intenta desmitificar los modelos de aprendizaje automático, ofreciendo a los usuarios finales, no solo las predicciones, sino además la evidencia de cómo se llegaron a ellas (Barredo, Díaz, Del Ser, Bennetot, Tabik, Barbado, García, Gil, Molina, Benjamins, Chatila y Herrera, 2020).

Modelos éticos

En XAI existen diferentes enfoques para generar modelos explicables:

Concepto / Método	Descripción
SHAP (Shapley Additive Explanations).	Este enfoque tiene como objetivo explicar la predicción de un modelo, midiendo la contribución de cada atributo de los datos a esa predicción (Merrick y Taly, 2020).
LIME (Local Interpretable Model-Agnostic Explanations).	Por lo general, se utiliza con modelos no lineales e intenta linealizar los espacios no lineales, separando el espacio de atributos original en subespacios lineales que puedan utilizarse en modelos lineales explicables (Ribeiro, Singh y Guestrin, 2016).
Importancia de atributos con base en árboles.	Usa la reducción promedio de las impurezas en un árbol (o un bosque de árboles) provocadas por cada atributo de entrada. Según esta metodología, los atributos que separan los nodos más cerca de la parte superior del árbol tendrían más peso al crear la predicción.
Gráficos de dependencia parcial (PDP).	Sintetiza la relación entre las variables de entrada y las predicciones. Se utiliza para visualizar la dependencia de la predicción con las diferentes variables del problema.
Gráficos de esperanza individual condicional (ICE).	Se utiliza para tratar de comprender la predicción de cada observación al simular lo que sucedería si los datos de entrada fueran ligeramente distintos.

Los algoritmos de aprendizaje han demostrado múltiples veces un asombroso poder predictivo debido a su capacidad para aprender relaciones complejas a partir de los datos, sin embargo, la aplicación de modelos en áreas como la medicina, las finanzas y la educación es actualmente complicada, debido a las preocupaciones éticas que rodean el uso de algoritmos como herramientas en la toma de decisiones.

Las personas desconfían del uso de algoritmos de aprendizaje automático y, de alguna manera, tienen razón. Hay dos causas principales: el sesgo y la explicabilidad.

Con el objetivo de crear mejores modelos de aprendizaje, las organizaciones han priorizado la complejidad sobre la explicabilidad y la confiabilidad. En la medida que el mundo se vuelve más dependiente de los algoritmos para tomar una gran cantidad de decisiones, las tecnologías y las empresas deben buscar la forma de explicar cómo un modelo dio tal resultado.

La transparencia es un requisito indispensable para generar confianza y adopción de estos modelos. Una forma de lograrlo es utilizando modelos de familias que se consideran explicables, como los lineales, árboles de decisión, conjuntos de reglas y de decisiones, aditivos generalizados y métodos de razonamiento basados en casos que a menudo proporcionan un equilibrio adecuado entre explicabilidad y desempeño (Anadiotis, 2020).

El uso de modelos explicables puede beneficiar a usuarios (¿por qué se rechazó la solicitud de crédito?), entidades reguladoras (evidencia de que los modelos son justos) y desarrolladores (¿qué tan bien funciona el modelo?).

Principio de responsabilidad de Hans Jonas

Existe evidencia importante de sesgo en los algoritmos de aprendizaje automático, de manera más precisa, en los datos de entrenamiento y de cómo sistemáticamente se discrimina a ciertos grupos o clases de personas. Actualmente, los problemas éticos del uso de algoritmos de aprendizaje automático son abordados cada vez más por la comunidad científica (Ito, 2017; Buolamwini y Gebru, 2018). Con frecuencia, la atención se centra en la tecnología, pero muy poco en las personas que la construyen, mantienen y usan.

Se debe poner especial atención en el rol que toma quien trabaja con estos algoritmos y en los deberes y valores morales que se derivan de este ejercicio en un entorno multinacional, donde existen regulaciones generales de protección de datos.

Es de vital importancia establecer **principios básicos** para el profesional que trabaja con algoritmos de aprendizaje automático, por ejemplo:



a. Estar preparados y ser lo suficientemente honestos para saber cuándo las herramientas y metodologías de aprendizaje automático o inteligencia artificial no pueden por sí solas dar solución a los problemas que enfrentan.

b. Reconocer cuándo sean necesarios otros mecanismos, como acciones sociales o políticas, para dar solución a los problemas como el del sesgo, por citar uno.

c. Comprender que no trabajan solos ni existen independientemente de una comunidad social mayor regida por sus propias reglas políticas, tradiciones, usos y costumbres de donde varias prácticas sociales derivan su significado.

d. Entender que no son instancias de datos distribuidos de forma idéntica e independiente, sino que representan nodos conscientes situados en una red compleja e interconectada de creencias, prácticas legales, sociales, culturales, económicas y morales, donde ellos mismos se pueden ver afectados por los propios algoritmos.

Principio de responsabilidad de Hans Jonas

No se debe olvidar que quienes trabajan en esta área son los agentes morales responsables de la toma de decisiones y el resto del mundo son usuarios morales. ¿Qué derechos deben tener los usuarios morales?, ¿qué obligaciones deben tener los agentes morales hacia sus usuarios?

Para resolver ambos cuestionamientos, se debe tener claro el significado de responsabilidad y conocer la diferencia entre **responsabilidad causal** y **responsabilidad moral**.

La responsabilidad causal implica que las acciones fueron próximas en el tiempo a algún efecto negativo. La forma de referirse a lo anterior es como **causa próxima** (Geistfeld, 2021). Por ejemplo, imagina que por algún motivo alguien sube un algoritmo de clasificación a GitHub utilizado en una aplicación para la contratación de candidatos. Poco tiempo después, otras personas lo descargan y utilizan. El clasificador tiene resultados sesgados hacia el género masculino y, aun así, se puso en producción. La publicación de ese código es causalmente responsable de este resultado. Las leyes deberían determinar si la acción de compartirlo fue la causa inmediata de ese efecto.

La responsabilidad moral, por otro lado, implica culpabilidad. Del caso anterior, la persona que publicó el código es causalmente responsable, pero no es culpable de alguna acción. Asume que en la situación planteada, la persona que compartió la información lo hizo al estar obligado por su jefe, quien lo amenazó de despedirlo en caso de que no lo hiciera. No es posible culpar al individuo de tal acción, pero estrictamente hablando es causalmente responsable (hasta cierto punto) por el daño causado.

La culpabilidad depende del libre albedrío. En la práctica, la determinación de la responsabilidad moral y causal depende de presiones sociales o políticas inherentes al contexto del problema. Cuando el ser humano tiende a mezclar ambos conceptos de responsabilidad cae en confusiones morales.

Principio de responsabilidad de Hans Jonas

Culpar a un algoritmo de sesgo es como culpar a una mesa en la que una persona se ha golpeado el dedo meñique del pie. La mesa no ha decidido estar en ese lugar, la persona es quien eligió sentarse en ella. En el contexto del aprendizaje automático, una persona es quien decide los datos a recolectar, medirlos de cierta forma, agruparlos alrededor de cierto atributo, limpiarlos, estandarizarlos y tal vez reducirlos en dimensión. Es más, una persona es quien decide los modelos a utilizar para después compararlos con un proceso de validación cruzada. La libre elección implica **responsabilidad moral**. Eventualmente, en algún punto, hay una persona tomando una decisión. Si la decisión pudo ser distinta y no la tomó, hay responsabilidad causal; si la cambió, hay culpabilidad moral. No es válido utilizar el pretexto de “caja negra” para escapar de las cuestiones de responsabilidad moral.

En 1979, **Hans Jonas** escribió *El principio de responsabilidad*, donde afirma que todos los sistemas éticos desarrollados se deben actualizar, ya que toman de forma errónea el alcance de las acciones humanas y, por lo tanto, la responsabilidad humana puede definirse de forma estricta. Jonas argumenta que los enfoques tradicionales de la ética están basados en consideraciones utilitarias o deontológicas que se desarrollaron bajo condiciones sociales completamente distintas.

En la era de la información, las causas locales pueden tener efectos globales. El trabajo de una persona utilizando un algoritmo de aprendizaje automático puede afectar a millones de personas alrededor del mundo. Desde la óptica de Jonas, se debe replantear la ética para que funcione como una guía de acción en donde el uso de algoritmos puede afectar las experiencias de potencialmente miles de millones de personas.

Principio de precaución

Durante la década de los 80, Jonas desarrolló aún más las implicaciones éticas de su “principio de responsabilidad” que se convirtió después en el “principio de precaución”. La idea detrás de este principio es, básicamente, “más vale prevenir, que lamentar”.

Aun sin tener claro si alguna actividad o acción provocará algún tipo de daño, ya sea a una persona, a su salud o incluso al medio ambiente, se deben tomar medidas para prevenirlo.

Este principio está motivado mayormente por las consecuencias de las prácticas regulatorias que se tuvieron en el pasado, dado que, con frecuencia, no se contaba con la evidencia científica de una conexión causal entre una actividad o acción y sus posibles daños.

El **principio de precaución** se adoptó en 1992 como parte de la Convención de Río de las Naciones Unidas sobre el desarrollo sustentable y después se incorporó a uno de los tratados fundacionales de la Unión Europea. El principio establece que la falta de certeza no puede ser una base para no proteger la salud humana o el medio ambiente, lo que sugiere una forma diferente y adecuada de abordar la incertidumbre de un futuro impulsado por la tecnología.

Aplicar el principio de precaución en el contexto de la inteligencia artificial ayudaría a equilibrar la discusión de políticas globales, permitiendo a las minorías una mayor influencia en los debates que actualmente están monopolizados por intereses corporativos; convirtiendo la toma de decisiones en un proceso más inclusivo y deliberativo con el objetivo de generar soluciones que reflejen de mejor forma las necesidades de la sociedad.

En esta dirección, hay instituciones que encabezan este trabajo, como el Instituto de Ingenieros Eléctricos y Electrónicos (Chatila y Havens, 2019) y la Escuela de Gobierno Kennedy en Harvard.

Al aplicar el principio de precaución, los órganos reguladores podrían transferir la carga de la responsabilidad a los creadores de los algoritmos. Determinar requisitos de explicabilidad sobre la toma de decisiones de algoritmos puede ayudar a modificar los incentivos, prevenir cajas negras, transparentar decisiones de comerciales, forzar a entidades públicas a trabajar con el sector privado en pro de desarrollos tecnológicos, etc. Con ello, el principio de precaución puede obligar a las empresas y a los gobiernos a atender situaciones como el impacto ambiental.



Principios de la bioética

El diseño de sistemas de decisión basados en aprendizaje automático no es un reto meramente técnico, se requiere además poner atención a los principios bioéticos: **beneficencia**, **no maleficencia**, **autonomía** y **justicia**.

En la medida que se avanza en la inteligencia artificial, los marcos de referencia bioéticos deben adaptarse para abordar los problemas que se pueden plantear a partir de estos sistemas. De la misma forma, el desarrollo de estos sistemas debe modificarse para adoptar principios éticos.

En el contexto de la inteligencia artificial, el principio de **beneficencia** subraya la importancia de promover el bienestar de los individuos y el mundo, preservar la dignidad humana y el sostenimiento del planeta. La **no maleficencia** trata sobre el hecho de no hacer daño primeramente, previniendo las violaciones a la privacidad; segundo, operando en un entorno seguro y, por último, evitando el mal uso de estos algoritmos.

La **autonomía** declara lograr un equilibrio entre el poder de decisión que tiene un individuo y el que se delega a los agentes artificiales, minimizando el riesgo de que un crecimiento de autonomía artificial ponga en peligro la autonomía humana.

Se debe promover la autonomía humana, respecto a la de las máquinas (sistemas), la autonomía debe restringirse y hacerla reversible en caso de que se necesite proteger o restablecer la humana. Por último, el principio de **justicia** aborda las consecuencias en la disparidad de una autonomía que no se encuentra distribuida equitativamente en la sociedad.

El desarrollo de la inteligencia artificial debe promover la justicia y buscar eliminar todo tipo de discriminación, así como ofrecer un acceso equitativo a sus beneficios.



La inteligencia artificial (IA) tiene ya un gran impacto en la sociedad. Hoy, las preguntas claves que se deben hacer son qué, cómo, cuándo y por quién se tendrá el impacto de algún algoritmo o sistema. Como resultado, varias organizaciones han lanzado distintas iniciativas con el fin de establecer principios éticos para la adopción de una IA con mayores beneficios (Montreal Declaration for a Responsible Development of AI, 2017; [ieee.org](https://www.ieee.org), 2020).

Cada iniciativa produce una declaración complementaria de principios, valores o principios para guiar el desarrollo y la adopción de la IA.

El desarrollo y uso de algoritmos de IA tiene el potencial de generar un impacto tanto positivo como negativo en la sociedad: minimizar o ampliar las desigualdades existentes, resolver problemas viejos o provocar nuevos.

Para trazar una ruta que sea socialmente preferida no solo se deben utilizar buenas regulaciones y estándares, sino también crear un marco de principios éticos dentro del cual se definan acciones concretas que permitan pasar de los buenos principios a las buenas prácticas.

Inteligencia artificial débil (ANI)

Hace 70 años, Alan Turing se cuestionó si las máquinas serían capaces de pensar en el futuro. Poco más adelante, a finales de los años 50, John McCarthy creó el término “inteligencia artificial”, que se refería a la simulación de la inteligencia humana hecha por computadoras.

Actualmente, las computadoras son capaces de procesar información y obtener conclusiones mucho más rápido que los humanos, logrando hacer predicciones precisas en distintos escenarios.

Ray Kurzweil, director de ingeniería de Google, predijo que las máquinas lograrían el nivel de la inteligencia humana para el 2029, también dijo que para el 2045 se alcanzaría la singularidad tecnológica, es decir, cuando la inteligencia artificial supere a los humanos (Reedy, 2017).

En ese momento existirá una separación en la inteligencia artificial como la conocemos ahora, llamada también inteligencia artificial débil (ANI), y su estado futuro: la inteligencia artificial general (AGI), que permite resolver cualquier tipo de problema.

La inteligencia artificial débil es aquella donde la **tecnología supera al humano en una tarea específica** y se centra en un subconjunto de habilidades cognitivas.

Actualmente existen varios ejemplos de este tipo de inteligencia artificial:

1. Asistentes personales: Siri, Alexa y Cortana.
2. Automóviles autónomos.
3. Herramientas de etiquetado facial en fotografías digitales.
4. El algoritmo de Google que determina, en función de cierta calificación, el sitio que debe aparecer al principio de los resultados de una búsqueda.
5. Sistemas que recomiendan el tipo de producto a comprar con base en el historial de navegación.
6. Filtros de correo no deseado que permiten tener un buzón libre de *spam*.



Inteligencia artificial débil (ANI)

De los ejemplos anteriores, se puede identificar que la ANI se enfoca en un solo tipo de tarea, ya sea conducir un automóvil, jugar ajedrez o analizar datos de navegación para recomendar productos. De la misma manera, estos tipos de sistemas extraen información de un conjunto de datos específico, por lo que no es posible utilizarlos para resolver un problema diferente para los que fueron originalmente diseñados, pues operan dentro de un rango predeterminado y predefinido, aunque pareciera mucho más complejo. A pesar del adjetivo “débil”, este tipo de inteligencia artificial ofrece una gran habilidad y capacidad de interacción con los humanos y de procesamiento de lenguaje. El adjetivo se debe a que los sistemas diseñados se encuentran aún muy lejos de tener una inteligencia similar a la humana. Carecen de conciencia, autoconocimiento e inteligencia genuina, por lo que no son capaces de pensar por sí mismos. Por ejemplo, la asistente Siri no es propiamente una máquina consciente que responda a las solicitudes que se le hacen. Lo que es capaz de hacer y para lo que se diseñó es procesar lenguaje natural, es decir, ejecutar una búsqueda en un motor de búsqueda y presentar los resultados que se obtienen de esa acción.

Esto explica por qué cuando se le plantean preguntas abstractas sobre el significado de la vida o la forma de resolver un problema personal se obtienen respuestas sin sentido o enlaces de Internet que hablen sobre el tema. Por el contrario, si se le pregunta por el clima en la ciudad, da una respuesta precisa; esto muestra el rango de inteligencia con la que se diseñó.

Todo ser humano tiene la capacidad de evaluar su entorno, es decir, es sensible y tiene respuestas impulsadas por las emociones en ciertas situaciones. La inteligencia artificial que hoy existe no tiene la fluidez ni la flexibilidad para pensar y responder como el ser humano. Aun cuando existen ejemplos de tareas complejas como conducir un automóvil, la inteligencia artificial sigue siendo débil, ya que un automóvil autónomo está compuesto por múltiples subsistemas débiles para lograr su objetivo.

La ANI tiene múltiples beneficios y es el resultado de grandes avances científicos, de innovación y de la aplicación de la inteligencia humana. **Estos sistemas son capaces de procesar gran cantidad de información y completar tareas a un ritmo mayor que los humanos, lo que permite mejorar la productividad, la eficiencia y la calidad de vida.** Por ejemplo, sistemas como Watson de IBM son capaces de aprovechar la ANI para ayudar a médicos a tomar decisiones con base en datos, logrando que la atención sea mejor, más rápida y segura. Además, la ANI ha facilitado la automatización de tareas aburridas, rutinarias y simples en la vida del hombre, desde pedir una pizza hasta revisar una gran cantidad de datos, con el fin de proponer algún tipo de acción como resultado.

Inteligencia artificial débil (ANI)

Actualmente, varias compañías apuestan por la investigación y mejora de sistemas de ANI para mejorar la eficiencia operativa, reducir costos y automatizar tareas. Algunas de las **limitantes o barreras de la ANI** son las siguientes:

a. Se requiere de una gran cantidad de datos de calidad para obtener resultados precisos y no necesariamente todos los ambientes o escenarios cubren esta necesidad.

b. La curva de aprendizaje para implementar e institucionalizar la IA dentro de una compañía puede ser ascendente. Se debe invertir en la capacitación de las personas en nuevas tecnologías, así como adaptar sus procesos.

c. Si por algún motivo una tarea llega a sufrir cambios, la efectividad de un sistema ANI disminuye, ya que se diseñó para un propósito específico y debe actualizarse.

d. En ciertos escenarios, reemplazar a humanos por máquinas que procesan reglas puede generar una frustración mayor para los usuarios que prefieren un servicio personalizado y con interacción humana, lo que puede reducir la satisfacción del cliente.

Inteligencia artificial débil (ANI)

Los **dilemas morales** a los que se enfrenta la IA débil son múltiples, por ejemplo:

Número	Descripción
1	Desigualdad económica y laboral: un mayor uso de la tecnología puede desplazar puestos laborales, así como generar la necesidad de mayores conocimientos técnicos y capacitación.
2	Influenciar en el comportamiento humano: existen aplicaciones que usan algoritmos para provocar adicción en el uso de estas.
3	Sesgo en los datos de entrenamiento de algoritmos para contratación de personal o para determinar culpabilidad en ciertos crímenes.
4	Noticias falsas: actualmente proliferan las falsificaciones profundas, por ejemplo, una técnica que usa IA para sobreponer imágenes, audio y videos de otras personas sobre una en particular, creando una falsa impresión de los audios y medios originales.
5	Privacidad y seguridad en los datos: el riesgo de utilizar IA en los datos personales es enorme, incluso con las regulaciones existentes.

Inteligencia artificial general (AGI)

El concepto de inteligencia artificial general (AGI) se utiliza para referirse a aquellas **máquinas que muestran inteligencia humana**, son sistemas que pueden procesar, de forma exitosa, cualquier tipo de tarea que un humano pueda realizar.

Es el tipo de sistemas como los que se muestran en las películas como el *Hombre Bicentenario* o *Her*, donde se ve la interacción humana con máquinas y sistemas operativos que son conscientes, sensibles e impulsados por las emociones y autoconciencia.

Son máquinas capaces de procesar una gran cantidad de datos a velocidades que un humano no puede y tienen la habilidad de pensar de forma abstracta, generar estrategias y aprovechar pensamientos y recuerdos para tomar decisiones o generar ideas creativas.

El objetivo de la AGI es precisamente replicar lo anterior. Se espera que los sistemas diseñados con AGI sean capaces de razonar, resolver problemas, planificar, emitir juicios bajo incertidumbre, aprender, integrar conocimientos previos, innovar, imaginar y crear. Incluso con todo lo anterior, para que las máquinas puedan realmente integrar una inteligencia como la humana, deberán ser capaces de experimentar la conciencia.

Recientemente, este tipo de IA recibió una inversión importante para desarrollar tecnología con el fin de tener aplicaciones AGI (Brockman, 2019).

La AGI permite que una máquina sea capaz de aplicar conocimientos y habilidades en diferentes contextos, tal como los seres humanos, permitiendo mejorar las oportunidades de aprendizaje y resolución de problemas. El desafío se centra en pasar de ANI a AGI en áreas como la visión computacional o el procesamiento de lenguaje natural. Para ello se requiere incrementar la capacidad de cómputo con el fin de realizar una mayor cantidad de cálculos.

Inteligencia artificial general (AGI)

Actualmente, una de las áreas de desarrollo dentro de la AGI se llama ***whole brain emulation*** y su intención es emular al cerebro humano (Oliveira, 2019). El objetivo es transferir la memoria y el estado mental del cerebro a una computadora, cuya arquitectura es similar a la del humano en el sentido de las conexiones hechas por medio de redes neuronales y que permite el fortalecimiento de las conexiones cuando la acción que se ejecuta es la correcta.

Para que la AGI sea equiparable con la inteligencia humana, debe ser capaz de transferir el aprendizaje de un entorno o contexto a otro, utilizar el sentido común, trabajar en colaboración con humanos/máquinas y tener conciencia.

¿Cómo saber que se ha logrado desarrollar sistemas AGI? Además de la prueba de Turing, donde una máquina contrasta sus habilidades conversacionales con un humano, Steve Wozniak, cofundador de Apple, sugiere la prueba del café, donde una máquina entra a una casa, encuentra la cocina y prepara una taza de café (Zerega, 2017).

En la ruta de AGI, los avances en aprendizaje automático y aprendizaje profundo sugieren ya una transición suave de ANI a AGI, donde hay sistemas que toman decisiones sin tener instrucciones explícitas de cómo hacerlo, ya que las redes neuronales pueden desarrollar tanto procesos de entrenamiento como de inferencia.

Inteligencia artificial general (AGI)

Como resultado de conferencias en AGI, se ha llegado a la conclusión de que una plataforma AGI requiere de razonamientos **deductivo**, **inductivo** y **abductivo**.

Tipo	Descripción
Deductivo	El razonamiento inicia con el planteamiento de una hipótesis general y examina las posibilidades de llegar a una conclusión lógica específica. La inferencia deductiva genera la predicción de las consecuencias a partir de una teoría, esto es, se predicen las observaciones que deberían ser, en caso de que la teoría fuera correcta.
Inductivo	Realiza generalizaciones a partir de observaciones específicas. La inferencia inductiva va de lo particular a lo general. Se hacen observaciones de las que se obtiene un patrón para realizar generalizaciones e inferir una explicación o teoría.
Abductivo	El razonamiento abductivo comienza con un conjunto incompleto de observaciones de las que se deriva la explicación más probable para ese grupo de observaciones. Formula y prueba hipótesis usando la mejor información disponible.

Inteligencia artificial general (AGI)

Aunque hay un camino muy largo por recorrer antes de llegar a la inteligencia artificial general, los avances en IA están dándose a pasos agigantados y a una gran velocidad.

La inteligencia artificial promete ser capaz de realizar múltiples tareas, recordar y memorizar la información de forma perfecta, funcionar continuamente sin afectaciones ni interrupciones, realizar una gran cantidad de cálculos a velocidades récord, examinar datos y documentos extensos, así como tomar decisiones imparciales.

En la medida que la IA reemplaza puestos de trabajo, se da un gran debate sobre ética y sobre si los gobiernos deberían intervenir para monitorear y regular su uso y crecimiento, ya que es muy alto el riesgo de que la IA podría transformar las relaciones humanas, aumentar la discriminación, invadir la privacidad personal e incluso plantear amenazas a la seguridad, al permitir el uso de armas autónomas.

Roles Humanos → Responsabilidades IA

•1. Rol: **Desarrollador** (Developer)

- Responsabilidad:** Se encarga de mitigar y controlar los **sesgos en los datos de entrenamiento y la arquitectura del modelo**.

- Explicación:** Quien programa la IA es responsable de que los datos con los que el algoritmo aprende sean limpios, éticos y variados, asegurando que el diseño técnico del modelo no perpetúe discriminaciones o errores estructurales.

•2. Rol: **Operador** (Operator)

- Responsabilidad:** Está a cargo de la **configuración, monitoreo y casos de uso del sistema**.

- Explicación:** Es el puente técnico o administrativo que implementa la IA en un entorno real. Su deber es vigilar que el sistema funcione correctamente en el día a día, ajustar los parámetros necesarios y garantizar que se use exclusivamente para los fines autorizados.

•3. Rol: **Usuario Final** (End User)

- Responsabilidad:** Le corresponde el **uso apropiado y la verificación de los resultados generados**.

- Explicación:** La persona que finalmente consume o interactúa con las respuestas de la IA no debe confiar ciegamente en ella. Su obligación es aplicar el pensamiento crítico para validar que la información recibida sea correcta y utilizar la herramienta de manera ética y responsable.

En resumen: La IA no opera en un vacío ético; desde que se crea hasta que se usa, siempre hay un ser humano responsable de su correcto funcionamiento.

Base legal para recolección de datos

•1. Informar al ciudadano

- Los ciudadanos deben conocer qué datos se recolectan y con qué propósito.
- *Explicación:* El primer paso es la transparencia. No se pueden recolectar datos a escondidas; la población tiene el derecho normativo de saber exactamente qué información suya se está registrando y para qué se va a utilizar.

•2. Obtener permiso legal

- Se requiere autorización explícita antes de instalar sensores y cámaras.
- *Explicación:* No basta con avisar; se debe contar con el respaldo y la autorización legal o regulatoria explícita exigida por la ley vigente antes de colocar cualquier dispositivo de captura de datos.

•3. Implementar sensores

- Solo después de cumplir requisitos legales se puede proceder con la instalación.
- *Explicación:* Este es el último paso. La infraestructura física y tecnológica (como cámaras o sensores) solo se despliega una vez que los pasos 1 y 2 han sido rigurosamente validados y aprobados.

Principio fundamental: La conciencia ciudadana y el marco legal deben preceder a cualquier instalación de tecnología de vigilancia.

Control de Acceso: 3 reglas clave

•1. ¿Quién? (Autorización)

- Define roles y permisos específicos para cada usuario.
- Explicación:* No todos los usuarios deben tener acceso a toda la información. Esta regla exige delimitar de forma estricta los privilegios de cada persona en el sistema, asegurando que cada perfil solo pueda ver o modificar lo estrictamente necesario para su trabajo.

•2. ¿Cuánto tiempo? (Retención)

- Establece períodos de retención y expiración de datos.
- Explicación:* La información no debe almacenarse de manera indefinida. Se deben programar fechas de caducidad y políticas de borrado seguro para garantizar que los datos se eliminen una vez que hayan cumplido con el propósito original para el cual fueron recolectados.

•3. Auditoría (Trazabilidad)

- Registra todas las acciones para trazabilidad completa.
- Explicación:* Consiste en mantener un historial o bitácora ("log") detallado de cada movimiento en el sistema. Esto permite saber con precisión quién, cuándo y qué se hizo con los datos, facilitando revisiones de seguridad o investigaciones ante cualquier anomalía.

Estas tres reglas forman el pilar de la gobernanza de datos, garantizando que el acceso sea **restringido** (¿Quién?), **temporal** (¿Cuánto tiempo?) y **supervisado** (Auditoría).

Límites de Retención e Implicaciones GDPR (Reglamento General de Protección de Datos)

•Períodos de Retención

- Datos transaccionales: 6 años** → Información sobre compras, facturas o movimientos financieros que legalmente se deben guardar por un período largo debido a auditorías fiscales o comerciales.
- Logs de acceso: 90 días** → Los registros de quién entró al sistema (vistos en la lámina anterior como auditoría) tienen una vida útil más corta, ideal para detectar incidentes recientes sin acumular basura digital.
- Datos de marketing: 2 años** → Historiales de preferencias o campañas publicitarias; si el usuario no interactúa en este tiempo, los datos deben ser descartados.
- Backups: 30 días** → Las copias de seguridad de respaldo se van sobrescribiendo mensualmente para garantizar la disponibilidad del sistema sin almacenar datos viejos innecesariamente.

•Cumplimiento GDPR

- Art. 17 Derecho al olvido** → Obliga a las organizaciones a eliminar de forma definitiva todos los datos de un ciudadano si este así lo solicita.
- Art. 20 Portabilidad de datos** → El derecho del usuario a pedir que se le entreguen sus datos en un formato estructurado y común para poderse los llevar a otra plataforma.
- Art. 5 Minimización de datos** → Establece que solo se deben recolectar y conservar los datos estrictamente necesarios para la finalidad del servicio.
- Art. 30 Registro de actividades** → Exige a las empresas llevar una bitácora interna detallada de cómo, por qué y quién trata los datos personales de los usuarios.

Esto nos ayuda con el concepto de "retención" con tiempos específicos para cada tipo de archivo, vinculándolo directamente con los artículos legales que protegen los derechos de privacidad de los ciudadanos.

Agenda 2030

La Asamblea General de la ONU adoptó hoy la Agenda 2030 para el Desarrollo Sostenible, un plan de acción a favor de las personas, el planeta y la prosperidad, que también tiene la intención de fortalecer la paz universal y el acceso a la justicia.

Los Estados miembros de la Naciones Unidas aprobaron una resolución en la que reconocen que el mayor desafío del mundo actual es la erradicación de la pobreza y afirman que sin lograrla no puede haber desarrollo sostenible.

La Agenda plantea 17 Objetivos con 169 metas de carácter integrado e indivisible que abarcan las esferas económica, social y ambiental.

La nueva estrategia regirá los programas de desarrollo mundiales durante los próximos 15 años. Al adoptarla, los Estados se comprometieron a movilizar los medios necesarios para su implementación mediante alianzas centradas especialmente en las necesidades de los más pobres y vulnerables. La Agenda implica un compromiso común y universal, no obstante, puesto que cada país enfrenta retos específicos en su búsqueda del desarrollo sostenible, los Estados tienen soberanía plena sobre su riqueza, recursos y actividad económica, y cada uno fijará sus propias metas nacionales, apegándose a los Objetivos de Desarrollo Sostenible (ODS), dispone el texto aprobado por la Asamblea General.



Producido en colaboración con TROLLBÄCK + COMPANY | TheGlobalGoal@trollback.com | +1 212 526 1010
Para cualquier duda sobre la utilización, por favor comuníquese con: dpcampaign@un.org

Agenda 2030

*«Estamos resueltos a poner fin a la pobreza y el hambre en todo el mundo de aquí a 2030, a combatir las desigualdades dentro de los países y entre ellos, a construir sociedades pacíficas, justas e inclusivas, a proteger los derechos humanos y promover la igualdad entre los géneros y el empoderamiento de las **mujeres** y las **niñas**, y a garantizar una protección duradera del planeta y sus recursos naturales», señalaron los Estados en la resolución.*



Producido en colaboración con TROLLBACK + COMPANY | TheGlobalGoal@trollback.com | +1.212.526.1010
Para cualquier duda sobre la utilización, por favor comuníquese con: dpcampaign@un.org

Agenda 2030

El Puente entre la Agenda 2030 y la IA

La Agenda 2030 tiene **17 Objetivos de Desarrollo Sostenible (ODS)**. Para los científicos de la computación, la IA debe entenderse aquí como un **habilitador tecnológico**. No es una solución mágica, sino una herramienta de optimización masiva. Podemos agrupar el impacto de la IA en los ODS en tres grandes dimensiones:

A. Dimensión Ambiental (La IA como guardiana del planeta)

•**ODS 13: Acción por el clima & ODS 15: Vida de ecosistemas terrestres.** *¿Cómo ayuda la IA?* Mediante modelos de visión por computadora y redes neuronales, podemos procesar imágenes satelitales en tiempo real para predecir incendios forestales, rastrear la deforestación ilegal en el Amazonas o modelar el derretimiento de los glaciares con gemelos digitales (*Digital Twins*).

•**ODS 7: Energía asequible y no contaminante.**

- *¿Cómo ayuda la IA?* Los algoritmos de aprendizaje profundo optimizan las redes eléctricas inteligentes (*Smart Grids*), prediciendo cuándo habrá más viento o sol para almacenar la energía renovable de manera eficiente y reducir el desperdicio.



Agenda 2030

El Puente entre la Agenda 2030 y la IA

La Agenda 2030 tiene **17 Objetivos de Desarrollo Sostenible (ODS)**. Para los científicos de la computación, la IA debe entenderse aquí como un **habilitador tecnológico**. No es una solución mágica, sino una herramienta de optimización masiva. Podemos agrupar el impacto de la IA en los ODS en tres grandes dimensiones:

B. Dimensión Social (IA para reducir brechas)

•ODS 3: Salud y bienestar.

- *¿Cómo ayuda la IA?* Modelos predictivos que detectan brotes epidemiológicos antes de que se expandan, o algoritmos de visión artificial que diagnostican radiografías en comunidades rurales donde no hay médicos especialistas.

•ODS 4: Educación de calidad.

- *¿Cómo ayuda la IA?* Sistemas de tutoría inteligente que adaptan el ritmo de aprendizaje para alumnos que se quedaron rezagados (¡justo lo que necesitan los chicos post-pandemia!).



Agenda 2030

El Puente entre la Agenda 2030 y la IA

La Agenda 2030 tiene **17 Objetivos de Desarrollo Sostenible (ODS)**. Para los científicos de la computación, la IA debe entenderse aquí como un **habilitador tecnológico**. No es una solución mágica, sino una herramienta de optimización masiva. Podemos agrupar el impacto de la IA en los ODS en tres grandes dimensiones:

C. Dimensión Económica e Institucional

•ODS 9: Industria, innovación e infraestructura.

- Optimización de cadenas de suministro, reducción de desperdicios en fábricas y diseño de nuevos materiales más ligeros y ecológicos mediante IA generativa.



Agenda 2030

La paradoja ética: El lado oscuro de la IA frente a los ODS

La IA ayuda a cumplir los ODS, pero **su desarrollo actual también los sabotea**. Esto les romperá la cabeza:

- **El ODS 13 (Acción por el clima) vs. La Huella de Carbono de la IA:** Entrenar un solo modelo de lenguaje grande (como GPT-4 o modelos de IA generativa masivos) consume tanta electricidad y agua para enfriar los servidores que equivale a las emisiones de carbono de varios autos durante toda su vida útil. *¿Es sostenible destruir el clima local para entrenar una IA que promete salvar el clima global? Y si cada empresa requiere una ¿cuál será el impacto real de contaminación?*
- **El ODS 10 (Reducción de las desigualdades) vs. El Monopolio Tecnológico:** El poder de la IA está concentrado en 4 o 5 empresas gigantes del norte global. Si los países en desarrollo solo "consumimos" su IA, estamos aumentando la brecha de dependencia tecnológica, lo cual perpetúa la desigualdad.



Agenda 2030

El Discurso del 2015: La IA y la Agenda 2030 como la "Mesa Limpia"

En 2015, el gobierno de Peña Nieto venía impulsando con mucha fuerza las reformas estructurales y la **Estrategia Digital Nacional (EDN)**. En la ONU, el discurso oficial se alineó con la narrativa de Silicon Valley y los organismos multilaterales (OCDE, Foro Económico Mundial):

- **La promesa de la neutralidad y la eficiencia:** Se vendió la idea de que los problemas históricos de México (pobreza, corrupción, ineficiencia en el campo, servicios de salud colapsados) ya no se resolverían con la vieja burocracia, sino a través de datos, algoritmos y automatización.

- **El sesgo del "Gobierno Abierto":** Peña Nieto promovió en esa cumbre el concepto de "gobiernos abiertos" basados en datos masivos. La narrativa implícita era: *"Si metemos datos a una computadora, la máquina tomará decisiones óptimas e incorruptibles"*. Se ignoró por completo que los algoritmos heredan los sesgos históricos, la discriminación y la desigualdad del entorno de donde salen esos datos (justo lo que vieron en el laboratorio de Fairlearn).

Se proyectó un México hipermoderno que, mediante la tecnología, alcanzaría mágicamente las metas de desarrollo sostenible para el 2030, firmando en septiembre el acuerdo junto a otras 192 naciones bajo un manto de optimismo puramente técnico, en la Cumbre de la ONU en Nueva York y la asumió formalmente como un "Compromiso de Estado".

En ese momento, el discurso internacional (y el de México) vendió la tecnología y los sistemas inteligentes no como una herramienta más, sino como una **panacea** (la solución mágica para todos los males).

Agenda 2030

El Aterrizaje Forzoso: ¿Qué pasó después en México?

Como suele pasar en nuestra historia política, del papel a la práctica hay una brecha enorme. El plan original empezó a fragmentarse por varias razones que hoy sirven como un gran caso de estudio ético:

A. La llegada del nuevo gobierno y el cambio de prioridades (La ruptura institucional)

Con el cambio de administración en 2018, la tecnología de punta e iniciativas como la Estrategia Digital Nacional dejaron de ser la prioridad central del presupuesto. El enfoque gubernamental viró hacia programas sociales de entrega directa de recursos y megaproyectos de infraestructura física.

Muchos de los planes para integrar IA en el sector público se congelaron o se delegaron a esfuerzos de la sociedad civil y la academia (como la coalición *IA2030Mx*).

La tecnología en el sector público depende enteramente de la voluntad política del gobernante en turno, no de su eficiencia técnica.

B. El "Legado Negativo" y los datos sesgados en el contexto mexicano

Cuando se intentó plantear el uso de algoritmos para políticas públicas en México, se topó con pared debido al diseño de los datos:

- El sesgo de exclusión:** Si el gobierno diseña un algoritmo para asignar apoyos agrícolas o becas usando solicitudes en línea o aplicaciones móviles, automáticamente deja fuera a las comunidades rurales sin conectividad. La IA "resuelve" el problema optimizando la entrega solo para el sector que ya está digitalizado.
- El sesgo cognitivo e histórico:** Si entrenas un modelo para predecir la delincuencia o el éxito académico en México con datos históricos, el algoritmo aprenderá y replicará el racismo, el clasismo y la desigualdad estructural del país, penalizando a los sectores tradicionalmente vulnerables bajo una máscara de "objetividad matemática".

Agenda 2030

El Sueño de 2015 (Peña Nieto / ONU): *"Firmamos la Agenda 2030. Usaremos Inteligencia Artificial y datos para erradicar la pobreza, optimizar los recursos y tomar decisiones perfectas sin intervención humana corruptible".*

La Realidad Actual: Austeridad republicana, falta de infraestructura tecnológica pública, bases de datos gubernamentales desactualizadas o fragmentadas, y un enfoque político centrado en lo humano y lo territorial, no en los algoritmos.

Preguntas clave :

1. Al ver que el presupuesto y las políticas actuales en México no priorizan el desarrollo de software de vanguardia para el gobierno, ¿la IA sigue siendo una panacea o terminó siendo una promesa de discurso internacional?
2. Si les tocara a ustedes (como científicos de la UNAM) diseñar una IA para cumplir el ODS de "Hambre Cero" en el México actual, ¿cómo se asegurarían de no generar exclusión tecnológica en las comunidades que ni siquiera tienen luz o internet estable?

Pensando en estas preguntas nos ayudará a entender que un científico o ingeniero en México no puede programar ignorando el contexto sociopolítico del país.

Agenda 2030

El Antídoto a la Soberbia Intelectual: Desarrollar la Humildad Epistémica

En las carreras de tecnología existe un monstruo silencioso: **el mito del programador dios o el genio solitario**, ya que tienden a refugiarse en sus pantallas y a medir su valor por cuántas líneas de código dominan o qué tan rápido resuelven un problema. Esto genera arrogancia, vanidad falsa y una soberbia que destruye los equipos de trabajo.

Humildad Epistémica:

La humildad no es "sentirse menos" ni agachar la cabeza; **la humildad es el reconocimiento preciso de los propios límites.**

- En computación, significa entender que nadie, absolutamente nadie, puede dominar todo el ecosistema tecnológico solo.
- El software moderno es tan complejo que requiere, por definición, un esfuerzo colectivo. La soberbia es un "bug" de diseño que rompe la arquitectura del equipo.

• **Soberbia vs. Colaboración:** El arrogante cree que su código es perfecto y no acepta críticas (bloquea el *code review*). El humilde entiende que el software siempre es perfectible y que la crítica de un compañero mejora el producto final.

• **La trampa de la vanidad falsa:** El miedo a parecer "tontos" o "ignorantes" hace que muchos alumnos no pregunten sus dudas, hundiéndose solos. Hay que comprender que en ciencias, decir "*no sé, ¿me explicas?*" es un acto de valentía intelectual, no de debilidad.

• Las grandes empresas tecnológicas (e incluso las *startups*) han modificado sus procesos de reclutamiento por una razón matemática: **un sabelotodo arrogante cuesta más dinero del que produce.**

"Estimados alumnos, el código más brillante del mundo no sirve de nada si nadie puede trabajar con ustedes. La soberbia técnica los aísla; la humildad compartida crea tecnología de impacto real."

Agenda 2030

Humildad Epistémica:

A. Las entrevistas "No Asshole" (Sin patanes) y las Soft Skills

Hoy en día, las evaluaciones técnicas en empresas serias incluyen filtros de habilidades blandas (*soft skills*). Puedes tener un puntaje perfecto en código, pero si en la entrevista de diseño de sistemas te muestras soberbio, descartas las opiniones del entrevistador o finges saber algo que no sabes (vanidad falsa), te ponen sello de **"No Contratable"**.

- **La razón de negocio:** Un empleado arrogante rompe la comunicación, causa rotación de personal (la gente renuncia para no trabajar con él) y atrasa los despliegues de software. La soberbia cuesta millones en pérdida de productividad.

B. El concepto de "seniority" real

Los profesionales recién egresados confunden ser "Senior" con saberse de memoria todas las librerías de Python. Hay que comprender que en la industria:

- **Junior:** Necesita ayuda para resolver problemas.
- **Mid-level:** Resuelve problemas solo.
- **Senior:** Ayuda a otros a resolver problemas y hace crecer a su equipo. Un desarrollador senior que no tiene la **humildad** de enseñar o colaborar, en realidad se comporta como un junior con experiencia. La soberbia estanca el crecimiento salarial y profesional.



Agenda 2030

El reto colectivo de las Mujeres en la tecnología

Es un elefante en el aula que requiere toda su sabiduría. La Facultad de Ciencias e Ingeniería sigue siendo, estadísticamente, un territorio predominantemente masculino. Históricamente, a las mujeres se les ha colocado en una posición de "excepción" dentro de estos sistemas, lo que lamentablemente detona dinámicas de rivalidad o territorialidad inconsciente en lugar de sororidad. Vamos a desmenuzar por qué ocurre esto y cómo reconfigurar el chip de sus alumnas (y alumnos):

El Diagnóstico: ¿Por qué los hombres se apoyan por amistad y las mujeres son territoriales?

Esto tiene una explicación sociológica profunda que a las chicas les ayuda mucho entender para quitarse culpas:

- **La trampa de la "cuota única":** En sistemas patriarcales o muy masculinizados, se ha vendido la falsa idea implícita de que *"solo hay lugar para una mujer brillante en la mesa"*. Al sentir que los espacios son escasos, las mujeres a veces ven a otra mujer no como una aliada, sino como la competencia directa por ese único espacio disponible. Por eso apoyan solo a "la que más sabe", como una forma de validar que merece estar ahí, pero marcan distancia.

- **El pacto patriarcal informal:** Los hombres llevan siglos ensayando la socialización en espacios públicos y de poder (clubes, deportes, negocios). Saben separar la amistad o la incompetencia del apoyo mutuo (*"es mi amigo, lo ayudo aunque no sepa programar"*). Las mujeres apenas están construyendo esas redes de confianza masiva en el sector tecnológico.

Agenda 2030

¿Cómo sobrevivir y transicionar a un esquema colaborativo?

Para las mujeres en tecnología, debe ser de **estrategia colectiva y supervivencia inteligente**:

1.Romper la ilusión de escasez: El mercado tecnológico necesita desesperadamente científicas de datos e ingenieras. Ya no hay un solo lugar en la mesa; hay que construir mesas nuevas. Si una mujer avanza, abre la puerta para las demás, no les quita el puesto.

2.Cambiar la métrica de validación: En lugar de competir por quién es la "reina del lugar", hay que enseñarles el valor de las **redes de mentoría**. Las mujeres más avanzadas de los últimos semestres deben cobijar a las de primero, compartiendo recursos, apuntes y contención emocional.

3.El apoyo por empatía, no solo por mérito: Hay que invitar a las mujeres a romper el sesgo de la perfección. Apoyar a otra compañera aunque le esté costando trabajo la materia es vital. La solidaridad de género en la ciencia no debe condicionarse a que la otra sea una genio; basta con que sea una compañera intentando sobrevivir al mismo sistema.

Agenda 2030

¿Cómo sobrevivir y transicionar a un esquema colaborativo?

La competencia entre mujeres es un fenómeno real, pero frecuentemente malinterpretado por los hombres como "simple envidia entre mujeres". No lo es. Tiene causas estructurales muy claras:

A. El "Síndrome de la Abeja Reina" (*Queen Bee Syndrome*)

Este término científico (coñado en los años 70 en la Universidad de Michigan) describe precisamente este comportamiento de competencia. Ocurre cuando una mujer alcanza una posición de autoridad o éxito en un entorno dominado por hombres, y en lugar de apoyar a otras mujeres, se distancia de ellas o se vuelve hipercrítica con sus subordinadas.

- **¿Por qué pasa?** No es por maldad innata. Esa mujer tuvo que asimilarse a la cultura masculina, esforzarse el triple y adoptar conductas agresivas para ser respetada. Inconscientemente piensa: *"A mí me costó sangre llegar aquí, si a ellas se la pongo fácil, se desvalora mi propio esfuerzo"*.

- **La validación del mérito:** Las mujeres apoyan solo a "la que más sabe". Esto pasa porque la mujer siente que su propia posición es tan frágil que si apoya a una compañera que comete un error, el sistema de hombres dirá: *"Ya ven, las mujeres no sirven para esto"*. Apoyar solo a la excelente es una armadura de protección.

B. El "Pacto entre Caballeros" vs. El aislamiento de la mujer

Los hombres se apoyan por amistad (aunque el amigo sea incompetente) porque operan bajo una lógica de **red de protección mutua** que han heredado por generaciones. Sienten el espacio de la ingeniería como *suyo*, así que un error de un amigo es "un tropiezo individual". En cambio, la mujer en la ciencia suele operar bajo el estrés de representar a todo su género. Si una mujer falla, el prejuicio golpea a todas. Eso genera que sean territoriales y se fiscalicen entre ellas de manera implacable.

Agenda 2030

Crear profesionales éticos e integrales

La Agenda 2030 habla de sostenibilidad, y no hay nada más insostenible en una empresa que un equipo quebrado por la soberbia intelectual o la división interna. Un científico de datos que no sabe comunicarse con humildad o una ingeniera que sabotea a sus compañeras jamás podrán diseñar tecnología que realmente ayude a cumplir objetivos sociales o ambientales.

- AI of Things. (2021). *Coca-Cola's use of AI to stay at the top of the drinks market*. Recuperado de <https://business.blogthinkbig.com/coca-colas-use-of-ai-to-stay-at-the-top-of-the-drinks-market/>
- Burkov, A. (2020). *Machine Learning Engineering*. Canadá: True Positive Incorporated.
- Fernández, R. (2009). El teorema de Bayes y su utilización en la interpretación de las pruebas diagnósticas en el laboratorio clínico. *Revista Cubana de Investigaciones Biomédicas*, 28. Recuperado de http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0864-03002009000300013
- González, L. (2018). *Tipos de aprendizaje automático*. Recuperado de <https://bit.ly/36tVfYn>
- Heras, J. (2020). *Las 7 Fases del Proceso de Machine Learning*. Recuperado de <https://bit.ly/3wBv0d9>
- Heras, J. (2020). *Redes Neuronales Generativas Adversarias (GANs)*. Recuperado de <https://bit.ly/2T1VRkQ>
- Leone, G. (2017). *The Best Explanation: Machine Learning vs Deep Learning*. Recuperado de <https://bit.ly/3hJ1BYW>
- NBA. (s.f.). Yao Ming Stats. Recuperado de <https://www.basketball-reference.com/players/m/mingya01.html>
- QuestionPro. (s.f.). ¿Qué es el coeficiente de correlación de Pearson? Recuperado de <https://bit.ly/2TSOWzn>
- Ramírez, F. (2018). *Historia de la IA: Frank Rosenblatt y el Mark I Perceptrón, el primer ordenador fabricado específicamente para crear redes neuronales en 1957*. Recuperado de <https://bit.ly/36jUOQh>
- Fernández, R. (2009). El teorema de Bayes y su utilización en la interpretación de las pruebas diagnósticas en el laboratorio clínico. *Revista Cubana de Investigaciones Biomédicas*, 28. Recuperado de http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0864-03002009000300013
- Taulli, T. (2019). *Artificial Intelligence Basics: A Non-Technical Introduction*. Estados Unidos: Apress.
- Torres, J. (2018). *Deep Learning – Introducción práctica con Keras*. Recuperado de <https://bit.ly/3edNpg2>
- Veen, F. (2017). *Neural Network Zoo*. Recuperado de <https://www.asimovinstitute.org/?s=graphs>
- Castelvechi, D. (2016). ¿Podemos abrir la caja negra de la inteligencia artificial? Recuperado de <https://www.scientificamerican.com/espanol/noticias/podemos-abrir-la-caja-negra-de-la-inteligencia-artificial/>
- IBM. (2020). *IBM Skills Academy. Lecture 1 - Artificial Intelligence Landscape Notes*. Recuperado de <https://skills-academy.comprehend.ibm.com/>
- Kaplan, J. (2016). *Inteligencia Artificial: Lo que todo el mundo debe saber*. España: Teell Editorial.
- Koyanagi K. (2021). *Singapore startup Taiger earns its stripes with AI technology*. Recuperado de <https://asia.nikkei.com/Business/Business-Spotlight/Singapore-startup-Taiger-earns-its-stripes-with-AI-technology>
- Regader, B. (s.f.). *La Teoría de las Inteligencias Múltiples de Gardner*. Recuperado de <https://psicologiaymente.com/inteligencia/teoria-inteligencias-multiples-gardner>
- Sun R. (2015). *Artificial Intelligence: Connectionist and Symbolic Approaches*. International Encyclopedia of the Social & Behavioral Sciences. Recuperado de <https://www.sciencedirect.com/science/article/pii/B9780080970868430059?via%3Dihub>
- Taulli, T. (2019). *Artificial Intelligence Basics: A Non-Technical Introduction*. Estados Unidos: Apress.
- Real Academia Española. (s.f.). *Inteligencia Artificial*. Recuperado de <https://dle.rae.es/inteligencia>
- Wilkins N. (2019). *Inteligencia Artificial: Una Guía Completa sobre la IA, el Aprendizaje Automático, el Internet de las Cosas, la Robótica, el Aprendizaje Profundo, el Análisis Predictivo y el Aprendizaje Reforzado*. Estados Unidos: Bravex Publications

-
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
 - Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer Science & Business Media.
 - James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning: with Applications in R. Springer.
 - Russell, S. J., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.
 - Rascka, S., & Mirjalili, V. (2019). Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2 (3rd ed.). Packt Publishing.
 - VanderPlas, J. (2016). Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly Media.

Descifra el consejo

N0 r3nunc135 5020
p0rqu3 |4s c0545 53
pu513r0n d1f1c1235;
r3cu3rd4 qu3 51 v423
24 p3n4 n0 53r4 f4c12.



Gracias

[maestrajessicamendez](mailto:maestrajessicamendez@gmail.com)
[@gmail.com](mailto:maestrajessicamendez@gmail.com)