

Problema 1

La matriz de confusión organiza los aciertos y errores del modelo, para un clasificador binario, se estructura de la sig. manera.

	Predicción (+)	Predicción (-)
Clase Real Positiva	TP=50	FN=50
Clase Real Negativa	FP=10	TN=35

2. Accuracy (Exactitud)

Representa el porcentaje total de predicciones correctas

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{50 + 35}{1000} = 0.85$$

$$= 85\%$$

Precision

Mide que tan confiable es el modelo cuando dice que algo es positivo

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{50}{50 + 10} = \frac{50}{60} = 0.833$$

$$= 83.3\%$$

Recall (sensibilidad)

Mide la capacidad del modelo para encontrar todos los casos positivos reales.

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{50}{50 + 50} = \frac{50}{100} = 0.9091$$

$$= 90.9\%$$

F1 - Score

Es la media armónica entre precisión y recall, útil para buscar un equilibrio entre ambos.

$$F1 - \text{Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{precision} + \text{Recall}}$$

$$= \frac{2 \cdot (0.833) \cdot (0.909)}{0.833 + 0.909} = 0.869$$
$$= 86.9\%$$

③ En un contexto médico, la métrica más importante suele ser el recall (sensibilidad).
¿Por qué?

- Un Falso Negativo (FN) en medicina significa decirle a una persona enferma que está sana. Esto es crítico porque el paciente no recibiría tratamiento poniendo en riesgo su vida.

Preferimos tener algunos falsos positivos (personas sanas que se envían a pruebas confirmatorias adicionales), que dejar pasar un solo caso positivo real por alto.

Aunque el Recall es prioritario para no perder enfermos, siempre se debe vigilar que la precisión no sea excesivamente baja.

Problema 2

① No, en datasets desbalanceados, el Accuracy es engañoso.

Si lo calculamos

$$\text{Accuracy} = \frac{8+900}{1000} = 0.908 = 90.8\%$$

A primera vista, el 90% parece excelente, sin embargo, un modelo "tonto" que simplemente diga siempre que "No está enfermo" sin analizar nada tendría un Accuracy del 90% en este dataset. El 90.8% es de hecho peor que el azar estadístico de la clase mayoritaria.

② Identifiquemos los valores

$$TP=8$$

$$FN=2$$

$$FP=90$$

$$TN=900$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{8}{8+2} = \frac{8}{10} = 0.8 = 80\%$$

$$\text{Precisión} = \frac{TP}{TP+FP} = \frac{8}{8+90} = \frac{8}{98} = 0.081 = 8.1\%$$

③ En medicina seguimos priorizando el Recall pero aquí tenemos un dilema ético y operativo.

- Con el Recall del 80% estamos dejando

ir el 20% de los enfermos sin tratamiento 2 de cada 10
-Sin embargo con una precisión del 8.1% de cada 100 personas que el modelo marca como enfermas, más del 90 están sanas, esto causaría una angustia innecesaria masiva y saturación de hospitales con pruebas diagnósticas costosas.

④ No, es un modelo deficiente

① Baja precisión, el modelo es demasiado Paranoico pero poco asertivo, falla demasiado al predecir positivos.

② Recall insuficiente: Para una enfermedad un 20% de omisión (FN) sigue siendo MUY ALTO.

③ Costo de error: Un modelo útil en este escenario debería de subir el recall al menos en un rango del 95-99% sin destruir la precisión.

Actualmente el modelo está adivinando un mejor que el ruido, pero con un costo operativo altísimo por la cantidad de falsos positivos.

Problema 3

Aquí se visualiza el impacto de los valores atípicos (outliers), por la 3era predicción que dispara las métricas de forma distinta.

① MAE (mean absolute error)

Mide las diferencias absolutas, entre el valor real y la predicción. No le importa la dirección del error, solo la magnitud.

$$\text{Error 1: } |100 - 90| = 10$$

$$\text{Error 2: } |200 - 210| = 10$$

$$\text{Error 3: } |300 - 1000| = 700$$

$$\text{MAE} = \frac{10 + 10 + 700}{3} = \frac{720}{3} = 240$$

② MSE, eleva los errores al cuadrado antes de promediarlos. Esto cambia drásticamente el peso de cada error:

$$\text{Error 1: } (100 - 90)^2 = 10^2 = 100$$

$$\text{Error 2: } (200 - 210)^2 = 10^2 = 100$$

$$\text{Error 3: } (300 - 1000)^2 = (-700)^2 = 490,000$$

$$\text{MSE} = \frac{100 + 100 + 490,000}{3} = \frac{490,200}{3} = 163,400$$

③ El MSE, penaliza mucho más los errores grandes ya que al elevar al cuadrado los errores pequeños se mantienen

relativamente bajas pero con los errores grandes crecen de forma exponencial.

Problema 4.

① Interpretación

- Intersección ($b_0 = 5$) es el valor esperado de y cuando tanto x_1 como x_2 son iguales a cero. Es el punto de partida del modelo.
- Coeficiente x_1 ($w_1 = 2$) es una relación positiva contribuyendo a nuestra variable objetivo y aumentará en 2 unidades.
- Coeficiente x_2 ($w_2 = -3$) es una relación negativa y disminuirá en 3 unidades.

② Si x_2 aumenta, el valor de y disminuye. x_2 tiene un impacto o fuerza mayor que x_1 en el resultado final, pero en sentido opuesto. El signo negativo actúa como penalizador. En un escenario real si y fuera la Satisfacción del cliente.

x_1 podría ser Calidad del Producto
 x_2 sería por lo tanto

Tiempo de espera.

Problema 5

La función sigmoide que convierte valores lineales en probabilidades.

① Si sustituimos el valor en la ecuación para ver que probabilidad obtenemos:

• El exponente se vuelve $2(2) - 4 = 4 - 4 = 0$

• La fórmula queda:

$$\frac{1}{1+e^0}$$

Como $e^0 = 1 \therefore \frac{1}{1+1} = \frac{1}{2} = 0.5 = 50\%$

Cuando $x=2$ la probabilidad de que la clase positiva es exactamente del 50%.

② El umbral de decisión estándar suele ser 0.5

En este modelo específico el umbral de decisión en términos de la variable de entrada es $x=2$.

• Si $x > 2$ la probabilidad será mayor a 0.5 el modelo predice la clase 1.

• Si $x < 2$ la probabilidad será menor a 0.5 el modelo predice la clase 0.

③ El coeficiente que acompaña a x (el peso $w=2$)

determina la pendiente o el crecimiento de la curva. Al ser un valor positivo indica que a medida que x aumenta la probabilidad de que $y=1$ también aumenta.

- Su magnitud de 2 nos dice que tan rápido el modelo cambia de opinión.

Entre más grande sea este número más "vertical" será el salto en la curva Sigmoidal haciendo que la transición de las clases sean más abruptas.

El tiempo -4 es el Bias o SESGO y es el que desplaza la curva hacia la derecha.

Si es el bias fuera 0, el punto de indecisión (0.5) estaría exactamente en $x=0$.

Problema 1

La matriz de confusión organiza los aciertos y errores del modelo, para un clasificador binario, se estructura de la sig. manera.

	Predicción +1	Predicción -1
Clase Real Positiva	TP=50	FN=50
Clase Real Negativa	FP=10	TN=35

2. Accuracy (Exactitud)

Representa el porcentaje total de predicciones correctas

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{50 + 35}{1000} = 0.85$$

$$= 85\%$$

Precision

Mide que tan confiable es el modelo cuando dice que algo es positivo

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{50}{50 + 10} = \frac{50}{60} = 0.833$$

$$= 83.3\%$$

Recall (sensibilidad)

Mide la capacidad del modelo para encontrar todos los casos positivos reales.

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{50}{50 + 50} = \frac{50}{100} = 0.9091$$

$$= 90.9\%$$

F1 - Score

Es la media armónica entre precisión y recall, útil para buscar un equilibrio entre ambos.

$$F1 - \text{Score} = \frac{2 \cdot \text{Precisión} \cdot \text{Recall}}{\text{precisión} + \text{Recall}}$$

$$= \frac{2 \cdot (0.833) (0.909)}{0.833 + 0.909} = 0.869$$
$$= 86.9\%$$

③ En un contexto médico, la métrica más importante suele ser el recall (sensibilidad).
¿Por qué?

• Un Falso Negativo (FN) en medicina significa decirle a una persona enferma que está sana. Esto es crítico porque el paciente no recibiría tratamiento poniendo en riesgo su vida.

Preferimos tener algunos falsos positivos (personas sanas que se envían a pruebas confirmatorias adicionales), que dejar pasar un solo caso positivo real por alto.

Aunque el Recall es prioritario para no perder enfermos, siempre se debe vigilar que la precisión no sea excesivamente baja.

Problema 2

① No, en datasets desbalanceados, el Accuracy es engañoso.

Si lo calculamos

$$\text{Accuracy} = \frac{8+900}{1000} = 0.908 = 90.8\%$$

A primera vista el 90% parece excelente, sin embargo, un modelo "tonto" que simplemente diga siempre que "No está enfermo" sin analizar nada tendría un Accuracy del 90% en este dataset. El 90.8% es de hecho peor que el azar estadístico de la clase mayoritaria.

② Identifiquemos los valores

$$TP=8$$

$$FN=2$$

$$FP=90$$

$$TN=900$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{8}{8+2} = \frac{8}{10} = 0.8 = 80\%$$

$$\text{Precisión} = \frac{TP}{TP+FP} = \frac{8}{8+90} = \frac{8}{98} = 0.081 = 8.1\%$$

③ En medicina seguimos priorizando el Recall pero aquí tenemos un dilema ético y operativo.

- Con el Recall del 80% estamos dejando

ir el 20% de los enfermos sin tratamiento 2 de cada 10
-Sin embargo con una precisión del 8.1% de cada 100 personas que el modelo marca como enfermas, más del 90 están sanas, esto causaría una angustia innecesaria masiva y saturación de hospitales con pruebas diagnósticas costosas.

④ No, es un modelo deficiente

① Baja precisión, el modelo es demasiado paranoico pero poco asertivo, falla demasiado al predecir positivos.

② Recall insuficiente: Para una enfermedad un 20% de omisión (FN) sigue siendo MUY ALTO.

③ Costo de error: Un modelo útil en este escenario debería de subir el recall al menos en un rango del 95-99% sin destruir la precisión.

Actualmente el modelo está adivinando un mejor que el ruido, pero con un costo operativo altísimo por la cantidad de falsos positivos.

Problema 3

Aquí se visualiza el impacto de los valores atípicos (outliers), por la 3era predicción que dispara las métricas de forma distinta.

① MAE (mean absolute error)

Mide las diferencias absolutas entre el valor real y la predicción. No le importa la dirección del error, solo la magnitud.

$$\text{Error 1: } |100 - 90| = 10$$

$$\text{Error 2: } |200 - 210| = 10$$

$$\text{Error 3: } |300 - 1000| = 700$$

$$\text{MAE} = \frac{10 + 10 + 700}{3} = \frac{720}{3} = 240$$

② MSE, eleva los errores al cuadrado antes de promediarlos. Esto cambia drásticamente el peso de cada error:

$$\text{Error 1: } (100 - 90)^2 = 10^2 = 100$$

$$\text{Error 2: } (200 - 210)^2 = 10^2 = 100$$

$$\text{Error 3: } (300 - 1000)^2 = (-700)^2 = 490,000$$

$$\text{MSE} = \frac{100 + 100 + 490,000}{3} = \frac{490,200}{3} = 163,400$$

③ El MSE, penaliza mucho más los errores grandes ya que al elevar al cuadrado los errores pequeños se mantienen

relativamente bajos pero con los errores grandes crecen de forma exponencial.

Problema 4.

① Interpretación

- Intersección ($b_0 = 5$) es el valor esperado de y cuando tanto x_1 como x_2 son iguales a cero. Es el punto de partida del modelo.
- Coeficiente x_1 ($w_1 = 2$) es una relación positiva contribuyendo a nuestra variable objetivo y aumentará en 2 unidades.
- Coeficiente x_2 ($w_2 = -3$) es una relación negativa y disminuirá en 3 unidades.

② Si x_2 aumenta, el valor de y disminuye. x_2 tiene un impacto o fuerza mayor que x_1 en el resultado final, pero en sentido opuesto. El signo negativo actúa como penalizador. En un escenario real si y fuera la Satisfacción del cliente.

x_1 podría ser Calidad del Producto
 x_2 sería por lo tanto

Tiempo de espera.

Problema 5

La función sigmoide que convierte valores lineales en probabilidades.

① Si sustituimos el valor en la ecuación para ver que probabilidad obtenemos:

• El exponente se vuelve $2(2) - 4 = 4 - 4 = 0$

• La fórmula queda:

$$\frac{1}{1+e^0}$$

Como $e^0 = 1 \therefore \frac{1}{1+1} = \frac{1}{2} = 0.5 = 50\%$

Cuando $x=2$ la probabilidad de que la clase positiva es exactamente del 50%.

② El umbral de decisión estándar suele ser 0.5

En este modelo específico el umbral de decisión en términos de la variable de entrada es $x=2$.

• Si $x > 2$ la probabilidad será mayor a 0.5 el modelo predice la clase 1.

• Si $x < 2$ la probabilidad será menor a 0.5 el modelo predice la clase 0.

③ El coeficiente que acompaña a x (el peso $w=2$)

determina la pendiente o el crecimiento de la curva. Al ser un valor positivo indica que a medida que x aumenta la probabilidad de que $y=1$ también aumenta.

- Su magnitud de 2 nos dice que tan rápido el modelo cambia de opinión.


Entre más grande sea este número más "vertical" será el salto en la curva Sigmoidal haciendo que la transición de las clases sean más abruptas.

El tiempo -4 es el Bias o SESGO y es el que desplaza la curva hacia la derecha.

Si es el bias fuera 0, el punto de indecisión (0.5) estaría exactamente en $x=0$.

Problema 6

①



clase +1 {azul} : (2,2) y (3,3)
 clase -1 {roja} : (0,0) y (1,1)

- ② Como todos los puntos están sobre $y=x$ son perfectamente separables por una recta perpendicular a esa diagonal, que pasa entre (2,2) y (1,1).
 Una recta que lo separa intuitivamente es $x+y=3$

Comprobación

- C: Para (0,0): $0+0=0 < 3 \rightarrow$ lado -1
 D: Para (1,1): $1+1=2 < 3 \rightarrow$ lado -1
 A: Para (2,2): $2+2=4 > 3 \rightarrow$ lado +1
 B: Para (3,3): $3+3=6 > 3 \rightarrow$ lado +1

Alternativa Simétrica:

La recta $x+y=3$ está bien pero también podríamos elegir $x+y=3.5$ o una bisectriz perpendicular exacta entre los puntos más cercanos

El punto medio entre (1,2) y (2,2) es (1.5,1.5)

Una recta perpendicular $xy = x$ tiene pendiente -1 .

Ecuación que pasa por $(1.5, 1.5)$ con pendiente -1 .

$$y - 1.5 = -(x - 1.5)$$

$$y = -x + 3$$

$$y + x = 3$$

Los vectores de soporte es SVM son los puntos más cercanos al margen de separación aquellos que sostienen al margen máximo.

Entre los puntos de una clase y otra, la menor distancia entre el plano de características aquí es el mismo plano (x, y) ocurre entre $(1, 1)$ de la clase -1 y $(2, 2)$ de la clase $+1$.

Por lo tanto

vectores de soporte $(1, 1)$ y $(2, 2)$ los puntos $(0, 0)$ y $(3, 3)$ no son de soporte porque están más lejos de la recta $x + y = 3$ y no definen el margen.

Problema 7

① un SVM lineal busca separar las clases mediante una línea recta en 2D o un hiperplano en dimensiones superiores.

Si los datos están mezclados de tal forma que no existe ninguna línea recta capaz de dividir los grupos sin cometer errores masivos (como cuando una clase rodea a la otra) el modelo lineal simplemente no puede encontrar una solución válida. Por lo tanto falla cuando los datos no son linealmente separables.

② El truco del Kernel permite proyectar los datos de su espacio original a un espacio de mayor dimensión donde sí sean linealmente separables sin necesidad de calcular explícitamente esa transformación (truco del Kernel).

Beneficios:

1. Encontrar separaciones no lineales en el espacio original
2. Mantener la eficiencia computacional del SVM lineal.

3. Usar funciones como polinomial, RBF Signoide

Formula clave

$$R(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

El SVM trabaja con productos punto en el espacio transformado $\phi(x)$.

ϕ : función que lleva los datos a un espacio más complejo para que el SVM funcione mejor.

- ③ Imagina el tiro al blanco, los puntos rojos son el centro y los puntos azules son el amarillo exterior. No puedes pasar una línea recta que los separe.
Al aplicar un Kernel RBF (Radial Basis Function)

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right)$$

El modelo mide la distancia de cada punto hacia un centro.

- Los puntos del centro (rojos) 'se elevan' en una tercera dimensión (2) mientras que los anillos azules se quedan abajo.

Graciela Lago

14-Abril-2026

Problema 7 continuación

Ahora puedes pasar por un plano horizontal como una hoja de papel entre los puntos elevados y los puntos de abajo.

Al proyectar ese corte de regreso al plano 2D, se ve como un círculo perfecto.

④ Un ejemplo clásico es el reconocimiento de rostros ó la clasificación de imágenes complejas.

En una imagen, los píxeles no tienen una relación lineal sencilla. Las características que definen un ojo o una boca dependen de combinaciones no lineales de luz y sombra.

Un Kernel permite al SUM entender esas fronteras curvas y complejas para distinguir entre diferentes personas o tipos de objetos.

Problema 8

Para clasificar el nuevo punto (3,3), observamos las distancias, usando la distancia euclidiana por inspección visual, ya que todos están en la misma diagonal $y=x$.

Clase A distancia a (2,2)

$$\sqrt{(3-2)^2 + (3-2)^2} = \sqrt{2} = 1.41$$

Clase B distancia a (4,4)

$$\sqrt{(3-2)^2 + (3-2)^2} = \sqrt{2} = 1.41$$

en este caso (3,3) esta a la misma distancia pero en caso de empate se elige al azar o por aparición.

* Para $k=1$ buscamos al vecino más cercano el cual sería (2,2) de la clase A (6,4) de la clase B ya que ambas están a la misma distancia mínima

② Con $k=3$ buscamos los 3 vecinos más cercanos:

(2,2) clase A: Distancia 1.41

(4,4) clase B: Distancia 1.41

(1,1) clase C: Distancia 2.82

Al hacer la votación:

Votos clase A: 2 puntos (2,2) y (1,1)

Votos clase B: 1 punto (4,4)

La clase ganadora es la clase A

Continuación Problema 8

③ Lo que cambia es la estabilidad de la predicción y la sensibilidad del ruido:

- Con k pequeño (como $k=1$). El modelo es muy sensible. Si $(2,2)$ fuera un dato ruidoso ó un error de medición la predicción cambia por completo.

Es un modelo con tendencia al overfitting.

- Con k más grande ($k=3$) la decisión se vuelve más democrática. Al considerar más vecinos, el modelo suaviza la frontera de decisión y es menos probable que un solo dato atípico arruine la clasificación.

Problema 9

① KNN Calcula distancias euclidianas por lo general entre puntos.

Problema edad: rango 0-100

ingreso: 0-1,000,000

La escala del ingreso es mucho mayor (millones) comparados con la edad.

Por lo tanto la distancia sería

$$d = \sqrt{(edad_i - edad_j)^2 + (ingreso_i - ingreso_j)^2}$$

La diferencia en ingreso domina completamente la distancia.

Consecuencias prácticas:

- La variable edad prácticamente no influye en la clasificación.
- El algoritmo se comporta como si solo usará el ingreso, perdiendo información valiosa.
- Vecinos cercanos se eligen casi exclusivamente por similitud en ingreso.

② Solución: Escalar las variables para que tengan magnitudes comparables.

Existen 2 técnicas comunes:

a) Normalización (Min-Max Scaling)

Lleva los datos a un rango fijo, por ejemplo: $[0, 1]$:

$$X' = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Aplicando

Edad normalizada a $[0, 1]$

Ingreso normalizado a $[0, 1]$

Ambas variables contribuyen por igual a la distancia.

continuación Pregunta 9

b) Estandarización (Z-score scaling)

Media = desviación estándar = 1

$$x' = \frac{x - \mu}{\sigma}$$

• Util para valores atípicos outliers.

Problema 10.

Naive Bayes asume que las características (A y B) son independientes entre sí dada la clase. La fórmula simplificada para la probabilidad posterior es:

$$P(\text{clase} | A, B) \propto P(A | \text{clase}) \cdot P(B | \text{clase}) \cdot P(\text{clase})$$

① $P(A | \text{Spam}) = 0.6$

$P(B | \text{Spam}) = 0.7$

$P(\text{Spam}) = 0.4$

$P(\text{Spam} | \text{datos}) \propto (0.6)(0.7)(0.4) = 0.168$

② $P(A | \text{No Spam}) = 0.2$

$P(B | \text{No Spam}) = 0.3$

$P(\text{No Spam}) = 0.6$

$P(\text{No Spam} | \text{datos}) \propto (0.2)(0.3)(0.6) = 0.036$

③ Comparamos ambos resultados y clasificar viendo cual es el mayor.

Es Spam ya que $0.168 > 0.036$

④ No. En el mundo real, casi nunca existe una

independencia absoluta entre las características por eso el algoritmo se llama Naive (ingenuo).

Gretel Lugo

DÍA MES AÑO

21 abril 2020

Problema 1

- ① Sumamos el total de instancias (S) para obtener el denominador de nuestras probabilidades.

Clase Sí: 6 Total (N) = 6 + 4 = 10

Clase No: 4

Las probabilidades (P_i):

$$P(\text{Sí}) = 6/10 = 0.6 \quad P(\text{No}) = 4/10 = 0.4$$

- ② La entropía de Shannon para un conjunto de datos se define como:

$$H(S) = - \sum_{i=1}^n P_i \log_2(P_i)$$

Para nuestro caso binario (2 clases) la fórmula extendida es:

$$H(S) = - [P(\text{Sí}) \log_2(p(\text{Sí})) + p(\text{no}) \log_2(p(\text{no}))]$$

- ③ Sustituimos los valores en la fórmula:

① Término para "Sí"

$$0.6 \times \log_2(0.6) = (0.6) (-0.737) \approx -0.4422$$

② Término para "No"

$$0.4 \times \log_2(0.4) = (0.4) (-1.3214) \approx -0.5287$$

$$H(S) = -(-0.4422 - 0.5287)$$

$$H(S) = -(-0.9709)$$

$$H(S) = 0.9709 \text{ bits/}$$

Nota:

$$\frac{\log_{10}(x)}{\log_{10}(2)} = \log_2(x)$$

Gretel Lugo

DÍA MES AÑO

21 abril 2026

Interpretación

Como el valor esta muy cerca de 1 (0.9709) el nodo tiene una impureza alta. Si tuvieramos 5 "Si" y 5 "No" la entropía sería exactamente 1. (máxima incertidumbre).

Problema 2


1. Analizamos la columna objetivo "Jugar"

Total de casos: 8 Si: 4 No: 4

Como la distribución es perfecta (50/50) la incertidumbre es máxima.

$$H(S) = -[0.5 \log_2(0.5) + 0.5 \log_2(0.5)] = 1.0$$

ARBOL



② Ganancia de información

$$IG(S, A) = H(S) - \sum_{|S_v|} \frac{|S_v|}{|S|} H(S_v)$$

a. Clima

Analizamos cada valor del clima respecto a jugar:

- Soleado (3 casos): 0 Sí, 3 No $\rightarrow H(\text{Soleado}) = 0$
- Nublado (2 casos): 2 Sí, 0 No $\rightarrow H(\text{Nublado}) = 0$
- Lluvioso (3 casos): 2 Sí, 1 No $\rightarrow H(\text{Lluvioso})$
 $= -\left[\frac{2}{3} \log_2 \left(\frac{2}{3}\right) + \frac{1}{3} \log_2 \left(\frac{1}{3}\right)\right] \approx 0.918$

Entropía Residual (Clima):

$$\frac{3}{8}(0) + \frac{2}{8}(0) + \frac{3}{8}(0.918) \approx 0.344$$

$$|G(\text{Clima})| = 1 - 0.344 = 0.656$$

b. Humedad

- Alta (3 casos): 1 Sí, 2 No $\rightarrow H: 0.918$
- Media (2 casos): 1 Sí, 1 No $\rightarrow H: 1$
- Baja (3 casos): 2 Sí, 1 No $\rightarrow H: 0.918$

Entropía Residual Humedad

$$\frac{3}{8}(0.918) + \frac{2}{8}(1) + \frac{3}{8}(0.918) = 0.938$$

$$|G(\text{Humedad})| = 1 - 0.938 = 0.062$$

c. Viento

- No (5 casos): 3 Sí, 2 No $\rightarrow H: 0.971$
- Sí (3 casos): 1 Sí, 2 No $\rightarrow H: 0.918$

$$\text{Entropía Residual viento: } \frac{5}{8}(0.971) + \frac{3}{8}(0.918) = 0.951$$

$$|G(\text{Viento})| = 1.0 - 0.951 = 0.049$$

③ Comparamos las ganancias

$$\begin{aligned} |G(\text{Clima}) &= 0.656 && \text{Ganador} \\ |G(\text{Humedad}) &= 0.062 \\ |G(\text{Viento}) &= 0.049 \end{aligned}$$

El nodo Raíz del árbol es el clima

④ Al dividir por clima observamos los subconjuntos resultantes.

- ① Si clima es Soleado: Todos los nodos son "No" (Hoja para)
- ② Si clima es Nublado: Todos los casos son sí. (Hoja para)

3- Si clima = Lluvioso: El subconjunto es [sí, sí, No]

Aquí hay una ganancia para Humedad y viento que calcular

5. Repetición para el nodo Lluvioso


Si observamos los datos originales cuando llueve.

- Lluvioso + Humedad Media + Viento No → sí
- Lluvioso + Humedad Baja + Viento No → sí
- Lluvioso + Humedad Baja + Viento sí → No

Aquí el viento separa perfectamente:

Si no hay viento - se juega
Si hay viento → no se juega.

ARBOL



[1, 0, 1, 1, 0]

1. En un problema de clasificación (etiqueta 0, 1) Random Forest utiliza el mecanismo de votación Mayorista (Majority Voting).
 - Predicciones individuales: $\{1, 0, 1, 1, 0\}$
 - Conteo de votos
 - Clase 1: 3 votos
 - Clase 0: 2 votos
 - Resultados: Como $3 > 2$, la predicción final del ensamble es 1.
2. 1. La ley de los grandes números: Al promediar o votar los resultados de múltiples modelos independientes, el error aleatorio de cada uno tiende a cancelarse. Un solo árbol puede ser muy sensible al ruido de los datos de alta varianza, pero el promedio es mucho más estable.
2. Descorrelación: Gracias al Bootstrapping (muestreo aleatorio por reemplazo) y a la selección aleatoria de características (Feature Randomness) cada árbol "ve" una versión ligeramente distinta al problema. Si los árboles fueran idénticos, la varianza sería la misma, al ser diferentes sus errores no coinciden.
3. Efecto "Sabiduría de las Masas": Es menos probable que la mayoría de los árboles se equivoquen al mismo tiempo en la misma dirección, lo que suaviza la frontera de decisión y evita el overfitting.

GreteL Lugo

DÍA MES AÑO

21 abril 2028

- Si le preguntas a un solo médico, su diagnóstico puede estar sesgado por su experiencia, particular (varianza).
- Si juntas a 100 médicos y tomas la opinión de la mayoría, el diagnóstico final es mucho más robusto y menos propenso a errores individuales.

Problema 4

1. Un árbol con profundidad 20 es extremadamente complejo. El problema principal es el Overfitting (sobreajuste).

- Al ser tan profundo, el árbol deja de aprender patrones generales y comienza a "memorizar" el ruido y los casos particulares del dataset de entrenamiento.
- Consecuencia: Tendrá un error casi nulo en el entrenamiento, pero fallará drásticamente con datos nuevos, poca capacidad de generalización.

2. Random Forest no solo combina árboles, sino que introduce aleatoriedad para forzar la generalización mediante dos mecanismos:

- Bagging (Bootstrap Aggregating): Cada árbol se entrena con una muestra distinta de los datos.

- Feature Randomness: En cada división (split), el árbol solo puede elegir entre un subconjunto aleatorio de características.

Esto evita que un solo atributo domine el árbol, permitiendo que el bosque capture diferentes perspectivas de los datos.

3. Si eliminamos la aleatoriedad y todos los árboles son idénticos:

1. La varianza no se reduce: El error que comente un árbol lo cometerán todos. Votar entre 100 personas que piensan exactamente igual no aporta nueva información.
2. Se pierde la "Subadicia de las masas": el ensamble heredaría el overfitting del árbol individual de profundidad 20.
3. Resultados: El modelo deja de ser un 'Random' Forest y se convierte simplemente en un árbol individual repetido, perdiendo toda la ventaja del aprendizaje por conjunto.

La diversidad del Bosque es lo que permite que el error de un árbol sea compensado por el acierto de otros.

Si no hay diversidad, no hay robustez.

Problema 5:

1. Calcular Errores

En Boosting, los residuos son la diferencia entre el valor real y la predicción actual.

Representa "lo que el modelo aún no explica"

La fórmula es: $\text{Residuo} = y - y_{\text{pred}}$

• Para $y_1 = 12 - 10 = 2$

• Para $y_2 = 8 - 10 = -2$

• Para $y_3 = 15 - 10 = 5$

Vector residuo: $[2, -2, 5]$

Gretel Lugo

DÍA MES AÑO

21 abril 2028

2. Entrenar

A diferencia de Random Forest, donde cada árbol intenta predecir y , en Gradient Boosting el siguiente modelo (n) se entrena para predecir los residuos generados por el modelo anterior.

- Objetivo de Árbol 2: Aprender el patrón del vector $[2, -2, 5]$.

- Intuición: El nuevo modelo intentará entender porque nos faltarán 2 unidades en el primer caso, porque nos pasamos por 2 en el segundo y porque nos faltaron 5 en el tercero.

3. La nueva predicción no reemplaza a la anterior, si no que le suma (generalmente multiplicada por una tasa de aprendizaje o learning rate η).

$$y_{nueva} = y_{inicial} (\eta \times \text{predicción del residuo})$$

- Si $\eta = 0.1$ y el nuevo modelo predice perfectamente los residuos:

- Para el primer dato: $10 + (0.1 \times 2) = 10.2$

- Resultado: La predicción se mueve lentamente hacia el valor real. En cada paso (iteración) el error global disminuye.

- Bagging (RF): Árboles independientes en paralelo. El error se reduce promediando.

- Boosting (X. a Boost): Árboles secuenciales. Cada árbol intenta corregir los errores del anterior, reduce el sesgo.

Grete Lugo

DÍA MES AÑO

23 abril 2026

Problema 6

1. Diferencias Principales

Características	Random Forest Bagging	Gradient Boosting
Construcción	En paralelo (árboles independientes)	Secuenciales (un árbol tras otro)
Objetivo	Reducir varianza (evitar overfitting)	Reducir el sesgo (mejorar la precisión)
Mecanismo	Cada árbol vota, se promedian	Cada árbol corrige el error del anterior.
Sensibilidad	Robusto frente a datos ruidosos.	Sensible a valores atípicos (outliers).

2. Gradient Boosting sobre ajusta más fácilmente como su objetivo es reducir el error a toda costa, si le damos demasiadas iteraciones (árboles) o una tasa de aprendizaje muy alta, el modelo terminará aprendiendo perfectamente el ruido de los datos de entrenamiento. En Random Forest agregar más árboles no suele causar overfitting, en Boosting sí.

Por eso en XGBoost es vital usar Early Stopping.

3. En términos estrictos, ambos son modelos de "caja negra" comparados con un sólo árbol de decisión, pero:

- Random Forest suele considerarse ligeramente más interpretable de manera empírica.

ES más fácil entender el impacto promedio de las variables a través del "Feature importance" global.

- Gradient Boosting es más complejo de interpretar porque el efecto de una variable en el árbol 100 depende de lo que hicieron los 99 árboles anteriores.
- Herramientas de apoyo: Para ambos casos en la industria usamos valores SHAP o LIME para poder explicar estas predicciones a un cliente o usuario final.
- Si quieres un modelo rápido de entrenar y difícil de romper: Random Forest.
- Si buscas la máxima precisión posible y tienes tiempo para tunear hiperparámetros Gradient Boosting (XGBoost, LightGBM)

Gretel hugo

DÍA MES AÑO

23 abril 2020

Problema 7

- ① Distancia Euclidiana (asignación de clusters)
Calculamos la distancia de cada punto a las
centroides iniciales C_1 y C_2 .
Por aspecto visual o aplicando

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- (1,1): Distancia a $C_1 = 0$. Se queda en el cluster 1
- (2,2): Está más cerca del $C_2 (9,9)$, se queda en el cluster 2.
- (9,9): Distancia a $C_2 (9,9)$ es 0. Se queda en cluster 2.

Grupos resultantes: $G_1: \{(1,1), (2,2)\}$
 $G_2: \{(8,8), (9,9)\}$

- ② Para calcular centroides, el nuevo centroide es el promedio (la media) de los puntos asignados a cada grupo.

- Nuevo C_1 : $C_1 = \left(\frac{1+2}{2}, \frac{1+2}{2} \right) = (1.5, 1.5)$

• Nuevo C_2 : $C_2 = \left(\frac{8+9}{2}, \frac{8+9}{2} \right) = (8.5, 8.5)$

- ③ Una iteración más (¿Hay cambios?)
Volvemos a evaluar la cercanía de los
puntos con los nuevos centroides (8.5, 8.5) y (1.5, 1.5)

1. (1,1) y (2,2) siguen estando mucho más cerca de 1.5 que de 8.5 se mantienen en el cluster 1.

2. $(8,8)$ y $(9,9)$ siguen estando mucho más cerca de 8.5 que de 1.5

Se mantienen en el cluster 2.

Conclusión: Como la asignación de los puntos no cambio, los centroides tampoco cambiarán en la siguiente suma.

El algoritmo ha convergido.

Problema 8

1. Si elegimos un valor de K menor al número natural de grupos en los datos (por ejemplo $K=1$).

- **Subajuste** (Underfitting): El modelo agrupa datos que son muy diferentes entre sí en un mismo cluster.

Inercia total 0 alta: La suma de las distancias al cuadrado dentro de los clusters será muy grande porque los puntos estén lejos de su centroide.

2. Si elegimos un valor de K excesivo (por ejemplo $K=N$, donde N es el número de puntos):

- **Sobrec ajuste** (Overfitting): Cada podría terminar siendo su propio cluster.

- Fragmentación: Se pierde el propósito del clustering, que es encontrar estructuras generales. La inercia será 0, pero el modelo no tendrá utilidad práctica.

Continuación Problema 8

3. Método del codo (Elbow Method)

Este método busca "el punto de equilibrio" donde añadir un cluster más ya no reduce significativamente la inercia (wcss-within-cluster sum of squares).

Supongamos que calculamos la inercia para diferentes valores de k en un dataset:

k (clusters)	Inercia (wcss)	Reducción de Inercia
1	500	-
2	250	250
3	100	150 (punto de inflexión)
4	85	15
5	75	10

Análisis del ejemplo (tabla):

1. Al pasar de $k=1$ a $k=2$ la inercia baja drásticamente 250 unidades.
2. De $k=2$ a $k=3$ baja otras 150 unidades.
3. De $k=3$ a $k=4$, la mejora es mínima (solo 15 unidades).

Resultado: El codo está en $k=3$, a partir de ahí, el esfuerzo computacional de añadir más clusters no vale la pena por la poca ganancia de precisión.

Gretel Lago

DÍA MES AÑO

23 abril 2026

Problema 9

Parámetros de control

$\text{eps}(\text{Epsilon}) = 2$ El radio máximo para buscar vecinos.

$\text{minpts} = 3$ El número mínimo de puntos (incluyéndose a sí mismo) para ser núcleo.

① Análisis de Vecindades (N).

Evalúamos cuántos vecinos tiene cada punto a una distancia ≤ 2 :

1. Punto A (1,1):

vecinos: (2,1) $\text{dist} = 1$; (2,2) $\text{distancia} = \sqrt{2} = 1.41$

total: 3 puntos en su vecindad

2. Punto B (2,1):

vecinos: (1,1) $\text{distancia} = 1$; (2,2) $\text{distancia} = 1$.

total: 3 puntos en su vecindad.

3. Punto C (2,2):

vecinos: (1,1) $\text{dist} = 1.41$; (2,1) $\text{dist} = 1$

total: 3 puntos en su vecindad.

4. Punto D (3,3):

vecinos: ninguno cerca

total: 1 punto (él mismo)

② Clasificación final

• Puntos **NÚCLEO** (core): Aquellos con ≥ 3 puntos en su radio.
Resultado: (1,1) (2,1) y (2,2)

• Puntos **Borde** (Border): Aquellos con menos de 3 puntos, pero que son alcanzables desde el núcleo.

Gretel Lago

DÍA MES AÑO

23 abril 2026

continuación problema 9

• Resultado: Ninguno (En este caso todos los puntos cercanos cumplieron para ese núcleo).

- Puntos **Ruido** (Noise/outlier): Aquellos que no son núcleo ni son alcanzables por uno.

- Resultado: (8,8)

En DBSCAN, el modelo tiene la "honestidad" de decir: "Esto es ruido y no pertenece a ningún patrón". En K-means, el punto pertenecer a un grupo.

En DBSCAN están diferente a K-Means: aquí no hay centros, hay vecindades.

Un punto se incluye así mismo en el centro de su vecindad.

Problema 10

① z-score

Para saber qué tan extraño es un punto calculamos cuántas desviaciones estándar se aleja de la media del grupo.

① calcular la media ($\bar{x}$)

$$\bar{x} = \frac{10+12+11+17+100}{5} = \frac{146}{5} = 29.2$$

② Calcular la varianza (σ^2)

Calculamos la diferencia de cada punto con respecto a la media, la elevamos al cuadrado y promediamos:

$$1. (10 - 29.2)^2 = 368.64$$

$$2. (12 - 29.2)^2 = 295.84$$

$$3. (11 - 29.2)^2 = 331.24$$

$$4. (13 - 29.2)^2 = 262.44$$

$$5. (100 - 29.2)^2 = 5012.64$$

$$\sigma^2 = \frac{368.64 + 295.84 + 331.24 + 262.44 + 5012.64}{5}$$

$$= 6270.8 / 5 = 1254.16$$

Calcular la desviación estándar σ

$$\sigma = \sqrt{1254.16} = 35.41$$

Calcular el z-score del punto sospechoso (100)

La fórmula es $z = \frac{x - \bar{x}}{\sigma}$

$$z = \frac{100 - 29.2}{35.41} \approx 1.$$

Regla de Cro:

Normalmente en una distribución normal cualquier punto con un $|z| > 3$

se considera una **anomalía extrema**.

Aunque 1.99 no llega a 3 (porque el dataset es muy pequeño y 100 "jala" la media hacia arriba, los otros puntos tienen z-scores negativos o muy cercanos a 0:

Para 12:

$$z = \frac{12 - 29.2}{35.41} = -0.48$$

$z_{100} \approx 2$ frente $z_{12} = -0.48$ la diferencia de magnitud es evidente. El punto 100 está a casi 2 desviaciones estándar de la media mientras que el resto está amontonado en el lado negativo, confirmando matemáticamente que el 100 es un outlier.

Greteel Logo

DÍA MES AÑO

23 abril 2020

continuación 10

② El algoritmo de Isolation Forest funciona bajo una premisa simple: las anomalías son pocas y diferentes.

- Para aislar un punto el algoritmo realiza particiones aleatorias.
- Debido a que el 100 está muy alejado del resto, es mucho más probable que una línea de corte aleatoria lo separe del grupo principal en los primeros intentos.
- Intuición: Es mucho más fácil separar a una persona que está sola en un campo que una que está en medio de una multitud.

③ En este contexto, la profundidad se refiere a cuantas particiones (o niveles del árbol) se necesitaban para aislar un punto.

- Profundidad **Corta**: Significa que el punto se aísla en muy pocos pasos.

Esto es un indicador directo de que el punto es una **anomalía**.

- Profundidad **Larga**: los puntos que están muy agrupados (como el 10, 11 y 12) requieren muchas más particiones aleatorias para ser separadas individualmente.

Por lo tanto, una profundidad mayor indica que el punto es **normal**.